DATENFUSION

Druckfassung der Vorlesung Datenfusion

Hochschule Esslingen – Fakultät Informatik und Informationstechnik

Prof. Dr.-Ing. R. Marchthaler

SS 2024

Version: 22. März 2024

Inhaltsverzeichnis

I Einleitung **4**

1 Informationen zum Kurs **4**

1.1 Kursaufbau 4

1.2 Skript/Literatur 4

1.3 Notationen 5

2 Überblick **5**

2.1 Einführendes Beispiel 5

2.2 Beispiel Abhängigkeiten 7

2.3 Beispiel Schätzung unbekannter Größen 7

2.4 Zusammenfassung 8

II Grundlagen **9**

3 Wahrscheinlichkeitstheorie **9**

3.1 Definitionen und Begriffe 9

3.2 Dichtefunktion 11

3.3 Momente und zentrale Momente 13

3.4 Wichtige empirische Kenngrößen 14

3.5 Lernziele 20

4 Signaltheorie **20**

4.1 Stochastischer Prozess 20

4.2 Autokorrelation 21

4.3 Kreuzkorrelation 25

4.4 Lernziele 28

III Datenfusion zeitinvarianter Größen 29

5 Datenfusion zeitinvariante Größen 29

5.1 Schätzung Skalar . . . 29
5.2 Schätzung Vektor . . . 32
5.3 Gewichtete Schätzungen . . . 34
5.4 Lernziele . . . 39

IV Kalman-Filter 40

6 Zeitvariante Größen 40

6.1 Zustandsraum . . . 40
6.2 Systemeigenschaften . . . 44
6.3 Zeitdiskrete Systeme . . . 46
6.4 System- und Messrauschen . . . 50
6.5 Lernziele . . . 53

7 Klassisches Kalman-Filter 54

7.1 Herleitung Filtergleichungen . . . 54
7.2 Beispiel 1: Beta-Filter . . . 58
7.3 Kochrezept . . . 67
7.4 Beispiel 2: Alpha-Filter . . . 69
7.5 Beispiel 3: Gamma-Filter . . . 75
7.6 Modellierung Systemrauschens . . . 82
7.7 Lernziele . . . 82

V ROSE-Filter 83

8 ROSE-Filter 83

8.1 Kalman-Verstärkung . . . 83
8.2 Aufbau ROSE-Filter . . . 84
8.3 Beispiel ROSE-Filter . . . 86

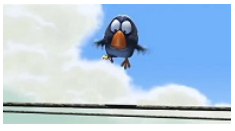
VI Nichtlineare-Filter 89

9 Spezielle Gauß-Filter 89

9.1 EKF . . . 89
9.2 UKF . . . 90
9.3 IF . . . 91
9.4 Lernziele . . . 91

10 Partikelfilter 92

10.1 Algorithmus . . . 92
10.2 Bsp: nichtlin. Funktion . . . 96
10.3 Lernziele . . . 99



VII Markov-Ketten **100**

11 Grundlagen **100**

11.1 Deterministischer Automat 100

11.2 Bedingte Wahrscheinlichkeit 102

12 Markov-Kette (Nichtdeterministischer Automat) **103**

12.1 Zeitdiskrete Markov-Kette 103

12.2 Zeitkontinuierliche Markov-Kette 105

12.3 Lernziele 108

13 Hidden-Markov-Kette (Hidden-Markov-Modell) **108**

13.1 Allgemeines 108

13.2 Schätzung der unbekannten Zustände 109

13.3 Ausblick 111

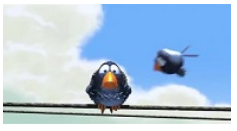
13.4 Lernziele 111

VIII Anhang **112**

Vektor- und Matrizenrechnung **112**

Literatur **118**

Folie 0.2



Teil I
Einleitung

1 Informationen zum Kurs

1.1 Aufbau des Kurses

Bausteine des Kurses

- Klassische „Frontalvorlesung“ im Seminarstil
  I. Einleitung
  II. Grundlagen
  III. Datenfusion zeitinvarianter Größen
  IV. Kalman-Filter
  V. ROSE-Filter
  VI. Nichtlineare-Filter
  VII. Markov-Ketten

- Übungen/Labor

Folie 1.4

1.2 Skript/Literatur

Unterrichtmaterial, Literaturempfehlung und weiterführende Literatur

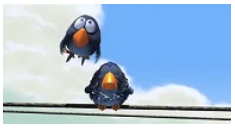
Unterrichtmaterial

- Skript in moodle Kurs „Datenfusion“.
- Selbsteinschreibung, PW: „Dtnfsn“

Literaturempfehlung und weiterführende Literatur

1. Richard E. Neapolitan: *„Learning Bayesian Networks“*. Prentice Hall, 2003
2. Olle Häggström: *„Finite Markov Chains and Algorithmic Applications“*. Cambridge University Press, 2002
3. Brown, R. G.; Hwang, P. Y. C.: *„Introduction to Random Signals and Applied Kalman Filtering“*. Third Edition. John Wiley & Sons, Inc., 2012
4. Simon, Dan: *„Optimal State Estimation“*, John Wiley & Sons, Inc., 2006
5. Thrun, S.; u.a.: *„Probabilistic Robotics“*, MIT Press, 2005
6. Marchthaler, R.; Dingler S.: *„Kalman-Filter - Einführung in die Zustandsschätzung und ihre Anwendung für eingebettete Systeme“*, Springer-Vieweg Verlag, Wiesbaden, 2017 https://link.springer.com/content/pdf/10.1007%2F978-3-658-16728-8.pdf

Folie 1.6



1.3 Notationen

Notationen / Definitionen

Bezeichnung	Bedeutung
$\hat{x}$	geschätzte bzw. prädizierte Größe
$\tilde{x}$	korrigierte Größe
$\underline{A}, \underline{B}, \ldots$	Vektoren, Matrizen
$\underline{A}^T, \underline{B}^T, \ldots$	transponierte Vektoren, Matrizen
$\underline{A}_d, \underline{B}_d, \ldots$	zeitdiskrete Vektoren, Matrizen
$\underline{0}$	Nullmatrix
$\underline{I}$	Einheitsmatrix
Det $(\underline{A})$	Determinante einer Matrix
Adj $(\underline{A})$	Adjunkte einer Matrix
Tr $(\underline{A})$	Spur einer Matrix
E (X)	Erwartungswert der Zufallsvariable X
Var (X)	Varianz der Zufallsvariable X
Cov (X, Y)	Kovarianz der Zufallsvariable X und Y
Rang $(\underline{S})$	Rang einer Matrix

Folie 1.8

2 Überblick

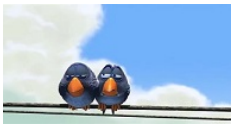
2.1 Einführendes Beispiel

Einwohner in Esslingen

Wie viele Einwohner hat Esslingen?

- Schreiben Sie Ihren Tipp auf einen Zettel
- Es liegen nun mehrere Schätzungen über die Anzahl der Einwohner vor.
  Wie lassen sich diese Daten zu einer besseren Schätzung *fusionieren*?
- *Lösungsidee*:

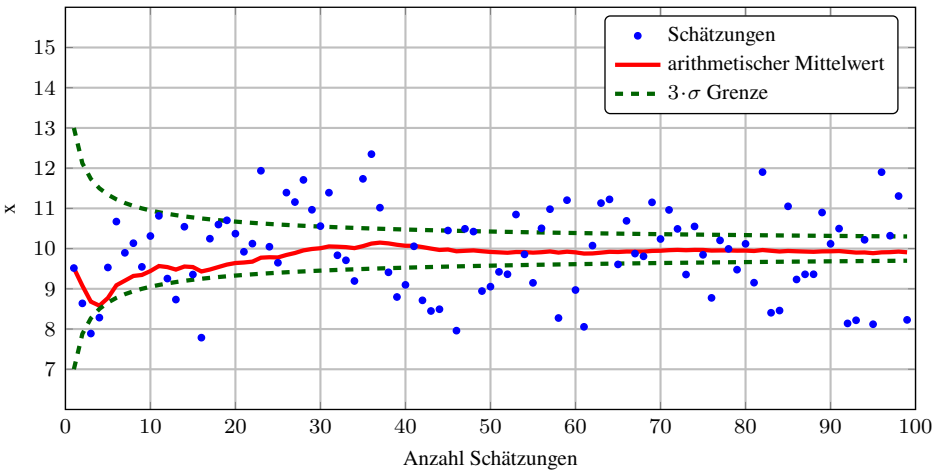
- *Zusatzfrage*: Um wie viel wird die fusionierte Schätzung mit jeder weiteren Schätzung *besser*?



- *Lösung*:

Folie 1.10

Schätzung einer unbekannten Konstanten



Folie 1.11

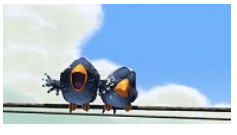
Verbesserung der Schätzungen einer unbekannten Konstanten

Überlegen Sie sich wie man die Datenfusion weiter verbessern kann?

Lösung/Ideen:

-
-
-

Folie 1.12



2.2 Beispiel Abhängigkeiten

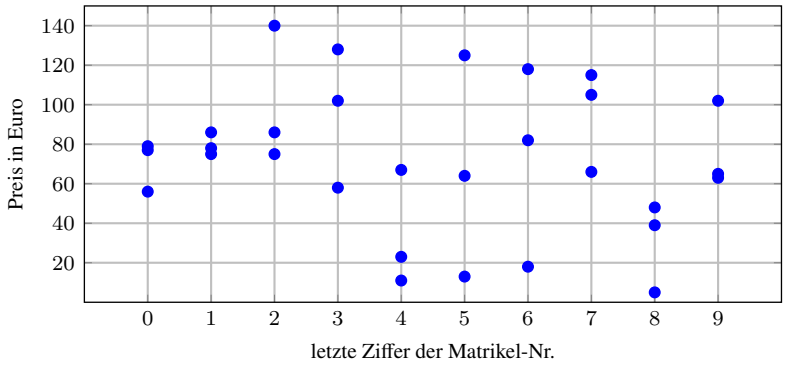
Schätzung des Preises einer Weinflasche

1. Schreiben Sie bitte auf dem Zettel die letzte Ziffer Ihrer Matrikel-Nr. auf!
2. Schätzen Sie nun den Preis der Weinflasche



Folie 1.14

Theoretisches Ergebnis



Fragen:

- Macht es überhaupt Sinn die Matrikelnummer bei der Fusion des geschätzten Preises der Weinflasche zu verwenden?
- Unter welchen Voraussetzungen würde es Sinn machen und unter welchen nicht?

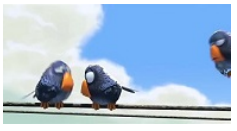
Folie 1.15

2.3 Beispiel Schätzung unbekannter Größen

Fragestellung

- Frage: Wie viel Klavierstimmer gibt es in Chicago?
- Schreiben Sie Ihre Schätzung auf einen Zettel.
- Lösungsansatz: Überlegen Sie sich eine Formel (Modell) mit der man die Anzahl der Klavierstimmer berechnen könnte.
- Schätzen Sie die in der Formel benötigten Größen ab und berechnen Sie mit der Formel die Anzahl der Klavierstimmer.

Folie 1.17



Lösung Klavierstimmer

Folie 1.18

2.4 Zusammenfassung

Vorgestellte Verfahren

Fall 1 (einführendes Beispiel):

- Eine unsichere (verrauschte) erfassbare Messgröße.
- Datenfusionierung über (gewichteten) Mittelwert

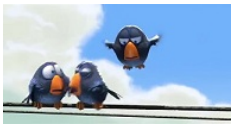
Fall 2 (Beispiel Weinflasche):

- Mehrere unsichere (verrauschte) erfassbare Messgrößen.
- Datenfusionierung über (gewichteten) Mittelwert und Berücksichtigung der Kovarianz

Fall 3 (Beispiel Klavierstimmer):

- Schätzung messtechnisch nicht erfassbarer (unbekannter) Größen.
- Datenfusionierung mittels physikalischen Modells (Formel)

Folie 1.20



Teil II
Grundlagen

3 Wahrscheinlichkeitstheorie

3.1 Definitionen und Begriffe

Zufälliges Experiment [1]

- In der Natur gibt es Experimente, auch Versuche genannt, bei denen der Ausgang des Experiments mehrere verschiedene „*Ausgänge / Ereignisse*“ hat, die *nicht vorhersehbar* bzw. nur mit großem Aufwand vorhersehbar sind. Liegt ein solches Experiment vor, spricht man von einem zufälligen Experiment / Versuch.
- Ein sehr oft zitiertes Beispiel ist das Benutzen eines *Würfels*. Das Experiment hat in diesem Fall sechs verschiedene Ausgänge. Welcher der sechs Ausgänge am Ende eines solchen Experiments eintritt, ist nicht vorhersehbar.
- Aber auch das Bestimmen der *Länge* eines Gegenstandes mit einem Lineal kann als zufälliges Experiment betrachtet werden. Durch Messungenauigkeiten wird nicht der wahre Wert bestimmt, sondern es entstehen verschiedene Längenergebnisse, die um den wahren Wert schwanken.

Folie 2.4

Ergebnis und Ergebnismenge [1]

- Der Ausgang eines zufälligen Experiments wird allgemein als *elementares Ereignis* ω bezeichnet. Die Menge aller möglichen Ausgänge / Ergebnisse eines zufälligen Experiments werden mit der *Menge* Ω beschrieben.
- Besteht ein zufälliges Experiment aus L *Elementarereignissen*, ist $\Omega = \{\omega_1, \omega_2, \ldots, \omega_L\}$
- Beim Würfelexperiment gilt somit $\Omega = \{\boxdot, \boxdot, \boxdot, \boxdot, \boxdot, \boxdot\}$
- Ein Ereignis besteht nicht zwangsläufig aus einem Elementarereignis, sondern kann allgemein eine *Teilmenge von* Ω sein.
- $A \subseteq \Omega$ heißt Ereignis und tritt dann ein, wenn ein Zufallsexperiment/Versuch ein Elementarereignis aus A ergibt. Für die Menge A gilt $A = \{a_1, a_2, \ldots, a_M\}$ mit $M \leq L$
- Beispielsweise sei $A = \{\boxdot, \boxdot, \boxdot\}$ die Menge aller Primzahlen von Ω oder $B = \{\boxdot\}$ sei die Menge, dass eine sechs gewürfelt wird.

Spezielle Ereignisse:

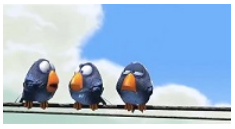
- Gilt $A = \Omega$ tritt das Ereignis sicher ein. Man spricht von einem *sicheren Ereignis*
- Ist $A = \emptyset$ eine leere Menge, kann das Ereignis nie eintreten. Dies wird als *unmögliches Ereignis* bezeichnet
- A^C heißt *Komplementärereignis*. Ist z. B. $A = \{\boxdot, \boxdot, \boxdot\}$ so folgt $A^C = \{\boxdot, \boxdot, \boxdot\}$
- A, B heißen *unvereinbar* oder *disjunkt*, falls $A \cap B = \emptyset$ ist

Folie 2.5

Zufallsvariable [1]

- Für das Rechnen mit zufälligen Ereignissen werden *Zufallsvariablen* eingeführt. Diese werden durch *Abbildungen/Zuordnungen* eines Elementarereignisses zu einer *Variable* gebildet. Mit anderen Worten ordnet die Zufallsvariable X jedem Ereignis $\omega \in \Omega$ eine reelle Zahl zu. Es gilt:

$$\begin{aligned} X : \Omega &\to \mathbb{R} \\ \omega &\mapsto X(\omega) \end{aligned}$$

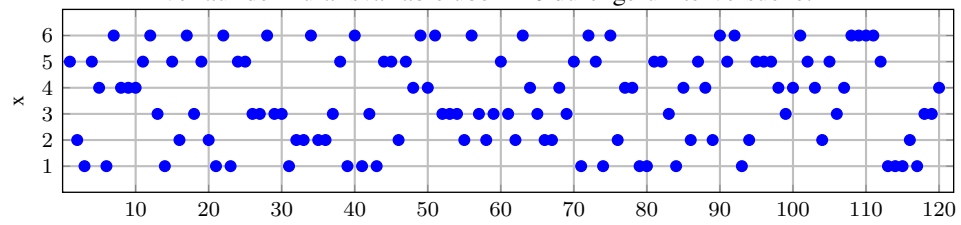


- Vor der Durchführung eines Zufallsexperiments *bildet* die Zufallsvariable X auf eine *reelle Zahl* ab, deren *Wert unbekannt* ist. Nach der Durchführung wird die Zufallsvariable X in dem Wert x realisiert. Man spricht deshalb in diesem Zusammenhang bei x von der *Realisierung* der Zufallsvariable X nach der Durchführung eines Zufallsexperimentes.
- Eine solche Abbildungsvorschrift könnte z. B. bei einem Zufallsexperiment mit einmaligem Würfeln wie folgt definiert sein: $X =$ Augenzahl des Würfelergebnisses. Dann wäre $X(\boxdot) = 1$, $X(\boxdot) = 2$, $X(\boxdot) = 3$, $X(\boxdot) = 4$, $X(\boxdot) = 5$ und $X(\boxdot) = 6$.

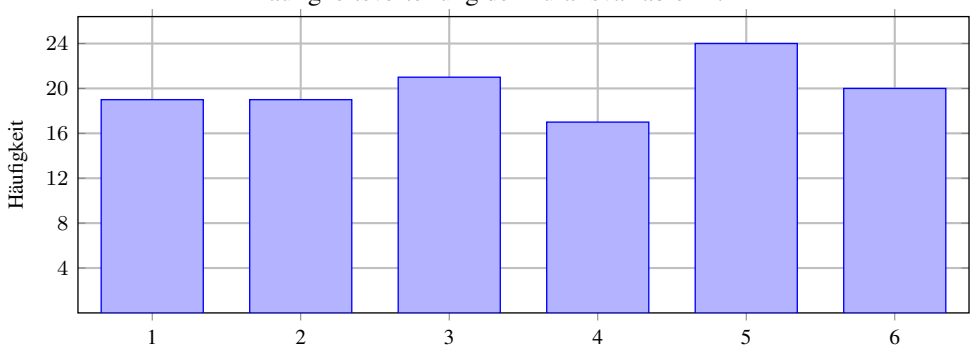
Folie 2.6

Wahrscheinlichkeit: Zufallsexperiment mit einem Würfel [1]

Verlauf der Zufallsvariable über 120 durchgeführte Versuche:



Häufigkeitsverteilung der Zufallsvariable X:



Folie 2.7

Wahrscheinlichkeit: Axiome nach Kolmogorov [1]

- Für $n \to \infty$ treten alle Häufigkeiten bei einem Würfelexperiment mit einem *idealen Würfel* gleich oft auf. Bei einem idealen Würfel beträgt die relative Häufigkeit h_n eines jeden Ereignisses $1/6$.
- Für $n \to \infty$ strebt die *relative Häufigkeit* $\mathbf{h_n(A)}$ eines Ereignisses A gegen die *Wahrscheinlichkeit* $\mathbf{P(A)}$. Es gilt: $P(A) = \lim\limits_{n\to\infty} h_n(A)$

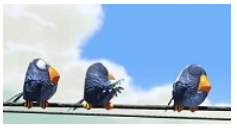
Die Zuordnung eines jeden Ereignisses A einer Wahrscheinlichkeit $P(A)$ wird in der Wahrscheinlichkeitstheorie *Wahrscheinlichkeitsmaß* genannt. Das Wahrscheinlichkeitsmaß muss hierbei die *drei Axiome nach Kolmogorov* erfüllen:

1. Jedem Ereignis A ist eine *reelle Zahl* (Wahrscheinlichkeit von A) *zwischen 0 und 1* zugeordnet: $0 \leq P(A) \leq 1$.
2. Ein *sicheres Ereignis* Ω hat die *Wahrscheinlichkeit 1*: $P(\Omega) = 1$.
3. Für zwei *disjunkte* Ereignisse gilt: $P(A \cup B) = P(A) + P(B)$, falls $A \cap B = \emptyset$.

Aus den Axiomen nach Kolmogorov folgt:

- Für die Wahrscheinlichkeit eines *komplementären Ereignisses* folgt: $P(A^C) = 1 - P(A)$
- Ein *unmögliches Ereignis* $A = \emptyset$ hat die Wahrscheinlichkeit: $P(\emptyset) = 0$
- Für die *Vereinigung nicht disjunkter* Ereignisse gilt: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

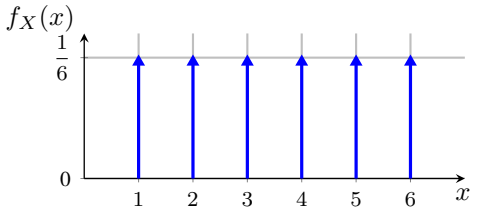
Folie 2.8



3.2 Dichtefunktion

Diskrete Gleichverteilung [1]

- Zufallsexperiment bei denen alle Werte der Zufallsvariable gleich oft auftreten, besitzen eine gleichverteilte *Häufigkeitsverteilungen*.
- Allgemein spricht man in diesem Zusammenhang auch von einer *Wahrscheinlichkeitsdichte-Funktion* oder kurz *Dichtefunktion* $f_X(x)$.
- Bei einem zufälligen Experiment mit diskreten Ausgängen wird diese durch eine Folge von Dirac-Impulsen beschrieben.
- Bei dem Würfelexperiment gilt für die Dichtefunktion: $f_X(x) = \frac{1}{6} \cdot \sum_{i=1}^{6} \delta(x-i)$



Folie 2.10

Dirac-Funktion [1]

- Die von Paul A. M. Dirac in der Physik eingeführte δ-*Funktion* (auch δ-Distribution, Dirac-Impuls, Dirac-Funktion, Dirac-Puls, Dirac-Stoß, Stoßfunktion oder Impulsfunktion genannt) ist vereinfachend geschrieben definiert durch:

$$\delta(x) = \begin{cases} +\infty & x = 0 \\ 0 & x \neq 0 \end{cases} \quad \text{und} \quad \int_G \delta(x)dx = \begin{cases} 1 & 0 \in G \\ 0 & 0 \notin G \end{cases}$$

- Im strengen Sinn ist die Dirac-Funktion *keine mathematische Funktion*. Jedoch sind die meisten Rechengesetze für die Dirac-Funktion gültig.
- Die für diesen Themenbereich wichtigste Eigenschaft ist die *Ausblendeigenschaft*. Es gilt:

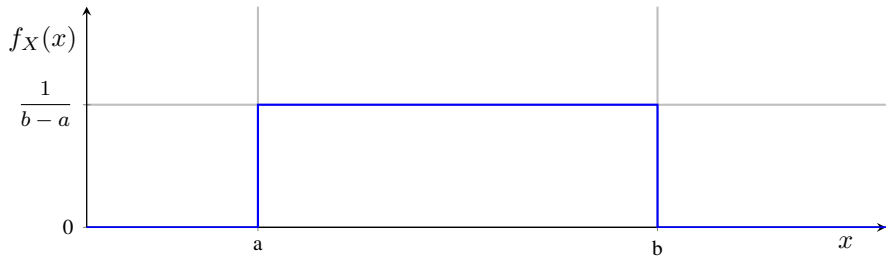
$$\int_G \delta(x-a) \cdot f(x)\, dx = \begin{cases} f(a) & a \in G \\ 0 & a \notin G \end{cases}$$

Folie 2.11

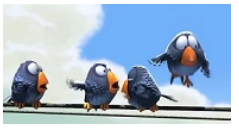
Kontinuierliche Gleichverteilung [1]

- Hat die Zufallsvariable *unendlich viele anzunehmende Werte* , spricht man von einer *kontinuierlichen* Zufallsvariablen.
- Für eine solche Zufallsvariable ist die stückweise steige Dichtefunktion einer *Gleichverteilung* definiert mit:

$$f_X(x) = \begin{cases} \dfrac{1}{b-a} & a \leq x \leq b \quad \text{für} \quad a < b \\ 0 & \text{sonst} \end{cases}$$



Folie 2.12

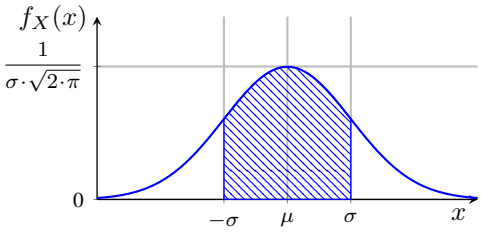


Normalverteilung [1]

Die Dichtefunktion einer *normalverteilten* Zufallsvariable ist definiert durch die Funktion:

$$f_X(x) = \frac{1}{\sigma \cdot \sqrt{2 \cdot \pi}} \cdot \mathrm{e}^{-\frac{(x-\mu)^2}{2 \cdot \sigma^2}} \qquad \sigma > 0$$

- μ: *Erwartungswert* (Mittelwert)
- σ: *Standardabweichung* (Streumaß für die Breite/Abweichung der Verteilung um den Erwartungswert μ).



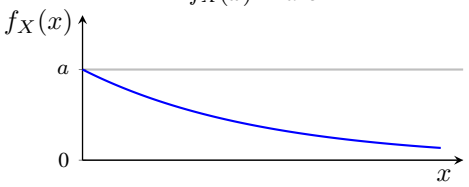
In dem Intervall zwischen $-\sigma$ und $+\sigma$ liegen *68,27%* aller Zufallszahlen

Folie 2.13

Weitere kontinuierliche Verteilungen [1]

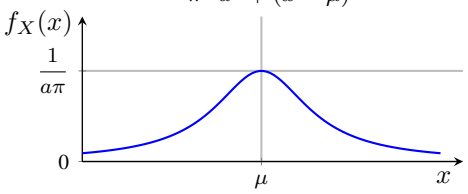
Exponential-Verteilung

$$f_X(x) = a \cdot e^{-ax}$$



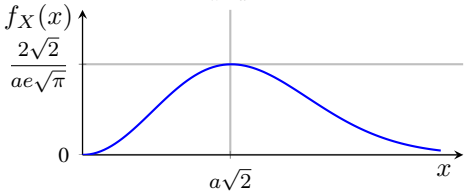
Cauchy-Verteilung

$$f_X(x) = \frac{a}{\pi} \cdot \frac{1}{a^2 + (x-\mu)^2}, \quad a > 0$$



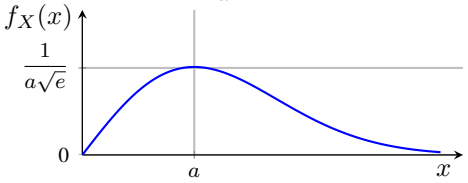
Maxwell-Boltzmann-Verteilung

$$f_X(x) = \sqrt{\tfrac{2}{\pi}} \cdot \tfrac{1}{a^3} \cdot x^2 \cdot e^{-\frac{x^2}{2a^2}}, \quad x \geq 0$$



Rayleigh-Verteilung

$$f_X(x) = \frac{x}{a^2} \cdot e^{-\frac{x^2}{2 \cdot a^2}}, \quad x \geq 0$$

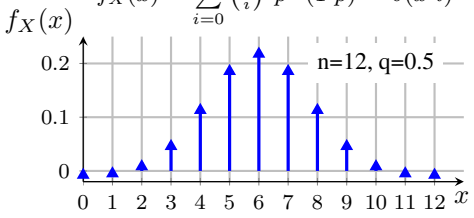


Folie 2.14

Weitere diskrete Verteilungen [1]

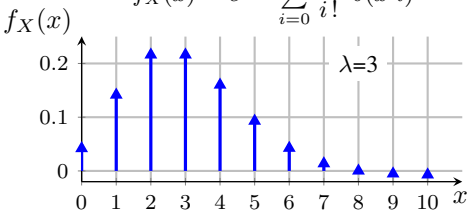
Binomial-Verteilung

$$f_X(x) = \sum_{i=0}^{n} \binom{n}{i} \cdot p^i \cdot (1\text{-}p)^{n-i} \cdot \delta(x\text{-}i)$$

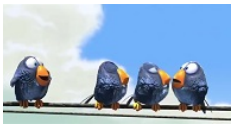


Poisson-Verteilung

$$f_X(x) = e^{-\lambda} \cdot \sum_{i=0}^{\infty} \frac{\lambda^i}{i!} \cdot \delta(x\text{-}i)$$



Folie 2.15



3.3 Momente und zentrale Momente

Charakterisierung von Zufallsexperimenten

- Es gibt eine *Vielzahl von Größen* die ein Zufallsexperiment *charakterisieren*.
- Neben der Charakterisierung mittels *Häufigkeitsverteilungen* existieren noch *Kennwerte*, die jedoch in *unvollständiger Weise* einen Zufallsprozess beschreiben.
- Zu diesen *Kennwerten* eines Zufallsexperiments zählen u. a.:
  -
  -
  -
  -

Folie 2.17

Erwartungswert

- Für eine Zufallsvariable X mit der Dichtefunktion $f_X(x)$ gilt für das *i-te Moment*:

$$\alpha_i = \mathrm{E}\left(X^i\right) = \begin{cases} \int_{-\infty}^{+\infty} x^i \cdot f_X(x)\, dx & \text{falls X stetig ist} \\ \sum_{k\in\mathbb{N}} x(k)^i \cdot f_X\big(x(k)\big) & \text{falls X diskret ist} \end{cases}$$

- Das wichtigste Moment stellt das *erste Moment* dar, welches auch als *Erwartungswert E(X)* der Zufallsvariable X bezeichnet wird.
- Für eine Zufallsvariable X mit der Dichtefunktion $f_X(x)$ gilt für den Erwartungswert:

$$\alpha = \mathrm{E}(X) = \begin{cases} \int_{-\infty}^{+\infty} x \cdot f_X(x)\, dx & \text{falls X stetig ist} \\ \sum_{k\in\mathbb{N}} x(k) \cdot f_X\big(x(k)\big) & \text{falls X diskret ist} \end{cases}$$

Folie 2.18

Varianz

- Für eine Zufallsvariable X mit der Dichtefunktion $f_X(x)$ gilt für das *i-te zentrale Moment*:

$$\mu_i = \mathrm{E}\Big(\big(X - \mathrm{E}(X)\big)^i\Big) = \begin{cases} \int_{-\infty}^{+\infty} \big(X - \mathrm{E}(X)\big)^i \cdot f_X(x)\, dx & \text{falls X stetig} \\ \sum_{k\in\mathbb{N}} \big(x(k) - \mathrm{E}(X)\big)^i \cdot f_X\big(x(k)\big) & \text{falls X diskret} \end{cases}$$

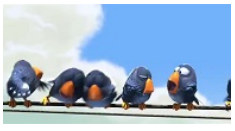
- Das wichtigste zentrale Moment stellt d. *zweite zentrale Moment* dar, welches auch als *Varianz* der Zufallsvariable X bezeichnet wird.
- Für eine Zufallsvariable X mit der Dichtefunktion $f_X(x)$ gilt für die Varianz:

$$\mathrm{Var}(X) = \mathrm{E}\Big(\big(X - \mathrm{E}(X)\big)^2\Big) = \begin{cases} \int_{-\infty}^{+\infty} \big(X - \mathrm{E}(X)\big)^2 \cdot f_X(x)\, dx & \text{falls X stetig} \\ \sum_{k\in\mathbb{N}} \big(x(k) - \mathrm{E}(X)\big)^2 \cdot f_X\big(x(k)\big) & \text{falls X diskret} \end{cases}$$

- Die Streuung oder Standardabweichung einer Zufallsvariable X ist definiert durch:

$$\sigma(X) = \sqrt{\mathrm{Var}(X)}$$

Folie 2.19



Verschiebungssatz

- Für eine Zufallsvariable X gilt für die Varianz:

$$\begin{aligned}\mathrm{Var}(X) &= \mathrm{E}\Big(\big(X-\mathrm{E}(X)\big)^2\Big) = \mathrm{E}\Big(\big(X^2 - 2\cdot X\cdot \mathrm{E}(X) + \mathrm{E}(X)^2\big)\Big)\\ &= \mathrm{E}\big(X^2\big) - \mathrm{E}\big(2\cdot X\cdot \mathrm{E}(X)\big) + \mathrm{E}\big(\mathrm{E}(X)^2\big)\\ &= \mathrm{E}\big(X^2\big) - 2\cdot \mathrm{E}(X)\cdot \mathrm{E}(X) + \mathrm{E}(X)^2\\ &= \mathrm{E}\big(X^2\big) - \mathrm{E}(X)^2\end{aligned}$$

Folie 2.20

Kovarianz

- Haben Zufallsexperimente mehrere Zufallsvariablen, entstehen *Momente 2. Ordnung*.
- Ist X und Y eine Zufallsvariable, so ist $\mathrm{Cov}(X,Y)$ die Kovarianz der beiden Zufallsvariablen. Diese beschreibt die *lineare statistische Abhängigkeit* der Zufallsvariable X von Y.
- Allgemein ist die *Kovarianz* zweier Zufallsvariablen X und Y definiert zu:

$$\mathrm{Cov}(X,Y) = \mathrm{E}\Big(\big(X-\mathrm{E}(X)\big)\cdot\big(Y-\mathrm{E}(Y)\big)\Big) = \mathrm{E}(X\cdot Y) - \mathrm{E}(X)\cdot\mathrm{E}(Y)$$

- Für *stetige Zufallsvariablen* X und Y mit der zweidimensionalen Dichtefunktion $f_{XY}(x,y)$ gilt:

$$\mathrm{Cov}(X,Y) = \int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}\big(x-\mathrm{E}(X)\big)\cdot\big(y-\mathrm{E}(Y)\big)\cdot f_{XY}(x,y)\,dx\,dy$$

- Sind die beiden Zufallsvariable X und Y *unkorreliert*, d. h. sie sind *linear unabhängig*, so ist die Kovarianz der beiden Zufallsvariable *Cov(X, Y) = 0*.

Folie 2.21

Rechenregeln: Erwartungswerte, Varianzen und Kovarianzen

Ist X und Y eine Zufallsvariable und a und b Konstanten, so gilt:

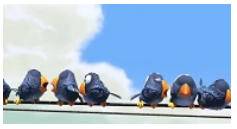
$$\begin{aligned}
&\mathrm{E}(a) &&= a\\
&\mathrm{E}(a\cdot X) &&= a\cdot\mathrm{E}(X)\\
&\mathrm{E}(a+b\cdot X) &&= a+b\cdot\mathrm{E}(X)\\
&\mathrm{E}(X+Y) &&= \mathrm{E}(X)+\mathrm{E}(Y)\\
&\mathrm{Var}(a) &&= 0\\
&\mathrm{Var}(a+X) &&= \mathrm{Var}(X)\\
&\mathrm{Var}(a+b\cdot X) &&= b^2\cdot\mathrm{Var}(X)\\
&\mathrm{Var}(X+Y) &&= \mathrm{Var}(X)+\mathrm{Var}(Y)+2\cdot\Big(\underbrace{\mathrm{E}(X\cdot Y)-\mathrm{E}(X)\cdot\mathrm{E}(Y)}_{\mathrm{Cov}(X,Y)}\Big)\\
&\mathrm{Cov}(X,Y) &&= \mathrm{E}(X\cdot Y)-\mathrm{E}(X)\cdot\mathrm{E}(Y)\\
&\mathrm{Cov}(X,X) &&= \mathrm{Var}(X)\\
&\mathrm{Cov}(a+b\cdot X,\ c+d\cdot Y) &&= b\cdot d\cdot\mathrm{Cov}(X,Y)\\
&\mathrm{Cov}(X+Y,\ Z) &&= \mathrm{Cov}(X,Z)+\mathrm{Cov}(Y,Z)
\end{aligned}$$

Folie 2.22

3.4 Wichtige empirische Kenngrößen

Mittelwert

- Die Bestimmung des Erwartungswertes einer Zufallszahl ist in der Praxis nicht immer einfach, da die *Dichtefunktion* $f_X(x)$ *nicht bekannt* ist.



- Oft behilft man sich, indem man den Erwartungswert durch eine Mittelwertbildung annähert.
- Der *Mittelwert* einer Zahlenfolge $x(k)$ berechnet sich durch:

$$\overline{x} = \frac{1}{n} \cdot \sum_{i=1}^{n} x(i)$$

- Der Mittelwert entspricht genau dann dem Erwartungswert, wenn die gesamte *Population* vorhanden ist.
- Da selten die gesamte Population vorhanden ist, muss man sich mit einer *Stichprobe* genügen.
- Je repräsentativer die Stichprobe, die Gesamtpopulation entspricht, desto mehr entspricht der Mittelwert (geschätzter Erwartungswert) dem Erwartungswert.

Folie 2.24

Frage zum Mittelwert

Frage: Darf die Formel für die Mittelwertbildung auch bei *nicht gleichverteilten Dichtefunktionen* verwendet werden?

- Allgemein berechnet sich der *Erwartungswert* mit:

$$\alpha = \mathrm{E}\left(X\right) = \sum\nolimits_{k \in \mathbb{N}} x(k) \cdot f_X\left(x(k)\right)$$

- Der *Mittelwert* einer Zahlenfolge $x(k)$ berechnet sich durch:

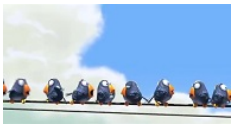
$$\overline{x} = \frac{1}{n} \cdot \sum_{i=1}^{n} x(i)$$

Antwort:

Folie 2.25

Erwartungstreue Schätzer: Mittelwert

- **Frage: Ist der Mittelwert und die Varianz *erwartungstreu*?**
- *Erwartungstreu* bezeichnet man die Eigenschaft, wenn der Erwartungswert eines Schätzers gleich dem wahren Wert des zu schätzenden Parameters ist.
- Ist $x(k)$ die Ausprägung der unabhängig identisch verteilten Zufallsvariablen $X(k)$ mit der Varianz σ^2 und dem Mittelwert α der Grundgesamtheit, so gilt: $\alpha = \mathrm{E}\left(X(k)\right)$



$$\mathrm{E}\left(\overline{X}\right) = \mathrm{E}\left(\frac{1}{n}\cdot\sum_{k=1}^{n} X_k\right) = \frac{1}{n}\cdot\sum_{k=1}^{n}\mathrm{E}\left(X_k\right) = \frac{1}{n}\cdot\sum_{k=1}^{n}\alpha = \frac{1}{n}\cdot n\cdot\alpha = \alpha$$

- Folglich ist der Mittelwert ein *erwartungstreuer Schätzer*.

Folie 2.26

Erwartungstreue Schätzer: Varianz s_0^2

- Es gilt $\sigma^2 = \mathrm{Var}\left(X(k)\right) = \mathrm{E}\left((X(k) - \mathrm{E}(X))^2\right) = \mathrm{E}\left((X(k) - \alpha)^2\right)$.
- Definiert man für die Varianz einer Stichprobe: $s_0^2 = \frac{1}{n}\cdot\sum\limits_{k=1}^{n}\left(X(k) - \alpha\right)^2$

$$\begin{aligned}\mathrm{E}\left(s_0^2\right) &= \mathrm{E}\left(\frac{1}{n}\cdot\sum_{k=1}^{n}\left(X(k)-\alpha\right)^2\right) = \frac{1}{n}\cdot\sum_{k=1}^{n}\underbrace{\mathrm{E}\left(\left(X(k)-\alpha\right)^2\right)}_{\sigma^2}\\ &= \frac{1}{n}\cdot\sum_{k=1}^{n}\sigma^2 = \frac{1}{n}\cdot n\cdot\sigma^2 = \sigma^2\end{aligned}$$

- Folglich ist die Varianz ein *erwartungstreuer Schätzer*.

Folie 2.27

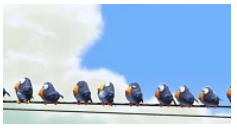
Erwartungstreue Schätzer: Varianz s_1^2

- Es gilt $\sigma^2 = \mathrm{Var}\left(X(k)\right) = \mathrm{E}\left((X(k) - \mathrm{E}(X))^2\right) = \mathrm{E}\left((X(k) - \alpha)^2\right)$.
- Definiert man für die Varianz einer Stichprobe: $s_1^2 = \frac{1}{n}\cdot\sum\limits_{k=1}^{n}\left(X(k) - \overline{X}\right)^2$

$$\begin{aligned}\mathrm{E}\left(s_1^2\right) &= \mathrm{E}\left(\frac{1}{n}\cdot\sum_{k=1}^{n}\left(X(k)-\overline{X}\right)^2\right) = \frac{1}{n}\cdot\mathrm{E}\left(\sum_{k=1}^{n}\left(X(k)-\alpha+\alpha-\overline{X}\right)^2\right)\\ &= \frac{1}{n}\cdot\mathrm{E}\left(\sum_{k=1}^{n}\left(\left(X(k)-\alpha\right)^2 - 2\cdot\left(X(k)-\alpha\right)\cdot\left(\overline{X}-\alpha\right) + \left(\overline{X}-\alpha\right)^2\right)\right)\\ &= \frac{1}{n}\cdot\mathrm{E}\left(\sum_{k=1}^{n}\left(X(k)-\alpha\right)^2 - 2\cdot\left(\overline{X}-\alpha\right)\cdot\underbrace{\sum_{k=1}^{n}\left(X(k)-\alpha\right)}_{n\cdot\left(\overline{X}-\alpha\right)} + \underbrace{\sum_{k=1}^{n}\left(\overline{X}-\alpha\right)^2}_{n\cdot\left(\overline{X}-\alpha\right)^2}\right)\\ &= \frac{1}{n}\cdot\mathrm{E}\left(\sum_{k=1}^{n}\left(X(k)-\alpha\right)^2 - n\cdot\left(\overline{X}-\alpha\right)^2\right)\\ &= \underbrace{\mathrm{E}\left(\frac{1}{n}\cdot\sum_{k=1}^{n}\left(X(k)-\alpha\right)^2\right)}_{\mathrm{E}\left(s_0^2\right)=\sigma^2} - \underbrace{\mathrm{E}\left(\left(\overline{X}-\alpha\right)^2\right)}_{\mathrm{Var}\left(\overline{X}\right)=\frac{\sigma^2}{n}\text{ siehe Folie I.10}} = \sigma^2 - \frac{\sigma^2}{n} = \frac{n-1}{n}\cdot\sigma^2\end{aligned}$$

- Folglich ist die Varianz s_1^2 *kein erwartungstreuer Schätzer*.

Folie 2.28



Empirische Varianz s^2

- Es gilt $\sigma^2 = \mathrm{Var}\left(X(k)\right) = \mathrm{E}\left((X(k) - \mathrm{E}(X))^2\right) = \mathrm{E}\left((X(k) - \alpha)^2\right)$.
- Definiert man für die Varianz einer Stichprobe: $s^2 = \frac{n}{n-1} \cdot s_1^2 = \frac{1}{n-1} \cdot \sum_{k=1}^{n} (X(k) - \overline{X})^2$

$$\mathrm{E}\left(s^2\right) = \mathrm{E}\left(\frac{n}{n-1} \cdot s_1^2\right) = \frac{n}{n-1} \cdot \mathrm{E}\left(s_1^2\right) = \frac{n}{n-1} \cdot \frac{n-1}{n} \cdot \sigma^2 = \sigma^2$$

- Folglich ist die Varianz s^2 ein *erwartungstreuer Schätzer*.
- Man spricht auch bei Varianz s^2 einer Stichprobe von der *empirischen Varianz*:

$$\begin{aligned} s^2 &= \frac{1}{n-1} \cdot \sum_{k=1}^{n} (x(k) - \overline{x})^2 \\ &= \frac{1}{n-1} \cdot \sum_{k=1}^{n} x(k)^2 - \frac{1}{n \cdot (n-1)} \cdot \left(\sum_{k=1}^{n} x(k)\right)^2 \end{aligned}$$

Folie 2.29

Vorteile / Nachteile Berechnung empirische Varianz

- Was sind die *Vor- und Nachteile* der zweiten Formeln zur Berechnung der empirischen Varianz über den Verschiebungssatz?
- Vorteile:
- Nachteile:

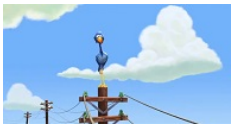
Folie 2.30

Empirische Kovarianz $\hat{\sigma}_{X,Y}^2$

- Analog zu der Bildung der Varianz einer Stichprobe wird die *empirische Kovarianz einer Stichprobe* gebildet.
- Für die Kovarianz diskreter Zufallsvariablen X und Y einer Stichprobe gilt:

$$\begin{aligned} \hat{\sigma}_{X,Y}^2 &= \frac{1}{n-1} \cdot \sum_{k=1}^{n} \left(x(k) - \overline{x}\right) \cdot \left(y(k) - \overline{y}\right) \\ &= \frac{1}{n-1} \cdot \sum_{k=1}^{n} \left(x(k) \cdot y(k)\right) - \frac{n}{n-1} \cdot \overline{x} \cdot \overline{y} \\ &= \frac{1}{n-1} \cdot \sum_{k=1}^{n} \left(x(k) \cdot y(k)\right) - \frac{1}{n \cdot (n-1)} \cdot \left(\sum_{k=1}^{n} x(k)\right) \cdot \left(\sum_{k=1}^{n} y(k)\right) \end{aligned}$$

Folie 2.31



Übungsaufgabe: Fertigungsanlage

- In einer Fertigungsanlage wird ein Produkt auf drei Linien (X, Y, Z) gefertigt.
- Ein Fertigungsingenieur erfasst jede Stunde die Anzahl der Ausschussteile.

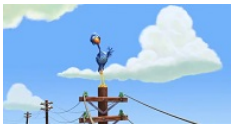
k	1	2	3	4	5	6	7	8	9
Linie X	6	5	3	4	2	3	5	5	3
Linie Y	9	7	2	4	3	4	6	6	4
Linie Z	4	5	3	1	1	3	2	4	4

- Berechnen Sie den Mittelwerte, die Varianzen und die Kovarianzen

Folie 2.32

Lösung: Fertigungsanlage

Folie 2.33



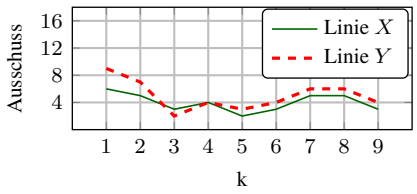
Korrelationskoeffizient

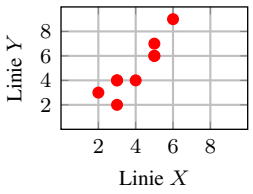
- Zur Charakterisierung wird die *Kovarianz* mit den *Standardabweichungen* auf *Werte zwischen -1 und +1 normiert*.
- Diese dimensionslose Größe wird als *Korrelationskoeffizient* $\mathbf{r_{XY}}$ bezeichnet.
- Für den Korrelationskoeffizient zweier Zufallsvariablen X und Y gilt:

$$r_{XY} = \frac{\mathrm{Cov}\,(X,Y)}{\sqrt{\mathrm{Var}\,(X)\cdot\mathrm{Var}\,(Y)}}$$

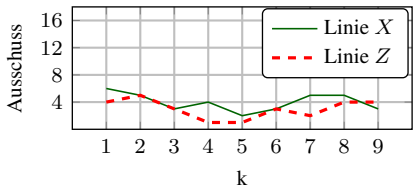
Folie 2.34

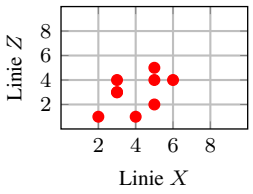
Korrelationskoeffizient Fertigungsanlage



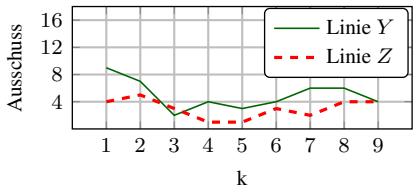


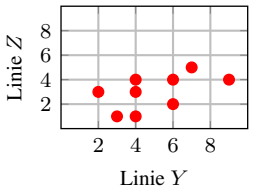
$$r_{XY} = \frac{2.625}{\sqrt{1.75\cdot 4.75}} = 0.91$$





$$r_{XZ} = \frac{0.875}{\sqrt{1.75\cdot 2.00}} = 0.47$$



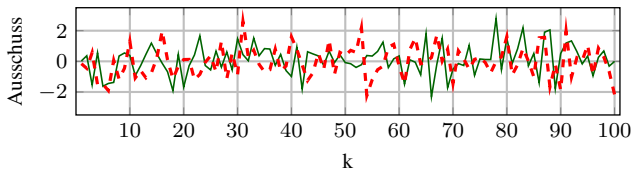


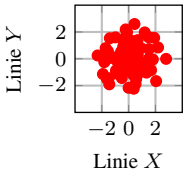
$$r_{YZ} = \frac{1.625}{\sqrt{4.75\cdot 2.00}} = 0.53$$

Folie 2.35

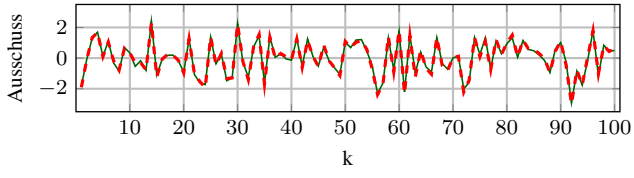
Beispiele für Korrelationskoeffizienten [1]

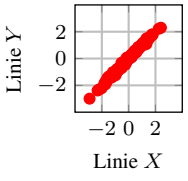
Korrelationskoeffizienten r_{XY} = 0.0



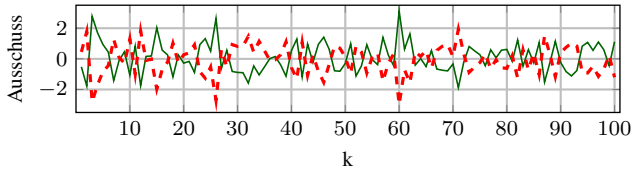


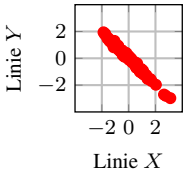
Korrelationskoeffizienten r_{XY} = +0.99



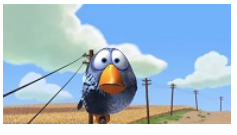


Korrelationskoeffizienten r_{XY} = -0.99





Folie 2.36



Zusammenfassung Korrelationskoeffizienten [1]

- Der Korrelationskoeffizient r_{XY} beschreibt die *lineare statistische Abhängigkeit* der Zufallsvariable X von Y.
- Der Korrelationskoeffizient r_{XY} kann *Werte zwischen +1 und -1* annehmen.
- Bei einem Korrelationskoeffizienten $r_{XY} = 1$ liegen alle Punkte auf einer *Geraden mit positiver Steigung*, die Zufallsvariablen X und Y sind *statistisch linear abhängig*.
- Bei einem Korrelationskoeffizienten $r_{XY} = -1$ liegen alle Punkte auf einer *Geraden mit negativer Steigung*, d. Zufallsvariablen X und Y sind *„negativ“ statistisch linear abhängig*.
- Bei einem Korrelationskoeffizienten $r_{XY} = 0$ liegen die Punkte auf *keiner Geraden*, es besteht keine lineare statistische Abhängigkeit der Zufallsvariable X von Y, die beiden Zufallsvariablen sind *unkorreliert*.

Folie 2.37

3.5 Lernziele

Lernkontrolle: Wahrscheinlichkeitstheorie

- Sie sollten mit den *Begriffen der Wahrscheinlichkeitstheorie* vertraut sein.
- Sie sollten eine *Verteilung* eines beliebigen Signals erstellen und charakterisieren können.
- Sie sollten die *Rechenregeln* der Erwartungswerte, Varianzen und Kovarianzen anwenden können.
- Sie sollten in der Lage sein, von beliebigen Signalen den *Mittelwert*, die *Varianz* und die *Kovarianz* berechnen zu können.

Folie 2.39

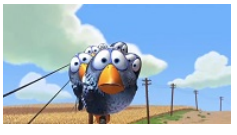
4 Signaltheorie

4.1 Stochastischer Prozess

Begrifflichkeiten I [1]

- Wird ein Zufallsexperiment parallel k-mal durchgeführt und jedes der k-Experimente zeitlich wiederholt, so lässt sich der Ausgang aller k-Experimente einer Zufallsvariable zuordnen.
- Die Zufallsvariable geht über in einen *Zufallsvektor* $\underline{X}(t)$, der von der Zeit abhängt. $\underline{X}(t) = \begin{bmatrix} X_1(t) & X_2(t) & \dots & X_k(t) \end{bmatrix}^T$
- Man spricht in diesem Zusammenhang von einem *stochastischen Prozess*. Diese werden durch die Wahrscheinlichkeitsdichtefunktion (Dichtefunktion) $f_X\left(\underline{x}(t)\right)$ beschrieben.
- Als *Beispiel* kann man sich z. B. einen Prozess vorstellen, bei dem *k-Spieler* (Schar von Spielern) jede Sekunde mit *k-Würfeln gleichzeitig* würfeln. Somit erhält man zu einem beliebigen Zeitpunkt t_1 k-Zufallszahlen, die in dem Vektor $\underline{x}(t_1)$ zugeordnet werden.

Folie 2.41



Begrifflichkeiten II [1]

- Prozesse, bei denen die Dichtefunktion $f_X\left(\underline{x}(t)\right)$ *nicht von der augenblicklichen Zeit abhängt* , haben die beiden Vektoren bei $\underline{x}(t)$ und $\underline{x}(t+t_0)$ für jedes t_0 dieselben statistischen Eigenschaften. Bei solchen stochastischen Prozessen ist: $f_X\left(\underline{x}(t)\right) = f_X\left(\underline{x}(t+t_o)\right) = f_X(\underline{x})$.
  Solche stochastische Prozesse werden als *stationär* bezeichnet. Der Erwartungswert für diesen speziellen Prozess ist: $\mathrm{E}\left(\underline{X}\right) = \int\limits_{-\infty}^{+\infty} \underline{x} \cdot f_X(\underline{x})\, d\underline{x} = \text{const.}$
- Stochastische Prozesse, bei denen der Scharmittelwert des Prozesses zu einem beliebigen Zeitpunkt t mit dem Zeitmittelwert jedes Einzelexperimentes übereinstimmt, werden als *ergodisch* bezeichnet. Dies hat in der Praxis eine große Bedeutung, da hierdurch die statistischen Momente anhand der zeitlichen Wiederholung eines einzelnen Zufallsexperiments bestimmt werden können. [2]
  Ein *Beispiel* für einen solchen ergodischen stochastischen Prozess ist das *Würfeln mit k-Spielern*. Es ist anzunehmen, dass es bei idealen Würfeln keine Rolle spielt, ob man mit k-Würfeln gleichzeitig würfelt oder mit einem einzelnen Würfel k-mal würfelt. Man erwartet in beiden Fällen die selben statistischen Momente.

Folie 2.42

4.2 Autokorrelation

Definitionen I

- Die *Autokorrelationsfunktion* charakterisiert einen *stochastischen Prozesses*
- Die *Autokorrelationsfunktion* eines *stochastischen Prozesses*, beschrieben durch die Dichtefunktion $f_X\left(\underline{X}(t)\right)$ und des Zufallsvektors $\underline{X}(t)$, ist definiert durch:

$$\gamma_{\underline{X}\,\underline{X}}(t_1,t_2) = \mathrm{E}\big(\underline{X}(t_1)\cdot\underline{X}(t_2)\big) = \int\limits_{-\infty}^{+\infty}\int\limits_{-\infty}^{+\infty} \underline{x}(t_1)\cdot\underline{x}(t_2)\cdot f_X\left(\underline{x}(t)\right)\, d\underline{x}(t_1)\, d\underline{x}(t_2)$$

- Für *stationäre stochastische Prozesse* hängt die Autokorrelationsfunktion nur von der Zeitdifferenz τ ab. Somit folgt für $t_2 = t+\tau$:

$$\gamma_{\underline{X}\,\underline{X}}(\tau) = \mathrm{E}\big(\underline{X}(t)\cdot\underline{X}(t+\tau)\big) = \int\limits_{-\infty}^{+\infty}\int\limits_{-\infty}^{+\infty} \underline{x}(t)\cdot\underline{x}(t+\tau)\cdot f_X(\underline{x})\, d\underline{x}(t)\, d\underline{x}(t+\tau)$$

Folie 2.44

Definitionen II

- Für *ergodische, stationäre stochastische Prozesse* berechnet sich die Autokorrelationsfunktion zu:

$$\gamma_{X\,X}(\tau) = \lim_{\Delta T\to\infty} \frac{1}{\Delta T} \cdot \int\limits_{-0.5\cdot\Delta T}^{0.5\cdot\Delta T} x(t)\cdot x(t+\tau)\, dt$$

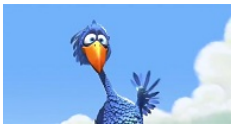
  Bei einem ergodischen, streng stationären stochastischen Prozess wird für $\tau = 0$ das Originalsignal mit einem um $\tau = 0$ verschobenen Signal verglichen. Diese beiden sind genau identisch, folglich besitzt die Autokorrelationsfunktion bei $\tau = 0$ das Maximum.
- Die *normierte Autokorrelationsfunktion* (Autokorrelationskoeffizienten) für stationäre stochastische Prozesse berechnet sich zu:

$$\gamma^*_{\underline{X}\,\underline{X}}(\tau) = \frac{\gamma_{\underline{X}\,\underline{X}}(\tau)}{\gamma_{\underline{X}\,\underline{X}}(0)}.$$

  Der Betrag dieser Autokorrelationskoeffizienten nimmt nur *Werte zwischen 0 und 1* an.
- Die Autokorrelationsfunktion eines *diskreten ergodischen, stationären stochastischen Prozesses* berechnet sich für eine Folge der Länge N zu:

$$\gamma_{X\,X}(k) = \begin{cases} \sum\limits_{n=0}^{N-k-1} x(n)\cdot x(n+k) & k \geq 0 \\ \gamma_{X\,X}(-k) & k < 0 \end{cases}$$

Folie 2.45



Übungsaufgaben Autokorrelationsfunktion I

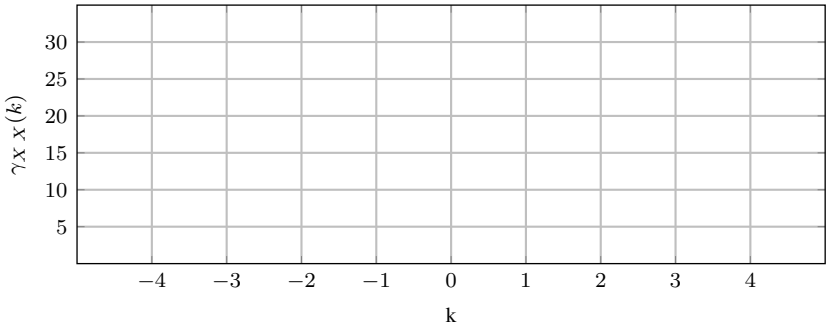
Bestimmen Sie die Autokorrelierte für einen ergodischen, streng stationären stochastischen Prozess mit x(k) = {0,1,2,3,4}

Lösung:

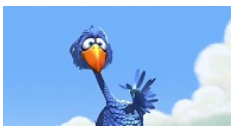
Folie 2.46

Lösung Übungsaufgaben I

Zeichnen Sie die Autokorrelierte in das unten stehende Diagramm



Folie 2.47



Übungsaufgaben Autokorrelationsfunktion II

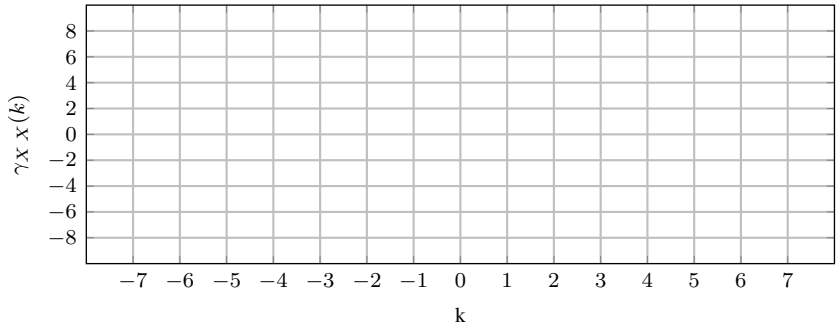
Bestimmen Sie die Autokorrelierte für einen ergodischen, streng stationären stochastischen Prozess mit x(k) = {1,1,-1,-1,1,1,-1,-1}

Lösung:

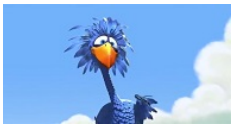
Folie 2.48

Lösung Übungsaufgaben II

Zeichnen Sie die Autokorrelierte in das unten stehende Diagramm

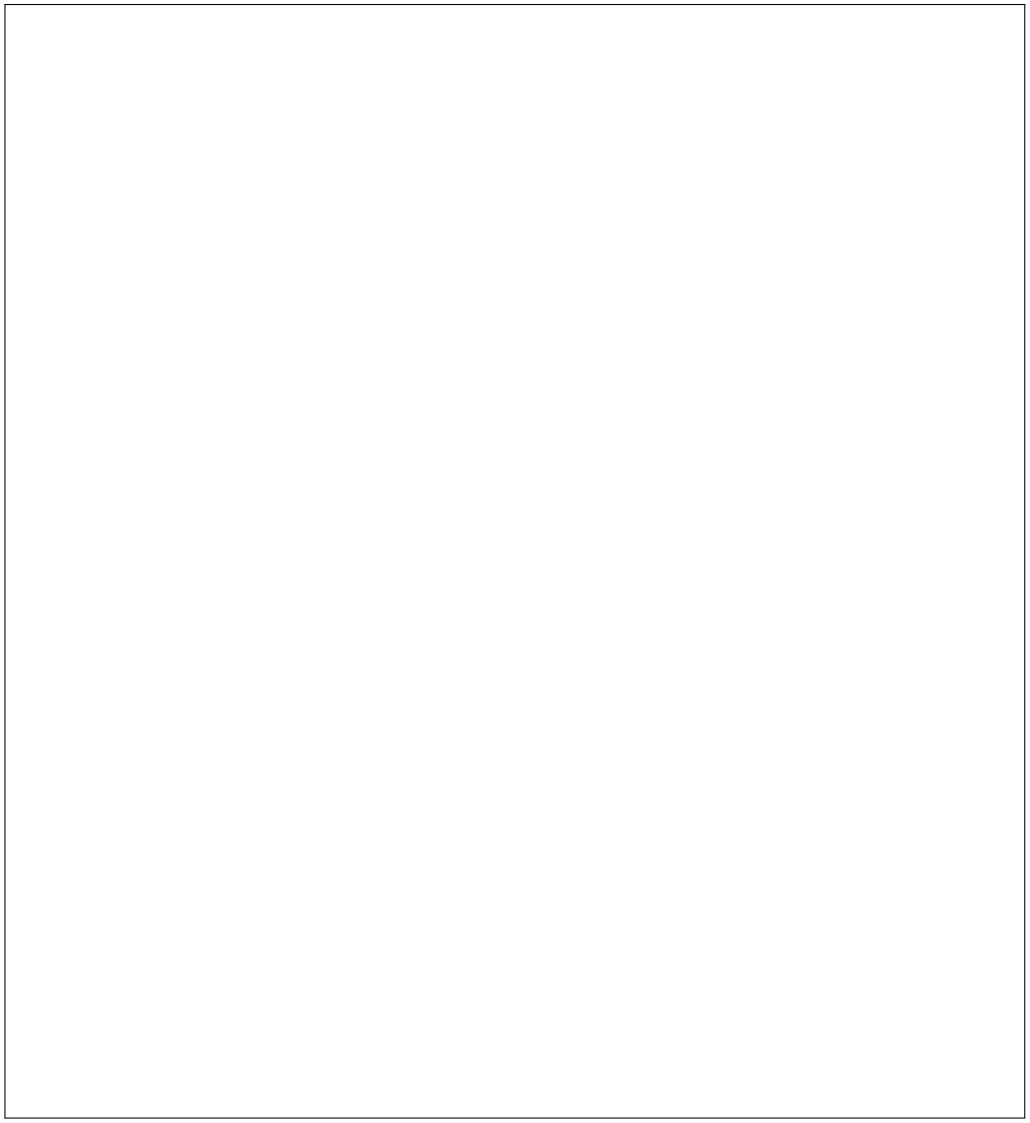


Folie 2.49



Spezielle Stochastische Prozesse

Wie sieht die Autokorrelationsfunktion eines „idealen“ Zufallssignals aus?



Folie 2.50

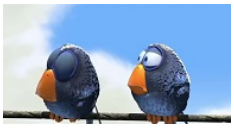
Weißes Rauschen [1]

- Bei *weißem Rauschen* handelt es sich um einen stationären stochastischen Prozess, dessen *Autokorrelationsfunktion* eine *Dirac-Funktion* ist: $\gamma_{\underline{X}\,\underline{X}}(\tau) = A \cdot \delta(\tau)$
- Der Begriff „weiß“ hat seinen Namen aus der *Optik*. Die Dirac-Funktion ist im Frequenzbereich eine Konstante und besitzt somit alle Frequenzen, genau wie „weißes“ Licht *alle Farbfrequenzen* enthält.
- Für die Fouriertransformierte $\Gamma_{\underline{X}\,\underline{X}}(j\cdot\omega)$ für weißes Rauschen gilt:

$$\Gamma_{\underline{X}\,\underline{X}}(j\cdot\omega) = \mathcal{F}\big(\gamma_{\underline{X}\,\underline{X}}(\tau)\big) = \frac{1}{2\pi}\int_{-\infty}^{\infty} \gamma_{\underline{X}\,\underline{X}}(t)\cdot e^{-i\omega t}\,dt = A$$

- *Unendlich hohe Frequenzen* lassen sich natürlich *nicht* in der Praxis *realisieren*. Weißes Rauschen wird trotzdem zur Modellierung stochastischer Prozesse verwendet, da im interessierten Frequenzbereich die Eigenschaft von weißem Rauschen vorliegen.
- Weißes Rauschen bezieht sich auf die Art, wie sich das Signal über die Zeit verhält. Es sagt nichts über die Art der Verteilung / Dichtefunktion $f_X\big(\underline{x}(t)\big)$ aus. Deshalb muss ein *normalverteiltes Rauschen nicht automatisch* ein *weißes Rauschen* sein.

Folie 2.51



4.3 Kreuzkorrelation

Definitionen I

- Die *Kreuzkorrelationsfunktion* charakterisiert d. Beziehung zwischen zwei *stochastischen Prozessen*
- Die *Kreuzkorrelationsfunktion* eines *stochastischen Prozesses*, beschrieben durch d. Dichtefunktion $f_{X\,Y}\big(\underline{x}(t),\underline{y}(t)\big)$ und die beiden Zufallsvektoren $\underline{X}(t)$, $\underline{Y}(t)$, ist definiert durch:

$$\gamma_{\underline{X}\,\underline{Y}}(t_1,t_2) = \mathrm{E}\big(\underline{X}(t_1)\cdot\underline{Y}(t_2)\big) = \int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} \underline{x}(t_1)\cdot\underline{y}(t_2)\cdot f_{X\,Y}\big(\underline{x}(t),\underline{y}(t)\big)\; d\underline{x}(t_1)\; d\underline{y}(t_2)$$

- Für *stationäre stochastische Prozesse* hängt die Kreuzkorrelationsfunktion nur von der Zeitdifferenz τ ab.
  Somit folgt für $t_2 = t+\tau$:

$$\gamma_{\underline{X}\,\underline{Y}}(\tau) = \mathrm{E}\big(\underline{X}(t)\cdot\underline{Y}(t+\tau)\big) = \int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} \underline{x}(t)\cdot\underline{y}(t+\tau)\cdot f_{X\,Y}(\underline{x},\underline{y})\; d\underline{x}(t)\; d\underline{y}(t+\tau)$$

- Für *ergodische, streng stationäre stochastische Prozesse* berechnet sich die Kreuzkorrelationsfunktion zu: $\gamma_{X\,Y}(\tau) = \lim\limits_{\Delta T\to\infty} \dfrac{1}{\Delta T}\cdot \int_{-0.5\cdot\Delta T}^{0.5\cdot\Delta T} x(t)\cdot y(t+\tau)\; dt$

Folie 2.53

Definitionen II

- Für stationäre stochastische Prozesse ist die *normierte Kreuzkorrelationsfunktion* definiert mit: $\gamma^*_{\underline{X}\,\underline{Y}}(\tau) = \dfrac{\gamma_{\underline{X}\,\underline{Y}}(\tau)}{\sqrt{\gamma_{\underline{X}\,\underline{X}}(0)\cdot\gamma_{\underline{Y}\,\underline{Y}}(0)}}$
- Die Kreuzkorrelationsfunktion eines *diskreten ergodischen, stationären stochast. Prozesses* berechnet sich zu:

$$\gamma_{X\,Y}(k) = \begin{cases} \displaystyle\sum_{n=0}^{N-k-1} x(n)\cdot y(n+k) & k \geq 0 \\ \gamma_{Y\,X}(-k) & k < 0 \end{cases}$$

- Die Kreuzkorrelation ist nicht zu verwechseln mit der Faltung von Signalen, die sehr ähnlich definiert ist. Die Faltung zweier Signale ist definiert mit:

$$x(t) * y(t) = \lim_{\Delta T\to\infty} \frac{1}{\Delta T}\cdot \int_{-0.5\cdot\Delta T}^{0.5\cdot\Delta T} x(\tau)\cdot y(t-\tau)\; d\tau$$

  Die Faltung ist für die Datenfusion von keiner Bedeutung und kommt im Bereich der Signalverarbeitung und in verschiedenen Gebieten der Physik zum Einsatz.

Folie 2.54



Übungsaufgaben Kreuzkorrelationsfunktion I

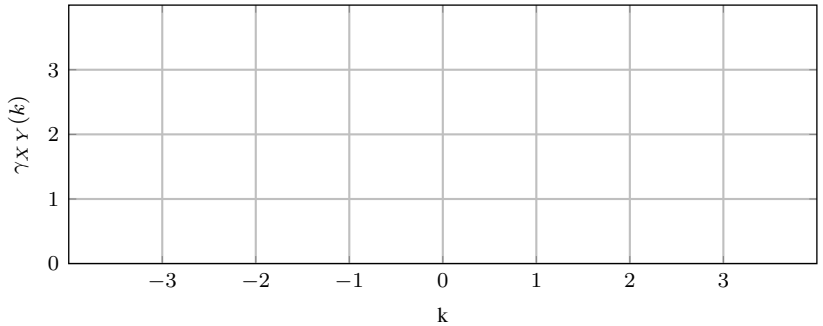
Bestimmen Sie die Kreuzkorrelationsfunktion für einen ergodischen, streng stationären stochastischen Prozess mit x(k) = {0,1,0,1}, y(k) = {0,1,0,2}

Lösung:

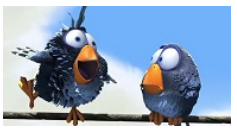
Folie 2.55

Lösung Übungsaufgaben I

Zeichnen Sie die Kreuzkorrelationsfunktion in das unten stehende Diagramm



Folie 2.56



Übungsaufgaben Kreuzkorrelationsfunktion II

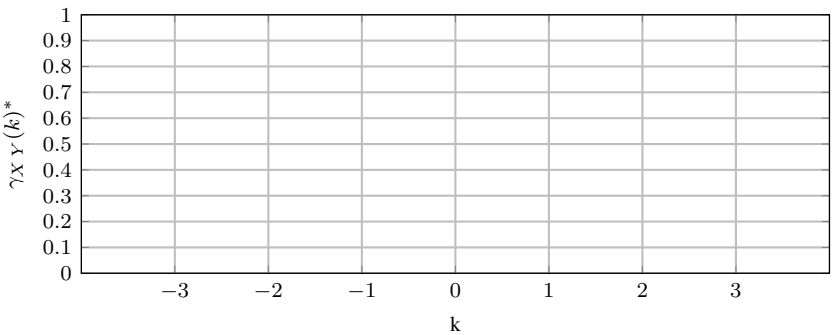
Bestimmen Sie die normierte Kreuzkorrelationsfunktion für einen ergodischen, streng stationären stochastischen Prozess mit x(k) = {1,0,1,0} und y(k) = {1,2,3,3}

Lösung:

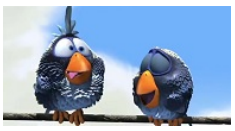
Folie 2.57

Lösung Übungsaufgaben II

Zeichnen Sie die Kreuzkorrelationsfunktion in das unten stehende Diagramm



Folie 2.58



Verständnisfragen I

1. Wie sieht die Kreuzkorrelationsfunktion eines ergodischen, streng stationären stochastischen Prozess $\gamma_{XY}(k)$ für eine periodischen Folge $f(k)$ mit weißem Rauschen aus?

Folie 2.59

Verständnisfragen II

2. Wie sieht die Kreuzkorrelationsfunktion zweier (unkorrelierter) Folgen, jeweils bestehend aus weißem Rauschen, aus?
3. Wie sieht die Kreuzkorrelationsfunktion zweier (unkorrelierter) Folgen, jeweils bestehend aus farbigen Rauschen, aus?
4. Welchen Wert besitzt die normierte Kreuzkorrelationsfunktion $\gamma_{XY}(k)^*$ einer Folge $f(k)$ mit sich selbst bei $k = 0$

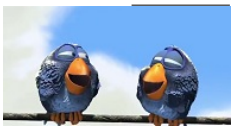
Folie 2.60

4.4 Lernziele

Lernkontrolle: Signaltheorie

- Sie sollten mit den *Begriffen von stochastischen Prozessen* vertraut sein.
- Sie sollten in der Lage sein von beliebigen Signalen den *Autokorrelation* und die *Kreuzkorrelation* berechnen zu können.
- Sie sollten die Definition und die Eigenschaften von *weißem Rauschen* kennen.

Folie 2.62



Teil III

Datenfusion zeitinvarianter Größen

5 Datenfusion zur Schätzung zeitinvarianter Größen (Konstanten)

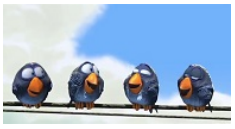
5.1 Schätzung einer Konstanten (Skalar)

Modellierung

Bezug nehmend auf das einführende Beispiel zur Schätzung der Einwohner von Esslingen lässt sich eine Schätzung y_i modellieren durch:

Messtechnisch erfassbares Residuum (engl.: „*measurement residual*“):

Folie 3.4



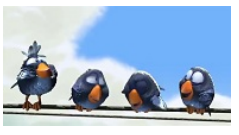
Gewinnfunktion M

Nach Carl F. Gauß wird das Minimum des Quadrats dieses Residuum gesucht:

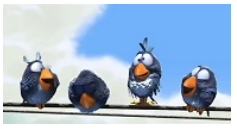
Minimum der Gewinnfunktion J

$$(\underline{a} \cdot \underline{b})^T = \underline{b}^T \cdot \underline{a}^T \qquad (\underline{a} + \underline{b})^T = \underline{a}^T + \underline{b}^T$$

$$\frac{\partial \underline{x}^T \cdot \underline{a}}{\partial \underline{x}} = \frac{\partial \underline{a}^T \cdot \underline{x}}{\partial \underline{x}} = \underline{a} \qquad \frac{\partial \underline{x}^T \cdot \underline{a} \cdot \underline{x}}{\partial \underline{x}} = \left(\underline{a} + \underline{a}^T\right) \cdot \underline{x}$$



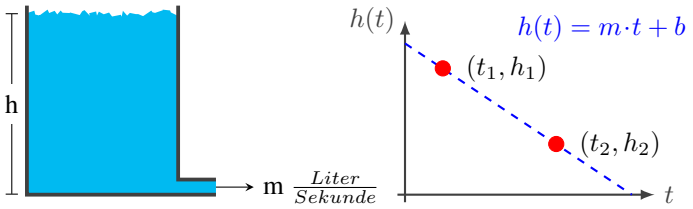
Bestimmung des Minimums durch:



5.2 Schätzung mehrerer Konstanten

Bestimmung der Abflussmenge pro Minute

- Ein Behälter hat die Querschnittsfläche von $1m^2$.
- Über einen Schwimmer wird die aktuelle Füllstandshöhe bestimmt.
- Nach dem Öffnen eines Ventils strömt das Wasser aus
- Zum Zeitpunkt $t_1 = 10$s wird der Füllstand von $h_1 = 69.9$cm und zum Zeitpunkt $t_2 = 110$s wird der Füllstand von $h_2 = 68.9$cm bemessen

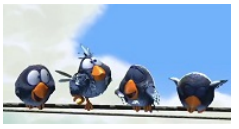


- Bestimmen Sie d. Menge Wasser die pro Sekunde m aus d. Tank fließt.
- Wie viel Wasser war zum Zeitpunkt t_0 (beim Öffnen des Tanks) im Tank?

Folie 3.8

Lösung: Bestimmung der Abflussmenge pro Minute

Folie 3.9



Verallgemeinerung I

Zur Schätzung eines Vektors bestehend aus m-Konstanten gilt:

$$\begin{aligned} y_1 &= c_{1,1}\cdot x_1 + c_{1,2}\cdot x_2 + \cdots + c_{1,m}\cdot x_m + v_1 \\ &\vdots \\ y_n &= c_{n,1}\cdot x_1 + c_{n,2}\cdot x_2 + \cdots + c_{n,m}\cdot x_m + v_n \\ \underline{y} &= \underline{C}\cdot\underline{x} + \underline{v} \end{aligned}$$

Messtechnisch erfassbares Residuum: $\underline{\epsilon} = \underline{y} - \underline{C}\cdot\underline{\hat{x}}$

$$\begin{aligned} J &= \epsilon_1^2 + \epsilon_2^2 + \cdots + \epsilon_n^2 = \underline{\epsilon}^T\cdot\underline{\epsilon} \\ &= (\underline{y} - \underline{C}\cdot\underline{\hat{x}})^T\cdot(\underline{y} - \underline{C}\cdot\underline{\hat{x}}) \\ &= \underline{y}^T\cdot\underline{y} - \underline{y}^T\cdot\underline{C}\cdot\underline{\hat{x}} - \underline{\hat{x}}^T\cdot\underline{C}^T\cdot\underline{y} + \underline{\hat{x}}^T\cdot\underline{C}^T\cdot\underline{C}\cdot\underline{\hat{x}} \end{aligned}$$

Folie 3.10

Verallgemeinerung II

$$(\underline{a}\cdot\underline{b})^T = \underline{b}^T\cdot\underline{a}^T \qquad (\underline{a}+\underline{b})^T = \underline{a}^T + \underline{b}^T$$

$$\frac{\partial \underline{x}^T\cdot\underline{a}}{\partial\underline{x}} = \frac{\partial \underline{a}^T\cdot\underline{x}}{\partial\underline{x}} = \underline{a} \qquad \frac{\partial \underline{x}^T\cdot\underline{a}\cdot\underline{x}}{\partial\underline{x}} = \left(\underline{a}+\underline{a}^T\right)\cdot\underline{x}$$

$$J = \underline{y}^T\cdot\underline{y} - \underline{y}^T\cdot\underline{C}\cdot\underline{\hat{x}} - \underline{\hat{x}}^T\cdot\underline{C}^T\cdot\underline{y} + \underline{\hat{x}}^T\cdot\underline{C}^T\cdot\underline{C}\cdot\underline{\hat{x}}$$

Bestimmung des Minimums durch:

$$\frac{\partial J}{\partial\underline{\hat{x}}} = -\underline{C}^T\cdot\underline{y} - \underline{C}^T\cdot\underline{y} + 2\cdot\underline{C}^T\cdot\underline{C}\cdot\underline{\hat{x}} = \underline{0}$$

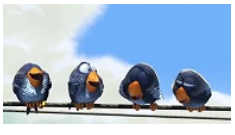
$$\begin{aligned} \underline{C}^T\cdot\underline{C}\cdot\underline{\hat{x}} &= \underline{C}^T\cdot\underline{y} \\ \underline{\hat{x}} &= (\underline{C}^T\cdot\underline{C})^{-1}\cdot\underline{C}^T\cdot\underline{y} \end{aligned}$$

Folie 3.11

Übung: Schätzung mehrerer Konstanten

- Ergänzung zum Beispiel zur Bestimmung der Abflussmenge.
- An einem anderen Tag musste wieder die Abflussmenge bestimmt werden. An diesem Tag herrschte jedoch starker Wind und es entstanden Wellen an der Oberfläche.
- Es wurde festgestellt, dass die Höhenmessungen aufgrund von Wellenbewegungen rauschen.
- Deshalb werden mehrere Messungen durchgeführt:
  - Zum Zeitpunkt $t_1 = 100$s wird der Füllstand von $h_1 = 58.1$cm,
  - zum Zeitpunkt $t_2 = 200$s wird der Füllstand von $h_2 = 56.0$cm,
  - zum Zeitpunkt $t_3 = 300$s wird der Füllstand von $h_3 = 53.9$cm und
  - zum Zeitpunkt $t_4 = 400$s wird der Füllstand von $h_4 = 52.2$cm bemessen
- Bestimmen Sie d. Menge Wasser die pro Sekunde m aus d. Tank fließt.
- Wie viel Wasser war zum Zeitpunkt t_0 (beim Öffnen des Tanks) im Tank?

Folie 3.12



Lösung: Schätzung mehrerer Konstanten

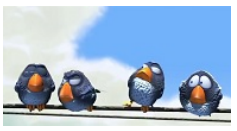
Folie 3.13

5.3 Gewichtete Schätzungen

Problematik mit unterschiedlich validen Messungen

- Bei den bisherigen Modellierungen wird davon ausgegangen, dass alle Messungen gleich valide sind.
- Sind Messungen unterschiedlich valide, müssen validere Messungen stärker gewichtet und unvalidere Messungen schwächer gewichtet werden.
- Beispielhaft sollte eine Schätzung der Einwohner in Esslingen stärker gewichtet werden, wenn einer sich bei der Schätzung sehr sicher ist und eine Schätzung schwächer gewichtet werden, wenn einer sich bei der Schätzung unsicher ist.
- Ebenso sollte eine Messung der Höhe des Tankinhalts, höher gewichtet werden, wenn man weiß, dass zu dem Messzeitpunkt z. B. gerade der Schwimmer nicht durch starke Wellen beeinflusst wurde.
- Für die Gewichtung einer Schätzung/Messung wird oft die Varianz einer Schätzung/Messung $\mathrm{Var}(v_i)$ benutzt.
- Darüber hinaus wird angenommen, dass der Erwartungswert $\mathrm{E}(v_i) = 0$ ist. Somit gilt für die Varianz einer Messung: $\mathrm{Var}\left(v_i\right) = \mathrm{E}\left(\left(v_i - \mathrm{E}\left(v_i\right)\right)^2\right) = \mathrm{E}\left(v_i^2\right) = \sigma_i^2$

Folie 3.15



Modellierung

Zur Schätzung eines Vektors bestehend aus n-Konstanten gilt:

$$\begin{aligned} y_1 &= c_{1,1}\cdot x_1 + c_{1,2}\cdot x_2 + \cdots + c_{1,m}\cdot x_m + v_1 \\ &\vdots \\ y_n &= c_{n,1}\cdot x_1 + c_{n,2}\cdot x_n + \cdots + c_{n,m}\cdot x_m + v_n \\ \underline{y} &= \underline{C}\cdot\underline{x} + \underline{v} \end{aligned}$$

Unter der Annahme, dass Rauschen mittelwertfrei und unkorreliert ist, folgt für die Kovarianz-Matrix des Messrauschens:

$$\underline{R} = \mathrm{E}\left(\underline{v}\cdot\underline{v}^T\right) = \begin{bmatrix} \sigma_1^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_n^2 \end{bmatrix}$$

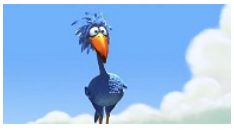
Messtechnisch erfassbares Residuum: $\underline{\epsilon} = \underline{y} - \underline{C}\cdot\underline{\hat{x}}$

$$\begin{aligned} J &= \left(\frac{\epsilon_1}{\sigma_1}\right)^2 + \left(\frac{\epsilon_2}{\sigma_2}\right)^2 + \cdots + \left(\frac{\epsilon_n}{\sigma_n}\right)^2 = \underline{\epsilon}^T\cdot\underline{R}^{-1}\cdot\underline{\epsilon} \\ &= (\underline{y} - \underline{C}\cdot\underline{\hat{x}})^T\cdot\underline{R}^{-1}\cdot(\underline{y} - \underline{C}\cdot\underline{\hat{x}}) \end{aligned}$$

Folie 3.16

Minimum der Gewinnfunktion J

Folie 3.17



Übung Schätzung einer Konstante

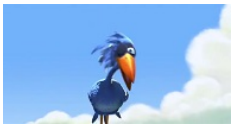
Bestimmen Sie die Länge eines Gegenstands:

- Die Länge eines Gegenstands wird mit zwei Messgeräten (A und B) bestimmt.
- Messungen mit dem Gerät A ergeben: 10.1m, 10.3m, 9.5m, 9.8m, 9.4m
- Messungen mit dem Gerät B ergeben: 11.0m, 10.5m, 9.5m, 10.0m, 9.0m
- Gerät A besitzt eine Messunsicherheit von 5% ($\propto$ Standardabweichung)
- Gerät B besitzt eine Messunsicherheit von 10% ($\propto$ Standardabweichung)
- Annahme: Die Messfehler zwischen den Geräten A und B sind unkorreliert

Folie 3.18

Lösung: Schätzung einer Konstante

Folie 3.19

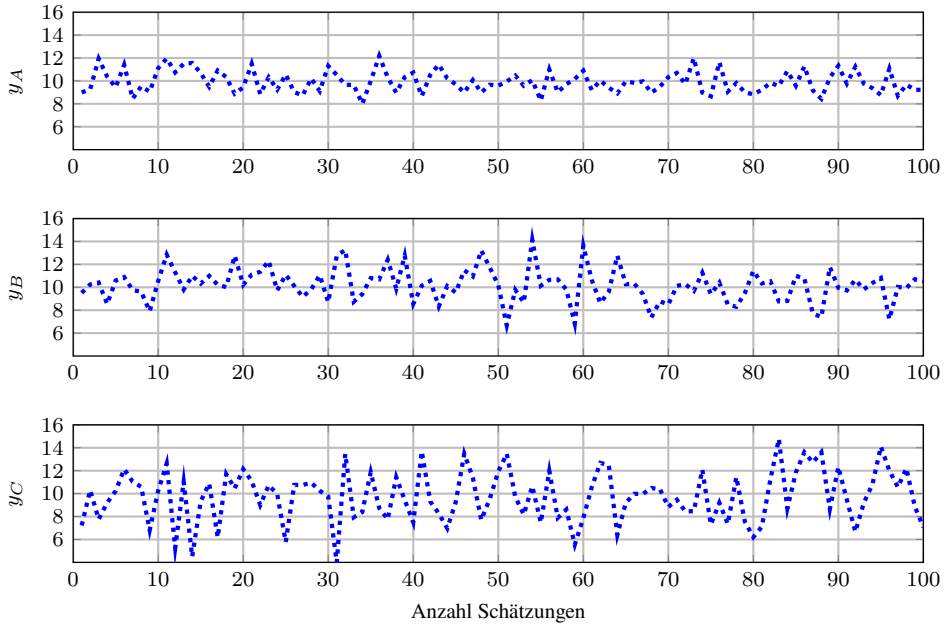


Übung Schätzung einer Konstante aus Zeitreihen

- Drei Sensoren (A,B,C) erfassen die selbe physikalische Größe, welche sich nicht über die Zeit verändert
- Aus messtechnischen Gründen sind die drei erfassten Sensorgrößen unterschiedlich stark verrauscht
- Annahme: Die Messfehler zwischen den drei Sensoren sind unkorreliert
- Bestimmen Sie die unbekannte Konstante mittels Datenfusion

Folie 3.20

Verlauf der Zeitreihen (Datei: data_n_Y.dat)



Folie 3.21

Lösung: Schätzung einer Konstante

Folie 3.22

Übung Schätzung einer Verschiebung und Drehung eines Bildes

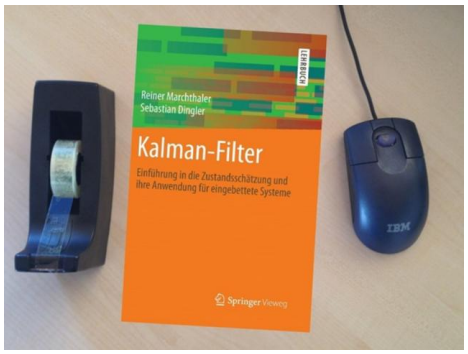


Abb. A: Originalbild

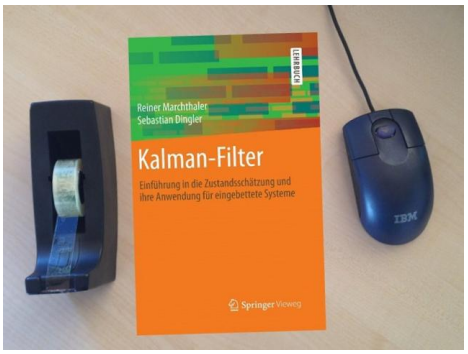


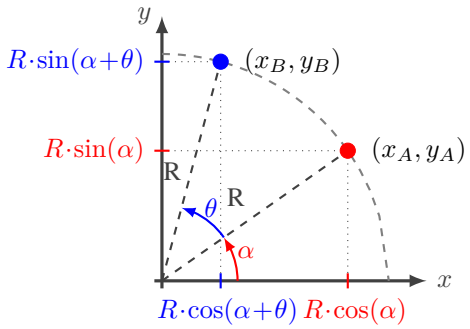
Abb. B: verschobenes und gedrehtes Bild

- In beiden Bilder wurde jeweils der geometrische Schwerpunkt der drei Gegenstände bestimmt.

  Punkt: Ia [92.4; 241.0] IIa [306.6; 241.7] IIIa [530.7; 240.8]
  Punkt: Ib [98.2; 267.4] IIb [311.6; 249.5] IIIb [535.0; 229.5]
- Bestimmen Sie die Translation (x- und y-Koordination) und die Rotation zwischen den beiden Bildern mittels Datenfusion

Folie 3.23

Hintergrund-Info: 2-D Affine Abbildungen Rotation



(1) $x_A = R{\cdot}\cos(\alpha)$
(2) $y_A = R{\cdot}\sin(\alpha)$
(3) $x_B = R{\cdot}\cos(\alpha{+}\theta) = R{\cdot}\cos(\alpha){\cdot}\cos(\theta) - R{\cdot}\sin(\alpha){\cdot}\sin(\theta)$
(4) $y_B = R{\cdot}\sin(\alpha{+}\theta) = R{\cdot}\cos(\alpha){\cdot}\sin(\theta) + R{\cdot}\sin(\alpha){\cdot}\cos(\theta)$

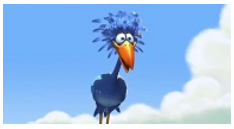
- (1) und (2) in (3): $x_B = x_A{\cdot}\cos(\theta) - y_A{\cdot}\sin(\theta)$
- (1) und (2) in (4): $y_B = x_A{\cdot}\sin(\theta) + y_A{\cdot}\cos(\theta)$

Folie 3.24

Hintergrund-Info: 2-D Affine Abbildungen Rotation, Translation und Skalierung

- Translation: $x_B = x_A + d_x \quad y_B = y_A + d_y$
- Rotation und Translation:
  $x_B = x_A{\cdot}\cos(\theta) - y_A{\cdot}\sin(\theta) + d_x$
  $y_B = x_A{\cdot}\sin(\theta) + y_A{\cdot}\cos(\theta) + d_y$
- Matrixschreibweise (ist für die Aufgabe nicht notwendig):

$$\begin{bmatrix} x_B \\ y_B \\ 1 \end{bmatrix} = \begin{bmatrix} \cos(\theta) & -\sin(\theta) & d_x \\ \sin(\theta) & \cos(\theta) & d_y \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x_A \\ y_A \\ 1 \end{bmatrix}$$



- Hinweis:
  Sie dürfen davon ausgehen, dass $a = \cos(\theta)$ und $b = \sin(\theta)$ in erster Näherung unabhängig sind.
  D. h. es gilt:
  $x_B = x_A \cdot a - y_A \cdot b + d_x$
  $y_B = x_A \cdot b + y_A \cdot a + d_y$

Folie 3.25

Lösung: Schätzung einer Verschiebung und Drehung eines Bildes

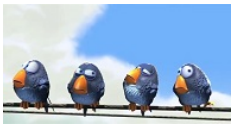
Folie 3.26

5.4 Lernziele

Lernkontrolle: Schätzung von zeitinvarianten Größen

- Sie sollten die *Herleitung* der Formeln zur gewichteten Fusionierung von zeitinvariante Größen *nachvollziehen* können.
- Sie sollten in der Lage sein *einzelne* und *mehrere* zeitinvariante Größen zu fusionieren.
- Sie sollten zeitinvariante Größen *gewichtet* fusionieren können.

Folie 3.28



Teil IV

Kalman-Filter

6 Beschreibung zeitvarianter Größen

6.1 Zustandsraum

Modellierung I

- Beschreibung dynamischer Systeme mittels einer Differentialgleichung
  $y^{(n)}(t) + a_{n-1} \cdot y^{(n-1)}(t) + \ldots + a_1 \cdot \dot{y}(t) + a_0 \cdot y(t) = b_0 \cdot u(t)$
- Man wählt die Zustandsvariable $\underline{x}(t)$ zu:

$$\begin{aligned} x_0(t) &= y(t) \\ x_1(t) &= \dot{y}(t) \\ &\vdots \\ x_{n-1}(t) &= y^{(n-1)}(t) \end{aligned}$$

- Somit kann die obige lineare Differentialgleichung n-ter Ordnung durch ein Gleichungssystem von n Differentialgleichungen erster Ordnung und einer weiteren Gleichung (Ausgangsgleichung) beschrieben werden:

$$\begin{aligned} \dot{x}_0(t) &= x_1(t) \\ \dot{x}_1(t) &= x_2(t) \\ &\vdots \\ \dot{x}_{n-1}(t) &= -a_{n-1} \cdot x_{n-1}(t) - \ldots - a_1 \cdot x_1(t) - a_0 \cdot x_0(t) + b_0 \cdot u(t) \\ y(t) &= x_0(t) \end{aligned}$$

Folie 4.4

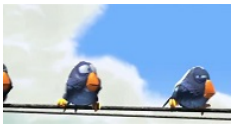
Modellierung II

- In Matrixform lautet das Gleichungssystem:

$$\begin{bmatrix} \dot{x}_0(t) \\ \dot{x}_1(t) \\ \vdots \\ \dot{x}_{n-1}(t) \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 & \ldots & 0 \\ 0 & 0 & 1 & \ldots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -a_0 & -a_1 & -a_2 & \ldots & -a_{n-1} \end{bmatrix} \cdot \begin{bmatrix} x_0(t) \\ x_1(t) \\ \vdots \\ x_{n-1}(t) \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ \vdots \\ b_0 \cdot u(t) \end{bmatrix}$$

$$y(t) = \begin{bmatrix} 1 & 0 & \ldots & 0 \end{bmatrix} \cdot \begin{bmatrix} x_0(t) \\ x_1(t) \\ \vdots \\ x_{n-1}(t) \end{bmatrix}$$

Folie 4.5



Modellierung III

- Verallgemeinert man die Zustandsgleichungen auf ein zeitinvariantes lineares System der Ordnung n mit i Eingangs- und j Ausgangsgrößen, erhält man in Matrixform folgendes Gleichungssystem:

$$\begin{bmatrix} \dot{x}_0(t) \\ \dot{x}_1(t) \\ \vdots \\ \dot{x}_{n-1}(t) \end{bmatrix} = \begin{bmatrix} a_{0,0} & a_{0,1} & a_{0,2} & \dots & a_{0,n-1} \\ a_{1,0} & a_{1,1} & a_{1,2} & \dots & a_{1,n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n-1,0} & a_{n-1,1} & a_{n-1,2} & \dots & a_{n-1,n-1} \end{bmatrix} \cdot \begin{bmatrix} x_0(t) \\ x_1(t) \\ \vdots \\ x_{n-1}(t) \end{bmatrix}$$
$$+ \begin{bmatrix} b_{0,0} & b_{0,1} & b_{0,2} & \dots & b_{0,i-1} \\ b_{1,0} & b_{1,1} & b_{1,2} & \dots & b_{1,i-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ b_{n-1,0} & b_{n-1,1} & b_{n-1,2} & \dots & b_{n-1,i-1} \end{bmatrix} \cdot \begin{bmatrix} u_0(t) \\ u_1(t) \\ \vdots \\ u_{i-1}(t) \end{bmatrix}$$

$$\begin{bmatrix} y_0(t) \\ y_1(t) \\ \vdots \\ y_{j-1}(t) \end{bmatrix} = \begin{bmatrix} c_{0,0} & c_{0,1} & c_{0,2} & \dots & c_{0,n-1} \\ c_{1,0} & c_{1,1} & c_{1,2} & \dots & c_{1,n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ c_{j-1,0} & c_{j-1,1} & c_{j-1,2} & \dots & c_{j-1,n-1} \end{bmatrix} \cdot \begin{bmatrix} x_0(t) \\ x_1(t) \\ \vdots \\ x_{n-1}(t) \end{bmatrix}$$
$$+ \begin{bmatrix} d_{0,0} & d_{0,1} & d_{0,2} & \dots & d_{0,i-1} \\ d_{1,0} & d_{1,1} & d_{1,2} & \dots & d_{1,i-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ d_{j-1,0} & d_{j-1,1} & d_{j-1,2} & \dots & d_{j-1,i-1} \end{bmatrix} \cdot \begin{bmatrix} u_0(t) \\ u_1(t) \\ \vdots \\ u_{i-1}(t) \end{bmatrix}$$

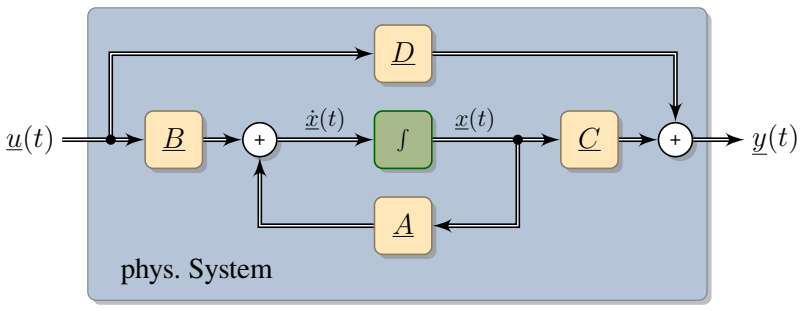
Folie 4.6

Modellierung IV

- In Kurzschreibweise in Matrixform lässt sich das Gleichungssystem mit der Zustandsdifferentialgleichung und der Ausgangsgleichung schreiben:

$$\dot{\underline{x}}(t) = \underline{A} \cdot \underline{x}(t) + \underline{B} \cdot \underline{u}(t)$$
$$\underline{y}(t) = \underline{C} \cdot \underline{x}(t) + \underline{D} \cdot \underline{u}(t)$$

- Zustandsvariable, Zustandsgröße oder Zustandsvektor $\underline{x}(t)$
- Eingangsvektor $\underline{u}(t)$ und Ausgangsvektor $\underline{y}(t)$
- Systemmatrix $\underline{A}$, Eingangsmatrix $\underline{B}$, Ausgangsmatrix $\underline{C}$ und Durchgangsmatrix $\underline{D}$



Quelle: Marchthaler, Kalman-Filter [1]

Folie 4.7

Übungsaufgaben Zustandsraumbeschreibung I

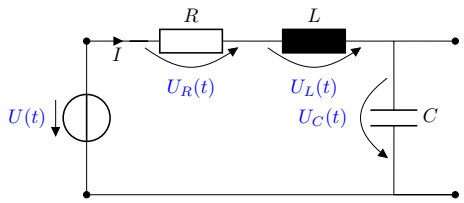
Geben Sie die Zustandsraumbeschreibung für ein Punkt-Masse-System mit der Eingangsgröße a(t) und der Ausgangsgröße s(t) an.

Es gilt: $a(t) = \dot{v}(t) = \ddot{s}(t)$

Lösung:

Übungsaufgaben Zustandsraumbeschreibung II

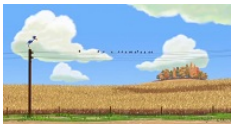
Geben Sie die Zustandsraumbeschreibung für einen Reihenschwingkreis mit der Eingangsgröße $U(t)$ und der Ausgangsgröße $U_C(t)$ an.



Es gilt:

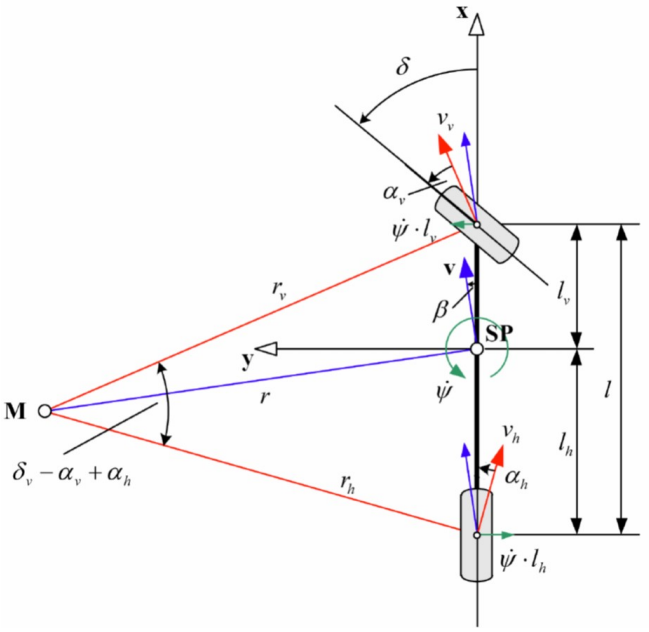
$$I(t) = C \cdot \dot{U}_C(t)$$
$$U_L(t) = L \cdot \dot{I}(t)$$
$$U_R(t) = R \cdot I(t)$$
$$U(t) = U_R(t) + U_L(t) + U_C(t)$$

Lösung:



Übungsaufgaben Zustandsraumbeschreibung III

Geben Sie die Zustandsraumbeschreibung für ein Einspurmodell mit der Eingangsgröße $\delta(t)$ und der Ausgangsgröße $\dot{\psi}(t)$ an.



Quelle: M. Graf [3]

Folie 4.10

Lösung Zustandsraumbeschreibung III

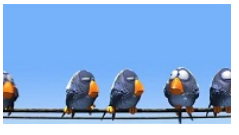
Es gilt mit den Schräglaufsteifigkeiten c_v und c_h :

$$\dot{\beta}(t) = -\frac{c_v + c_h}{m \cdot v} \cdot \beta(t) - \frac{m \cdot v^2 - (c_h \cdot l_h - c_v \cdot l_v)}{m \cdot v^2} \cdot \dot{\psi}(t) + \frac{c_v}{m \cdot v} \cdot \delta(t)$$

$$\ddot{\psi}(t) = \frac{c_h \cdot l_h - c_v \cdot l_v}{\theta} \cdot \beta(t) - \frac{c_h \cdot {l_h}^2 + c_v \cdot {l_v}^2}{\theta \cdot v} \cdot \dot{\psi}(t) + \frac{c_v \cdot l_v}{\theta} \cdot \delta(t).$$

Lösung:

Folie 4.11



6.2 Systemeigenschaften

Beobachtbarkeit

- Ein lineares zeitinvariantes System, im Zustandsraum ist vollständig *beobachtbar*, wenn es möglich ist, innerhalb eines endlichen Intervalls $[t_0, t_1]$, aus *Kenntnis der Eingangsgrößen* $\underline{u}(t)$ und der *Ausgangsgrößen* $\underline{y}(t)$ *jeden Anfangszustand* des Zustandsvektors $\underline{x}(t_0)$ zu bestimmen [1].
- Nach Kalman gilt: Ein lineares zeitinvariantes System der *Ordnung n* ist *beobachtbar*, wenn die *Beobachtbarkeitsmatrix* S_B

$$\underline{S}_B = \begin{bmatrix} \underline{C} \\ \underline{C} \cdot \underline{A} \\ \underline{C} \cdot \underline{A}^2 \\ \vdots \\ \underline{C} \cdot \underline{A}^{n-1} \end{bmatrix}$$

  den *Rang n* besitzt.
- Der *Rang* ist die *maximale Anzahl der linear unabhängigen Zeilenvektoren*.

Folie 4.13

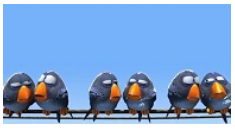
Beispiele für den Rang einer Matrix

$$\text{Rang}\left(\begin{bmatrix} 0 & 1 & 0 \\ 3 & 4 & 5 \\ 2 & 3 & 0 \end{bmatrix}\right) = 3 \qquad \text{Rang}\left(\begin{bmatrix} 0 & 1 & 0 \\ 1 & 4 & 2 \\ 2 & 8 & 4 \end{bmatrix}\right) = 2$$

$$\text{Rang}\left(\begin{bmatrix} 2 & 3 & 1 \\ 6 & 9 & 3 \\ 4 & 6 & 2 \end{bmatrix}\right) = 1 \qquad \text{Rang}\left(\begin{bmatrix} 2 & 3 \\ 1 & 2 \\ 6 & 2 \end{bmatrix}\right) = 2$$

$$\text{Rang}\left(\begin{bmatrix} 0 & 1 \\ 1 & 2 \\ 3 & 2 \end{bmatrix}\right) = 2 \qquad \text{Rang}\left(\begin{bmatrix} 3 & 1 \\ 9 & 3 \\ 6 & 2 \end{bmatrix}\right) = 1$$

Folie 4.14



Übungsaufgaben Beobachtbarkeit I

Überprüfen Sie, ob der Reihenschwingkreis mit der Eingangsgröße $U(t)$ und der Ausgangsgröße $U_C(t)$ beobachtbar ist.

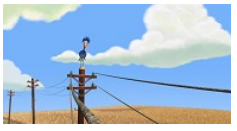
Lösung:

Folie 4.15

Übungsaufgaben Beobachtbarkeit II

Wäre jetzt abweichend bei dem Beispiel des Reihenschwingkreises $y(t) = I(t)$, ändert sich die Ausgangsmatrix zu: $\underline{C} = \begin{bmatrix} 0 & 1 \end{bmatrix}$. Ist ein solches System beobachtbar?

Folie 4.16



Steuerbarkeit

- Der Vollständigkeit halber ist erwähnt, dass es neben der Beobachtbarkeit auch die *Steuerbarkeit* eines System gibt. Diese ist jedoch für d. *Datenfusion* von *keiner Bedeutung* .
- Ein lineares zeitinvariantes System, im Zustandsraum ist vollständig *steuerbar*, wenn es möglich ist, innerhalb eines endlichen Intervalls $[t_0, t_1]$, aus *geeignete Eingangsgrößen* $\underline{u}(t)$ jeden *Anfangszustand* des Zustandsvektors $\underline{\mathbf{x}}(\mathbf{t_0})$ in jeden *Zustand* $\underline{\mathbf{x}}(\mathbf{t_1})$ zu überführen [1].
- Nach Kalman gilt: Ein lineares zeitinvariantes System der *Ordnung n* ist *steuerbar*, wenn die *Steuerbarkeitsmatrix* S_S

$$\underline{S}_S = \left[\begin{array}{cccc} \underline{B}, & \underline{A}\cdot\underline{B}, & \underline{A}^2\cdot\underline{B}, & \ldots, \quad \underline{A}^{n-1}\cdot\underline{B} \end{array} \right]$$

den *Rang n* besitzt.

Folie 4.17

6.3 Zeitdiskrete Systeme

Lösung der Zustandsgleichung I

- Multipliziert man die Zustandsdifferentialgleichung $\dot{\underline{x}}(t) = \underline{A}\cdot\underline{x}(t) + \underline{B}\cdot\underline{u}(t)$ mit $e^{-\underline{A}\cdot t}$ folgt:

$$e^{-\underline{A}\cdot t}\cdot\dot{\underline{x}}(t) - e^{-\underline{A}\cdot t}\cdot\underline{A}\cdot\underline{x}(t) = e^{-\underline{A}\cdot t}\cdot\underline{B}\cdot\underline{u}(t) \tag{1}$$

- Leitet man $e^{-\underline{A}\cdot t}\cdot\underline{x}(t)$ ab, erhält man mithilfe der Produktregel $(g\cdot h)' = g'\cdot h + g\cdot h'$:

$$\frac{d}{dt}\Big(\underbrace{e^{-\underline{A}\cdot t}}_{g}\cdot\underbrace{\underline{x}(t)}_{h}\Big) = \underbrace{-\underline{A}\cdot e^{-\underline{A}\cdot t}}_{\dot{g}}\cdot\underbrace{\underline{x}(t)}_{h} + \underbrace{e^{-\underline{A}\cdot t}}_{g}\cdot\underbrace{\dot{\underline{x}}(t)}_{\dot{h}} \tag{2}$$

- Somit lässt sich die Gleichung (1) mit (2) schreiben:

$$\frac{d}{dt}\Big(e^{-\underline{A}\cdot t}\cdot\underline{x}(t)\Big) = e^{-\underline{A}\cdot t}\cdot\underline{B}\cdot\underline{u}(t) \tag{3}$$

- Durch Integration folgt:

$$\int_{t_0}^{t}\left(\frac{d}{d\tau}\Big(e^{-\underline{A}\cdot\tau}\cdot\underline{x}(\tau)\Big)\right)d\tau = \int_{t_0}^{t} e^{-\underline{A}\cdot\tau}\cdot\underline{B}\cdot\underline{u}(\tau)d\tau$$

$$e^{-\underline{A}\cdot t}\cdot\underline{x}(t) - e^{-\underline{A}\cdot t_0}\cdot\underline{x}(t_0) = \int_{t_0}^{t} e^{-\underline{A}\cdot\tau}\cdot\underline{B}\cdot\underline{u}(\tau)d\tau \tag{4}$$

Folie 4.19

Lösung der Zustandsgleichung II

- Gleichung (4) nach $\underline{x}(t)$ aufgelöst, ergibt:

$$\underline{x}(t) = \underbrace{e^{\underline{A}\cdot(t-t_0)}\cdot\underline{x}(t_0)}_{\text{homogene Lösung}} + \underbrace{\int_{t_0}^{t} e^{\underline{A}\cdot(t-\tau)}\cdot\underline{B}\cdot\underline{u}(\tau)d\tau}_{\text{partikuläre Lösung}} \tag{5}$$

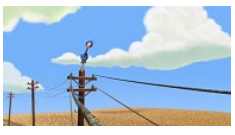
- Tastet man das kontinuierliche Signal alle $t = n\cdot T_s$ $(n = 0, 1, 2, ...)$ Sekunden ab, folgt für die Anfangszeit $t_0 = 0$ und $t = n\cdot T_s$ mit $n = 0, 1, 2, ...$:

$$\underline{x}(n\cdot T_s) = e^{\underline{A}\cdot n\cdot T_s}\cdot\underline{x}(0) + \int_0^{n\cdot T_s} e^{\underline{A}\cdot(n\cdot T_s-\tau)}\cdot\underline{B}\cdot\underline{u}(\tau)\,d\tau \tag{6}$$

- Für $t = (n+1)\cdot T_s$ folgt:

$$\underline{x}\big((n+1)\cdot T_s\big) = e^{\underline{A}(n+1)\cdot T_s}\cdot\underline{x}(0) + \int_0^{(n+1)T_s} e^{\underline{A}\left((n+1)T_s-\tau\right)}\cdot\underline{B}\cdot\underline{u}(\tau)\,d\tau \tag{7}$$

Folie 4.20



Lösung der Zustandsgleichung III

- Teilt man das Integral in zwei Integrale von Gleichung (7) auf und klammert den Term $e^{\underline{A}\cdot T_s}$ aus, folgt:

$$\begin{aligned}
\underline{x}\big((n+1)\cdot T_s\big) &= e^{\underline{A}\cdot(n+1)\cdot T_s}\cdot\underline{x}(0) + \int_0^{n\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot\underline{B}\cdot\underline{u}(\tau)\,d\tau \\
&\quad + \int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot\underline{B}\cdot\underline{u}(\tau)\,d\tau \\
&= e^{\underline{A}\cdot T_s}\cdot e^{\underline{A}\cdot n\cdot T_s}\cdot\underline{x}(0) + \int_0^{n\cdot T_s} e^{\underline{A}\cdot T_s}\cdot e^{\underline{A}\cdot\left(n\cdot T_s-\tau\right)}\cdot\underline{B}\cdot\underline{u}(\tau)\,d\tau \\
&\quad + \int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot\underline{B}\cdot\underline{u}(\tau)\,d\tau \\
&= e^{\underline{A}\cdot T_s}\cdot\underbrace{\left(e^{\underline{A}\cdot n\cdot T_s}\cdot\underline{x}(0) + \int_0^{n\cdot T_s} e^{\underline{A}\cdot\left(n\cdot T_s-\tau\right)}\cdot\underline{B}\cdot\underline{u}(\tau)\,d\tau\right)}_{\underline{x}(n\cdot T_s)} \\
&\quad + \int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot\underline{B}\cdot\underline{u}(\tau)\,d\tau \\
&= e^{\underline{A}\cdot T_s}\cdot\underline{x}(n\cdot T_s) + \int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot\underline{B}\cdot\underline{u}(\tau)\,d\tau
\end{aligned} \tag{8}$$

- Zur weiteren Vereinfachung müssen weitere Annahmen zum Verlauf des Signals $\underline{u}(t)$ im Intervall $n\cdot T_s$ und $(n+1)\cdot T_s$ vorgenommen werden, da nur der Wert zu den Abtastzeitpunkten $t = n\cdot T_s$ mit $n = 0, 1, 2, \ldots$ bekannt ist.

Folie 4.21

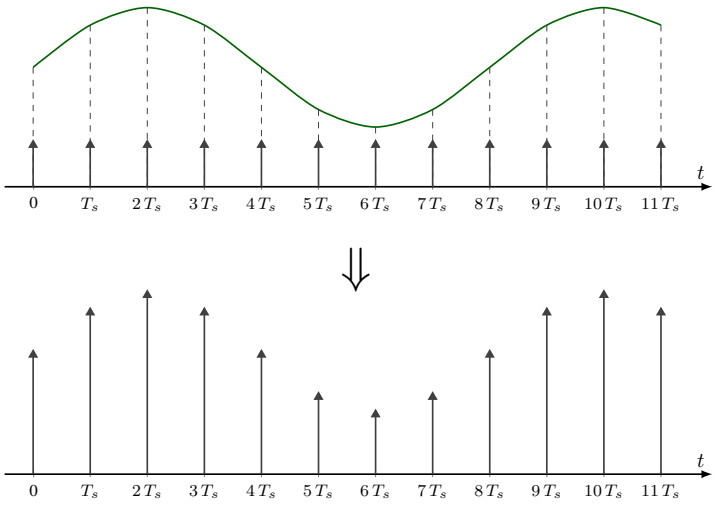
Ideale Abtastung I

- Mathematisch lässt sich das ideal abgetastete Signal $u_d(t)$ beschreiben durch:

$$u_d(t) = \sum_{n=0}^{n=\infty} u(n\cdot T_s)\cdot\delta(t - n\cdot T_s) \tag{9}$$

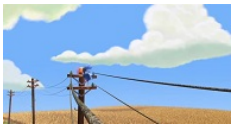
- Im Intervall $n\cdot T_s \le t < (n+1)\cdot T_s$ ist das Signal folglich:

$$u_d(t) = u(n\cdot T_s)\cdot\delta(t - n\cdot T_s) \tag{10}$$



Quelle: Marchthaler, Kalman-Filter [1]

Folie 4.22



Ideale Abtastung II

- Mit $u(t) \approx u_d(t)$, Gleichung (8) und Gleichung (10) folgt:

$$\underline{x}\big((n+1)\cdot T_s\big) = e^{\underline{A}\cdot T_s}\cdot \underline{x}(n\cdot T_s) + \int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot \underline{B}\cdot \underline{u}(\tau)\cdot\delta(\tau - n\cdot T_s)\,d\tau$$

- Durch die Ausblendeigenschaft des Dirac-Impulses folgt:

$$\begin{aligned}\underline{x}\big((n+1)\cdot T_s\big) &= e^{\underline{A}\cdot T_s}\cdot \underline{x}(n\cdot T_s) + e^{\underline{A}\cdot\left((n+1)\cdot T_s - nT_s\right)}\cdot \underline{B}\cdot \underline{u}(n\cdot T_s)\\ &= e^{\underline{A}\cdot T_s}\cdot \underline{x}(n\cdot T_s) + e^{\underline{A}\cdot T_s}\cdot \underline{B}\cdot \underline{u}(n\cdot T_s)\end{aligned}$$

- Mit $k = n\cdot T_s$ lässt sich die obige Gleichung schreiben, zu:

$$\underline{x}(k+1) = \underbrace{e^{\underline{A}\cdot T_s}}_{\underline{A}_d}\cdot\underline{x}(k) + \underbrace{e^{\underline{A}\cdot T_s}\cdot\underline{B}}_{\underline{B}_d}\cdot\underline{u}(k)$$

- Das lineare zeitdiskrete System wird somit beschreiben durch:

$$\begin{aligned}\underline{x}(k+1) &= \underline{A}_d\cdot\underline{x}(k) + \underline{B}_d\cdot\underline{u}(k)\\ \underline{y}(k) &= \underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k)\end{aligned}$$

$$\text{mit}\qquad \underline{A}_d = e^{\underline{A}\cdot T_s},\qquad \underline{B}_d = e^{\underline{A}\cdot T_s}\cdot\underline{B} \tag{11}$$

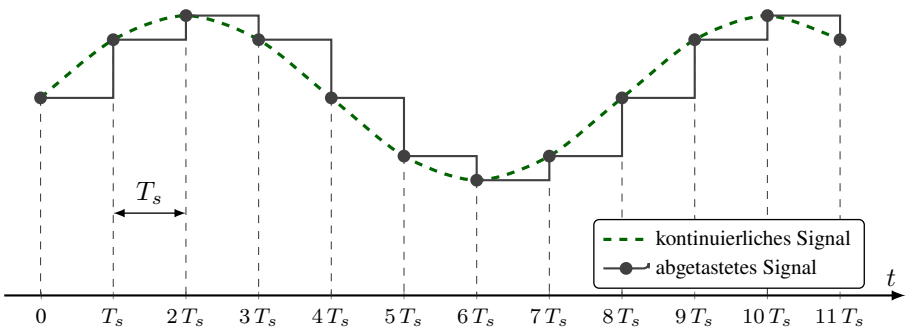
- Berechnung von $\underline{A}_d$ erfolgt z. B. mithilfe der Laplacetransformation

Folie 4.23

Reale Abtastung I

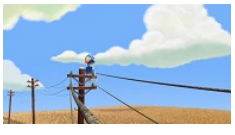
- In der Realität benötigt man eine endliche Zeit, um den abgetasteten Wert eines Signals zu bestimmen.
- Alternativer Ansatz: Modellierung des Abtastvorgangs nach einem Dirac-Impuls durch ein zusätzliches Halteglied.
- Annahme: das abgetastete Signal verändert sich nicht.
  Somit ist $u(t) = u(n\cdot T_s)$ im Intervall $n\cdot T_s \le t < (n+1)\cdot T_s$ konstant.
  $\underline{u}(\tau)$ geht in $\underline{u}(n\cdot T_s)$ über und d. Gleichung (8) lässt sich schreiben mit:

$$\underline{x}\big((n+1)\cdot T_s\big) = e^{\underline{A}T_s}\cdot\underline{x}(n\cdot T_s) + \int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot\underline{B}\,d\tau\cdot\underline{u}(n\cdot T_s) \tag{12}$$



Quelle: Marchthaler, Kalman-Filter [1]

Folie 4.24



Reale Abtastung II

- Substitution mit: $\nu(\tau) = (n+1)\cdot T_s - \tau$.
- Ableitung nach τ ergibt: $\frac{d\nu}{d\tau} = \frac{d}{d\tau}\big((n+1)\cdot T_s - \tau\big) = -1$.
- Somit ist $d\tau = -d\nu$.
- Integrationsgrenzen des Integrals ändern sich mit dieser Substitution zu:
  - Untere Integrationsgrenze: $\nu(n\cdot T_s) = (n+1)\cdot T_s - n\cdot T_s = T_s$
  - Obere Integrationsgrenze: $\nu\big((n+1)\cdot T_s\big) = (n+1)\cdot T_s - (n+1)\cdot T_s = 0$
- Durch diese Substitution lässt sich Gleichung (12) vereinfachen.

$$\begin{aligned}\underline{x}\big((n+1)\cdot T_s\big) &= e^{\underline{A}\cdot T_s}\cdot \underline{x}(n\cdot T_s) - \int_{T_s}^{0} e^{\underline{A}\cdot\nu}\cdot \underline{B}\, d\nu \cdot \underline{u}(n\cdot T_s) \\ &= e^{\underline{A}\cdot T_s}\cdot \underline{x}(n\cdot T_s) + \int_{0}^{T_s} e^{\underline{A}\cdot\nu}\cdot \underline{B}\, d\nu \cdot \underline{u}(n\cdot T_s)\end{aligned}$$

- Mit $k = n\cdot T_s$ lässt sich die obige Gleichung schreiben, zu:

$$\underline{x}(k+1) = \underbrace{e^{\underline{A}\cdot T_s}}_{\underline{A}_d}\cdot \underline{x}(k) + \underbrace{\int_{0}^{T_s} e^{\underline{A}\cdot\nu}\cdot \underline{B}\, d\nu}_{\underline{B}_d}\cdot \underline{u}(k) \tag{13}$$

- Das lineare zeitdiskrete System wird somit beschrieben durch:

$$\begin{aligned}\underline{x}(k+1) &= \underline{A}_d\cdot \underline{x}(k) + \underline{B}_d\cdot \underline{u}(k) \\ \underline{y}(k) &= \underline{C}\cdot \underline{x}(k) + \underline{D}\cdot \underline{u}(k)\end{aligned}$$

$$\text{mit} \qquad \underline{A}_d = e^{\underline{A}\cdot T_s}, \qquad \underline{B}_d = \int_{0}^{T_s} e^{\underline{A}\cdot\nu}\cdot \underline{B}\, d\nu \tag{14}$$

Folie 4.25

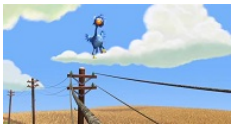
Übungsaufgaben Diskrete Zustandsraumbeschreibung I

Bestimmen Sie die Matrizen A_d und B_d für ein Punkt-Masse-System für welches gilt:

$$\underline{A} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \qquad \underline{B} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

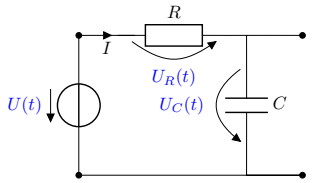
Lösung:

Folie 4.26



Übungsaufgaben Diskrete Zustandsraumbeschreibung II

Geben Sie die diskrete Zustandsraumbeschreibung für einen Tiefpass mit der Eingangsgröße $U(k)$ und der Ausgangsgröße $U_C(k)$ an.



Es gilt:

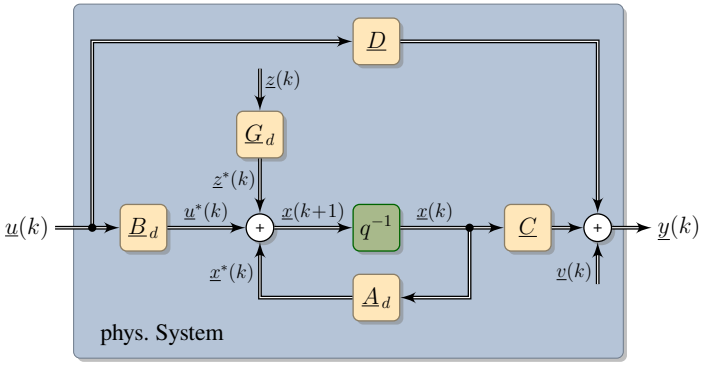
$$I(t) = C \cdot \dot{U}_C(t)$$
$$U_R(t) = R \cdot I(t)$$
$$U(t) = U_R(t) + U_C(t)$$

Lösung:

Folie 4.27

6.4 System- und Messrauschen

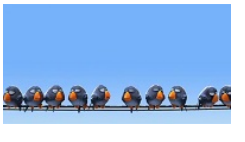
Beschreibung realer, zeitdiskreter, linearer Systeme im Zustandsraum



Quelle: Marchthaler, Kalman-Filter [1]

$$\underline{x}(k+1) = \underline{A}_d \cdot \underline{x}(k) + \underline{B}_d \cdot \underline{u}(k) + \underline{G}_d \cdot \underline{z}(k) \quad (15)$$
$$\underline{y}(k) = \underline{C} \cdot \underline{x}(k) + \underline{D} \cdot \underline{u}(k) + \underline{v}(k) \quad (16)$$

Folie 4.29



Lösung der erweiterten Zustandsgleichung

- Durch die Einführung des Systemrauschens erweitert sich die Lösung der Zustandsgleichung zu:

$$\underline{x}\big((n+1)\cdot T_s\big) = \underbrace{e^{\underline{A}\cdot T_s}\cdot \underline{x}(n\cdot T_s)}_{\underline{x}^*(nT_s)} + \underbrace{\int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot \underline{B}\cdot \underline{u}(\tau)\,d\tau}_{\underline{u}^*(nT_s)} + \underbrace{\int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot \underline{G}\cdot \underline{z}(\tau)\,d\tau}_{\underline{z}^*(nT_s)} \tag{17}$$

- Die verschiedenen Möglichkeiten zur Vereinfachung der Größe $\underline{u}^*(n\cdot T_s)$ wurde ausführlich beschrieben.
- Für das Systemrauschen gilt nach der obigen Definition:

$$\underline{z}^*(n\cdot T_s) = \int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot \underline{G}\cdot \underline{z}(\tau)\,d\tau \tag{18}$$

- Zur weiteren Vereinfachung müssen weitere Annahmen zum Verlauf des Signals $\underline{z}(t)$ im Intervall $n\cdot T_s$ und $(n+1)\cdot T_s$ vorgenommen werden, da nur der Wert zu den Abtastzeitpunkten $t = n\cdot T_s$ mit $n = 0, 1, 2, ...$ bekannt ist.

Folie 4.30

Methode 1: Direkte Diskretisierung

- Beschreibung eines abgetasteten Signals durch das Produkt aus dem zeitkontinuierlichen Signal und einer Folge von Dirac-Impulsen:

$$z_d(t) = \sum_{n=0}^{n=\infty} z(n\cdot T_s)\cdot\delta(t - n\cdot T_s)$$

- Im Intervall $n\cdot T_s \le t < (n+1)\cdot T_s$ ist das Signal folglich

$$z_d(t) = z(n\cdot T_s)\cdot\delta(t - n\cdot T_s)$$

- Nähert man $z(t)$ mit $z(t) \approx z_d(t)$ und setzt diese Näherung in Gleichung (18) ein und nutzt die Ausblendeigenschaft des Dirac-Impulses, folgt:

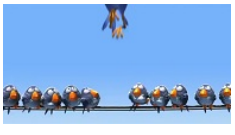
$$\begin{aligned}\underline{z}^*(n\cdot T_s) &= \int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{A}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot \underline{G}\cdot \underline{z}(\tau)\cdot\delta(\tau - n\cdot T_s)\,d\tau \\ &= e^{\underline{A}\cdot\left((n+1)\cdot T_s - nT_s\right)}\cdot \underline{G}\cdot \underline{z}(n\cdot T_s) \\ &= e^{\underline{A}\cdot T_s}\cdot \underline{G}\cdot \underline{z}(n\cdot T_s)\end{aligned} \tag{19}$$

- Mit $k = n\cdot T_s$ lässt sich die obige Gleichung schreiben, zu:

$$\underline{z}^*(k) = \underbrace{e^{\underline{A}\cdot T_s}\cdot \underline{G}}_{\underline{G}_d}\cdot \underline{z}(k) \tag{20}$$

$$\text{mit} \qquad \underline{G}_d = e^{\underline{A}\cdot T_s}\cdot \underline{G} \tag{21}$$

Folie 4.31



Methode 2: Partielles konstantes Rauschen

- Unter der *Annahme*, dass sich das *Rauschen innerhalb* eines *Abtastintervalls nicht verändert* und somit konstant ist, so lässt sich die Gleichung (18) schreiben:

$$\underline{z}^*(n\cdot T_s) = \int_{n\cdot T_s}^{(n+1)\cdot T_s} e^{\underline{\underline{A}}\cdot\left((n+1)\cdot T_s-\tau\right)}\cdot \underline{G}\, d\tau \cdot \underline{z}(n\cdot T_s) \tag{22}$$

- Substituiert man τ mit $\nu(\tau) = (n+1)\cdot T_s - \tau$ und weist der Folge den Index k zu, so folgt:

$$\underline{z}^*(k) = \underbrace{\int_0^{T_s} e^{\underline{\underline{A}}\cdot\nu}\cdot \underline{G}\, d\nu}_{\underline{G}_d}\cdot \underline{z}(k) \tag{23}$$

$$\text{mit} \qquad \underline{G}_d = \int_0^{T_s} e^{\underline{\underline{A}}\cdot\nu}\cdot \underline{G}\, d\nu \tag{24}$$

Folie 4.32

Methode 3: Diskretisiertes zeitkontinuierliches Modell I

- Das Integral der Gleichung (18) lässt sich durch die Substitution $\nu(\tau) = (n+1)\cdot T_s - \tau$ vereinfachen.
- Weist man der Folge den Index k zu, daraus folgt:

$$\underline{z}^*(k) = \int_0^{T_s} e^{\underline{\underline{A}}\cdot\nu}\cdot \underline{G}\cdot \underline{z}(\nu)\, d\nu \tag{25}$$

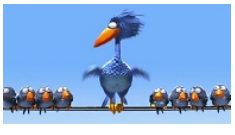
- Nimmt man an, dass es sich um *weißes*, *mittelwertfreies* Rauschen handelt, so lässt sich die Kovarianz des Systemrauschens im kontinuierlichen Zeitbereich mithilfe der Gleichung (132) schreiben:

$$\begin{aligned}\mathrm{Cov}\left(\underline{z}(t),\underline{z}(\tau)\right) &= E\left(\underline{z}(t)\cdot\underline{z}(\tau)^T\right) - \underbrace{E\left(\underline{z}(t)\right)}_{=\underline{0}}\cdot\underbrace{E\left(\underline{z}(\tau)^T\right)}_{=\underline{0}} = E\left(\underline{z}(t)\cdot\underline{z}(\tau)^T\right)\\ E\left(\underline{z}(t)\cdot\underline{z}(\tau)^T\right) &= \underline{q}\cdot\delta(t-\tau)\end{aligned} \tag{26}$$

- Weißes Rauschen besitzt innerhalb des Abstastintervalls ein *konstantes Leistungsdichtespektrum* der Höhe $\underline{q}(k)$, dessen Autokorrelationsfunktion ein Dirac-Impuls $\underline{q}(k)\cdot\delta(t-\tau)$ ist.
- Mit der Annahme, dass das zeitdiskrete Systemrauschen mittelwertfrei (Erwartungswert $E\left(\underline{z}^*(k)\right) = \underline{0}$) ist, lässt sich die Kovarianz des Systemrauschens im zeitdiskreten Bereich schreiben durch:

$$\begin{aligned}\mathrm{Cov}\left(\underline{z}^*(k),\underline{z}^*(k)\right) &= \mathrm{Var}\left(\underline{z}^*(k)\right)\\ &= E\left(\underline{z}^*(k)\cdot\underline{z}^*(k)^T\right) - \underbrace{E\left(\underline{z}^*(k)\right)}_{=\underline{0}}\cdot\underbrace{E\left(\underline{z}^*(k)^T\right)}_{=\underline{0}}\end{aligned} \tag{27}$$

Folie 4.33



Methode 3: Diskretisiertes zeitkontinuierliches Modell II

- Die Kovarianz (Varianz) des zeitdiskreten Systemrauschens lässt sich mit $\underline{z}^*(k) = \underline{G}_d \cdot \underline{z}(k)$ und $\underline{Q}(k) = \mathrm{Var}\big(\underline{z}(k)\big)$ ausdrücken.

$$\mathrm{Var}\big(\underline{z}^*(k)\big) = \mathrm{Var}\big(\underline{G}_d \cdot \underline{z}(k)\big) = \underline{G}_d \cdot \underbrace{\mathrm{Var}\big(\underline{z}(k)\big)}_{\underline{Q}(k)} \cdot \underline{G}_d^T = \underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T \tag{28}$$

- Mit Gleichung (25), (27) und (28) folgt:

$$\begin{aligned}
\underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T &= E\Big(\underline{z}^*(k) \cdot \underline{z}^*(k)^T\Big) \\
&= E\Big(\int_0^{T_s} e^{\underline{A}\cdot\nu_1} \cdot \underline{G} \cdot \underline{z}(\nu_1)\, d\nu_1 \cdot \int_0^{T_s} \Big(e^{\underline{A}\cdot\nu_2} \cdot \underline{G} \cdot \underline{z}(\nu_2)\Big)^T\, d\nu_2\Big) \\
&= E\Big(\int_0^{T_s} e^{\underline{A}\cdot\nu_1} \cdot \underline{G} \cdot \underline{z}(\nu_1)\, d\nu_1 \cdot \int_0^{T_s} \underline{z}(\nu_2)^T \cdot \underline{G}^T \cdot \big(e^{\underline{A}\cdot\nu_2}\big)^T\, d\nu_2\Big) \\
&= E\Big(\int_0^{T_s}\int_0^{T_s} e^{\underline{A}\cdot\nu_1} \cdot \underline{G} \cdot \underline{z}(\nu_1) \cdot \underline{z}(\nu_2)^T \cdot \underline{G}^T \cdot \big(e^{\underline{A}\cdot\nu_2}\big)^T\, d\nu_1\, d\nu_2\Big)
\end{aligned}$$

- Berücksichtigt man den Zusammenhang $E\big(\underline{A} \cdot \underline{x} \cdot \underline{B}\big) = \underline{A} \cdot E(\underline{x}) \cdot \underline{B}$ und die Linearität der Erwartungswerte bzw. des Integrals $E\Big(\int f(x)\, dx\Big) = \int E\big(f(x)\big)\, dx$, lässt sich der Erwartungswert in das Integral ziehen und mit Gleichung (26) folgt:

$$\underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T = \int_0^{T_s}\int_0^{T_s} e^{\underline{A}\cdot\nu_1} \cdot \underline{G} \cdot \underbrace{E\big(\underline{z}(\nu_1) \cdot \underline{z}(\nu_2)^T\big)}_{\underline{q}(k)\cdot\delta(\nu_1-\nu_2)} \cdot \underline{G}^T \cdot \big(e^{\underline{A}\cdot\nu_2}\big)^T\, d\nu_1\, d\nu_2$$

Folie 4.34

Methode 3: Diskretisiertes zeitkontinuierliches Modell III

- Nutzt man die Ausblendeigenschaft des Dirac-Impulses und die Annahme, dass $\underline{q}(k)$ innerhalb eines Abtastintervalls konstant ist, lässt sich die obige Gleichung weiter vereinfachen.

$$\underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T = \int_0^{T_s} e^{\underline{A}\cdot\nu_1} \cdot \underline{G} \cdot \underline{G}^T \cdot \big(e^{\underline{A}\cdot\nu_1}\big)^T\, d\nu_1 \cdot \underline{q}(k) \tag{29}$$

- Diese Formel gilt unter den Annahmen, dass das Rauschen *weiß*, *mittelwertfrei* ist und innerhalb des Abstastintervalls ein *konstantes Leistungsdichtespektrum* der Höhe $\underline{q}(k)$ besitzt.

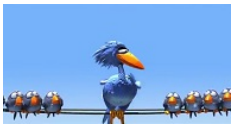
Folie 4.35

6.5 Lernziele

Lernkontrolle: Zustandsraumbeschreibung

- Sie sollten in der Lage sein ein lineares System in die *zeitdiskrete Zustandsraumbeschreibung* zu überführen.
- Sie sollten die Annahmen bei den *beiden Berechnungen* von $\underline{B}_d$ kennen.
- Sie sollten überprüfen können, ob ein System *beobachtbar* ist.
- Sie sollten die *drei Formeln* zur Berechnung von $\underline{G}_d$ kennen und deren *Annahmen* verstanden haben.

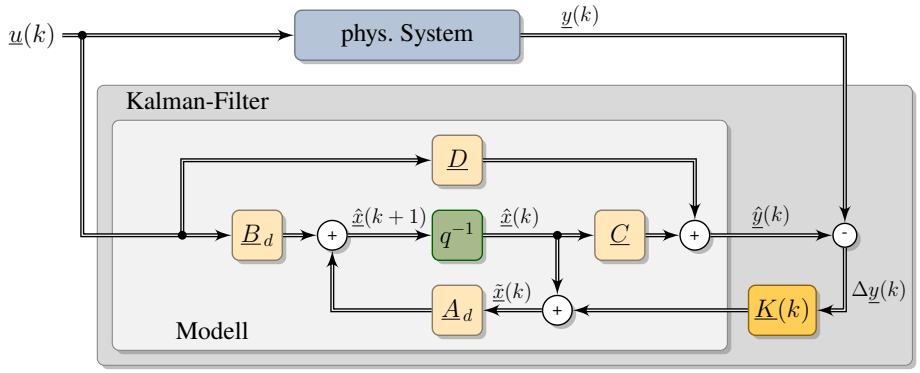
Folie 4.37



7 Klassisches Kalman-Filter

7.1 Herleitung Kalman-Filter Gleichungen

Struktur Kalman-Filter



Quelle: Marchthaler, Kalman-Filter [1]

Prädiktion:

$$\hat{\underline{x}}(k+1) = \underline{A}_d \cdot \tilde{\underline{x}}(k) + \underline{B}_d \cdot \underline{u}(k) \tag{30}$$

$$\hat{\underline{P}}(k+1) = \underline{A}_d \cdot \tilde{\underline{P}}(k) \cdot \underline{A}_d^T + \underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T \quad \text{mit} \quad \underline{Q}(k) = \mathrm{Var}\big(\underline{z}(k)\big) \tag{31}$$

Korrektur:

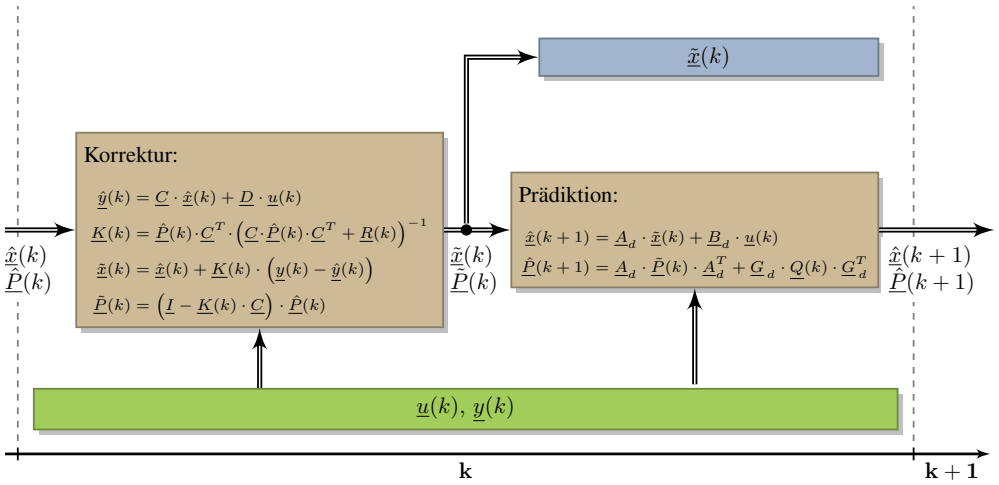
$$\underline{K}(k) = \hat{\underline{P}}(k) \cdot \underline{C}^T \cdot \Big(\underline{C} \cdot \hat{\underline{P}}(k) \cdot \underline{C}^T + \underline{R}(k)\Big)^{-1} \quad \text{mit} \quad \underline{R}(k) = \mathrm{Var}\big(\underline{v}(k)\big) \tag{32}$$

$$\tilde{\underline{x}}(k) = \hat{\underline{x}}(k) + \underline{K}(k) \cdot \Big(\underline{y}(k) - \underline{C} \cdot \hat{\underline{x}}(k) - \underline{D} \cdot \underline{u}(k)\Big) \tag{33}$$

$$\tilde{\underline{P}}(k) = \Big(\underline{I} - \underline{K}(k) \cdot \underline{C}\Big) \cdot \hat{\underline{P}}(k) \tag{34}$$

Folie 4.39

Zyklische Berechnung Kalman-Filter Gleichungen



Quelle: Marchthaler, Kalman-Filter [1]

Folie 4.40

Prädiktion I

- Aus der Struktur aus der Abbildung aus Folie IV.39 folgt:

$$\hat{\underline{x}}(k+1) = \underline{A}_d \cdot \tilde{\underline{x}}(k) + \underline{B}_d \cdot \underline{u}(k) \tag{35}$$

$$\tilde{\underline{x}}(k) = \hat{\underline{x}}(k) + \underline{K}(k) \cdot \Big(\underline{y}(k) - \underline{C} \cdot \hat{\underline{x}}(k) - \underline{D} \cdot \underline{u}(k)\Big) \tag{36}$$



- Der Schätzfehler $\underline{\hat{\varepsilon}}(k+1)$ zum Zeitpunkt $k+1$ ist definiert als die Differenz zwischen dem wahren Zustandsvektor $\underline{x}(k+1)$ und dem geschätzten Zustandsvektor $\underline{\hat{x}}(k+1)$.

$$\underline{\hat{\varepsilon}}(k+1) = \underline{x}(k+1) - \underline{\hat{x}}(k+1) \tag{37}$$

- Unter Verwendung von $\underline{x}(k+1) = \underline{A}_d \cdot \underline{x}(k) + \underline{B}_d \cdot \underline{u}(k) + \underline{G}_d \cdot \underline{z}(k)$ (15) und Gleichungen (35) folgt:

$$\begin{aligned}\underline{\hat{\varepsilon}}(k+1) &= \underline{A}_d \cdot \underline{x}(k) + \underline{B}_d \cdot \underline{u}(k) + \underline{G}_d \cdot \underline{z}(k) - \underline{A}_d \cdot \underline{\tilde{x}}(k) - \underline{B}_d \cdot \underline{u}(k) \\ &= \underline{A}_d \cdot \big(\underline{x}(k) - \underline{\tilde{x}}(k)\big) + \underline{G}_d \cdot \underline{z}(k) \\ &= \underline{A}_d \cdot \underline{\tilde{\varepsilon}}(k) + \underline{G}_d \cdot \underline{z}(k)\end{aligned} \tag{38}$$

$$\text{mit} \qquad \underline{\tilde{\varepsilon}}(k) = \underline{x}(k) - \underline{\tilde{x}}(k) \tag{39}$$

Folie 4.41

Prädiktion II

- Die Kovarianz des Schätzfehlers $\underline{\hat{\varepsilon}}(k+1)$ berechnet sich mithilfe der Gleichungen (38): $\underline{\hat{\varepsilon}}(k+1) = \underline{A}_d \cdot \underline{\tilde{\varepsilon}}(k) + \underline{G}_d \cdot \underline{z}(k)$,
folgt mit:
Gleichung (129): $\mathrm{Var}\big(\underline{X} + \underline{Y}\big) = \mathrm{Var}\big(\underline{X}\big) + \mathrm{Var}\big(\underline{Y}\big) + 2 \cdot \mathrm{Cov}\big(\underline{X}, \underline{Y}\big)$,
Gleichung (130): $\mathrm{Var}\big(\underline{A} \cdot \underline{X}\big) = \underline{A} \cdot \mathrm{Var}\big(\underline{X}\big) \cdot \underline{A}^T$,
Gleichung (132): $\mathrm{Cov}\big(\underline{X}, \underline{X}\big) = \mathrm{Var}\big(\underline{X}\big)$
und der Annahme, dass der Schätzfehler $\underline{\tilde{\varepsilon}}(k)$ und das Systemrauschen $\underline{z}(k)$ unkorreliert sind, d. h. $\mathrm{Cov}\big(\underline{\tilde{\varepsilon}}(k), \underline{z}(k)\big) = \underline{0}$, so berechnet sich dieser zu:

$$\begin{aligned}\underline{\hat{P}}(k+1) &= \mathrm{Cov}\big(\underline{\hat{\varepsilon}}(k+1), \underline{\hat{\varepsilon}}(k+1)\big) \\ &= \mathrm{Var}\big(\underline{\hat{\varepsilon}}(k+1)\big) \\ &= \mathrm{Var}\big(\underline{A}_d \cdot \underline{\tilde{\varepsilon}}(k) + \underline{G}_d \cdot \underline{z}(k)\big) \\ &= \mathrm{Var}\big(\underline{A}_d \cdot \underline{\tilde{\varepsilon}}(k)\big) + \mathrm{Var}\big(\underline{G}_d \cdot \underline{z}(k)\big) + 2 \cdot \underbrace{\mathrm{Cov}\big(\underline{A}_d \cdot \underline{\tilde{\varepsilon}}(k), \underline{G}_d \cdot \underline{z}(k)\big)}_{=\underline{0}} \\ &= \underline{A}_d \cdot \mathrm{Var}\big(\underline{\tilde{\varepsilon}}(k)\big) \cdot \underline{A}_d^T + \underline{G}_d \cdot \mathrm{Var}\big(\underline{z}(k)\big) \cdot \underline{G}_d^T\end{aligned}$$

$$\boxed{\underline{\hat{P}}(k+1) = \underline{A}_d \cdot \underline{\tilde{P}}(k) \cdot \underline{A}_d^T + \underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T \quad \text{mit} \quad \underline{Q}(k) = \mathrm{Var}\big(\underline{z}(k)\big)}$$

Folie 4.42

Korrektur I

- Der Schätzfehler $\underline{\tilde{\varepsilon}}(k) = \underline{x}(k) - \underline{\tilde{x}}(k)$ lässt sich mithilfe der Gleichung (16): $\underline{y}(k) = \underline{C} \cdot \underline{x}(k) + \underline{D} \cdot \underline{u}(k) + \underline{v}(k)$ und
Gleichung (36): $\underline{\tilde{x}}(k) = \underline{\hat{x}}(k) + \underline{K}(k) \cdot \big(\underline{y}(k) - \underline{C} \cdot \underline{\hat{x}}(k) - \underline{D} \cdot \underline{u}(k)\big)$ schreiben.

$$\begin{aligned}\underline{\tilde{\varepsilon}}(k) &= \underline{x}(k) - \underline{\tilde{x}}(k) \\ &= \underline{x}(k) - \underline{\hat{x}}(k) - \underline{K}(k) \cdot \big(\underline{y}(k) - \underline{C} \cdot \underline{\hat{x}}(k) - \underline{D} \cdot \underline{u}(k)\big) \\ &= \underline{x}(k) - \big(\underline{I} - \underline{K}(k) \cdot \underline{C}\big) \cdot \underline{\hat{x}}(k) - \underline{K}(k) \cdot \underline{y}(k) + \underline{K}(k) \cdot \underline{D} \cdot \underline{u}(k) \\ &= \underline{x}(k) - \big(\underline{I} - \underline{K}(k) \cdot \underline{C}\big) \cdot \underline{\hat{x}}(k) - \underline{K}(k) \cdot \underline{C} \cdot \underline{x}(k) - \underline{K}(k) \cdot \underline{D} \cdot \underline{u}(k) \\ &\quad - \underline{K}(k) \cdot \underline{v}(k) + \underline{K}(k) \cdot \underline{D} \cdot \underline{u}(k) \\ &= \big(\underline{I} - \underline{K}(k) \cdot \underline{C}\big) \cdot \underline{x}(k) - \big(\underline{I} - \underline{K}(k) \cdot \underline{C}\big) \underline{\hat{x}}(k) - \underline{K}(k) \cdot \underline{v}(k) \\ &= \big(\underline{I} - \underline{K}(k) \cdot \underline{C}\big) \cdot \big(\underline{x}(k) - \underline{\hat{x}}(k)\big) - \underline{K}(k) \cdot \underline{v}(k) \\ &= \big(\underline{I} - \underline{K}(k) \cdot \underline{C}\big) \cdot \underline{\hat{\varepsilon}}(k) - \underline{K}(k) \cdot \underline{v}(k)\end{aligned} \tag{40}$$

Folie 4.43



Korrektur II (Joseph Formel)

- Die Kovarianz $\underline{\tilde{P}}(k)$ des Schätzfehlers $\underline{\tilde{\varepsilon}}(k)$ lässt sich mithilfe der Gleichung (129): $\mathrm{Var}\big(\underline{X}+\underline{Y}\big) = \mathrm{Var}\big(\underline{X}\big) + \mathrm{Var}\big(\underline{Y}\big) + 2\cdot\mathrm{Cov}\big(\underline{X},\underline{Y}\big)$ darstellen.
- Unter der Annahme, dass $\underline{\hat{\varepsilon}}(k)$ und $\underline{v}(k)$ unkorreliert sind und unter Verwendung von Gleichung (130): $\mathrm{Var}\big(\underline{A}\cdot\underline{X}\big) = \underline{A}\cdot\mathrm{Var}\big(\underline{X}\big)\cdot\underline{A}^T$ folgt:

$$\begin{aligned}
\underline{\tilde{P}}(k) &= \mathrm{Cov}\big(\underline{\tilde{\varepsilon}}(k),\underline{\tilde{\varepsilon}}(k)\big) = \mathrm{Var}\big(\underline{\tilde{\varepsilon}}(k)\big)\\
&= \mathrm{Var}\Big(\big(\underline{I}-\underline{K}(k)\cdot\underline{C}\big)\cdot\underline{\hat{\varepsilon}}(k) - \underline{K}(k)\cdot\underline{v}(k)\Big)\\
&= \mathrm{Var}\Big(\big(\underline{I}-\underline{K}(k)\cdot\underline{C}\big)\cdot\underline{\hat{\varepsilon}}(k)\Big) + \mathrm{Var}\big(-\underline{K}(k)\cdot\underline{v}(k)\big) +\\
&\quad \underbrace{2\cdot\mathrm{Cov}\Big(\big(\underline{I}-\underline{K}(k)\cdot\underline{C}\big)\cdot\underline{\hat{\varepsilon}}(k),\big(-\underline{K}(k)\cdot\underline{v}(k)\big)^T\Big)}_{=\underline{0},\ \text{da } \underline{\hat{\varepsilon}}(k) \text{ und } \underline{v}(k) \text{ unkorreliert}}\\
&= \big(\underline{I}-\underline{K}(k)\cdot\underline{C}\big)\cdot\underbrace{\mathrm{Var}\big(\underline{\hat{\varepsilon}}(k)\big)}_{\underline{\hat{P}}(k)}\cdot\big(\underline{I}-\underline{K}(k)\cdot\underline{C}\big)^T + \underline{K}(k)\cdot\underbrace{\mathrm{Var}\big(\underline{v}(k)\big)}_{\underline{R}(k)}\cdot\underline{K}(k)^T
\end{aligned}$$

$$\boxed{\underline{\tilde{P}}(k) = \big(\underline{I}-\underline{K}(k)\cdot\underline{C}\big)\cdot\underline{\hat{P}}(k)\cdot\big(\underline{I}-\underline{K}(k)\cdot\underline{C}\big)^T + \underline{K}(k)\cdot\underline{R}(k)\cdot\underline{K}(k)^T} \tag{41}$$

$$\text{mit}\qquad \underline{R}(k) = \mathrm{Var}\big(\underline{v}(k)\big) \tag{42}$$

Folie 4.44

Korrektur III

- Umformung der Gleichung (41):

$$\begin{aligned}
\underline{\tilde{P}}(k) &= \big(\underline{\hat{P}}(k) - \underline{K}(k)\cdot\underline{C}\cdot\underline{\hat{P}}(k)\big)\cdot\big(\underline{I}-\underline{K}(k)\cdot\underline{C}\big)^T + \underline{K}(k)\cdot\underline{R}(k)\cdot\underline{K}(k)^T\\
&= \big(\underline{\hat{P}}(k) - \underline{K}(k)\cdot\underline{C}\cdot\underline{\hat{P}}(k)\big)\cdot\big(\underline{I}-\underline{C}^T\cdot\underline{K}(k)^T\big) + \underline{K}(k)\cdot\underline{R}(k)\cdot\underline{K}(k)^T\\
&= \underline{\hat{P}}(k) - \underline{K}(k)\cdot\underline{C}\cdot\underline{\hat{P}}(k) - \underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\underline{K}(k)^T + \underline{K}(k)\cdot\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\underline{K}(k)^T\\
&\quad + \underline{K}(k)\cdot\underline{R}(k)\cdot\underline{K}(k)^T
\end{aligned} \tag{43}$$

- Bestmögliche Schätzung für den Zustandsvektor $\underline{\tilde{x}}$ durch $\frac{\partial\mathrm{Tr}(\underline{\tilde{P}}(k))}{\partial\underline{K}} = \underline{0}$.
- Unter Verwendung der Gleichung (125): $(\underline{X}\cdot\underline{Y})^T = \underline{Y}^T\cdot\underline{X}^T$,

  Gleichung (133): $\frac{\partial\mathrm{Tr}\left(\underline{X}\cdot\underline{B}\cdot\underline{X}^T\right)}{\partial\underline{X}} = 2\cdot\underline{X}\cdot\underline{B}$,

  Gleichung (134): $\frac{\partial\mathrm{Tr}\left(\underline{X}\cdot\underline{A}\right)}{\partial\underline{X}} = \underline{A}^T$,

  Gleichung (135) $\frac{\partial\mathrm{Tr}\left(\underline{A}\cdot\underline{X}^T\right)}{\partial\underline{X}} = \underline{A}$

  und unter Berücksichtigung $\underline{\hat{P}}(k) = \underline{\hat{P}}(k)^T$ folgt:

$$\begin{aligned}
\frac{\partial\mathrm{Tr}(\underline{\tilde{P}}(k))}{\partial\underline{K}} &= -\underline{\hat{P}}(k)^T\cdot\underline{C}^T - \underline{\hat{P}}(k)\cdot\underline{C}^T + 2\cdot\underline{K}(k)\cdot\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + 2\cdot\underline{K}(k)\cdot\underline{R}(k)\\
\underline{0} &= -2\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + 2\cdot\underline{K}(k)\cdot\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + 2\cdot\underline{K}(k)\cdot\underline{R}(k)\\
\underline{\hat{P}}(k)\cdot\underline{C}^T &= \underline{K}(k)\cdot\big(\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + \underline{R}(k)\big)
\end{aligned} \tag{44}$$

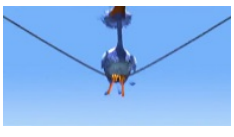
$$\boxed{\underline{K}(k) = \underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\big(\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + \underline{R}(k)\big)^{-1}} \tag{45}$$

Folie 4.45

Korrektur IV

- Für ein Minimum muss d. zweite Ableitung $\frac{\partial^2\mathrm{Tr}(\underline{\tilde{P}}(k))}{\partial^2\underline{K}}$ positiv definit sein.

$$\frac{\partial^2\mathrm{Tr}(\underline{\tilde{P}}(k))}{\partial^2\underline{K}} = 2\cdot\big(\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + \underline{R}(k)\big)^T \tag{46}$$



- Diese Bedingung gilt immer, da die Kovarianzmatrizen $\underline{\hat{P}}$ und $\underline{R}$ quadratisch, symmetrisch, diagonal dominant und somit positiv definit sind. Folglich ist auch der Ausdruck $\underline{C} \cdot \underline{\hat{P}}(k) \cdot \underline{C}^T + \underline{R}(k)$ positiv definit.
- Durch Umstellen der Gleichung (43) lässt sich diese, unter Verwendung der Gleichung (44), weiter vereinfachen.

$$\begin{aligned}\underline{\tilde{P}}(k) =& \underline{\hat{P}}(k) - \underline{K}(k)\cdot\underline{C}\cdot\underline{\hat{P}}(k) - \underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\underline{K}(k)^T + \underline{K}(k)\cdot\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\underline{K}(k)^T \\ &+ \underline{K}(k)\cdot\underline{R}(k)\cdot\underline{K}(k)^T \\ =& \big(\underline{I} - \underline{K}(k)\cdot\underline{C}\big)\cdot\underline{\hat{P}}(k) - \underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\underline{K}(k)^T + \underbrace{\underline{K}(k)\cdot\big(\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + \underline{R}(k)\big)}_{=\underline{\hat{P}}(k)\cdot\underline{C}^T}\cdot\underline{K}(k)^T \\ =& \big(\underline{I} - \underline{K}(k)\cdot\underline{C}\big)\cdot\underline{\hat{P}}(k) - \underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\underline{K}(k)^T + \underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\underline{K}(k)^T\end{aligned}$$

$$\underline{\tilde{P}}(k) = \big(\underline{I} - \underline{K}(k)\cdot\underline{C}\big)\cdot\underline{\hat{P}}(k) \tag{47}$$

Folie 4.46

Fragen zu Kalman-Filter-Gleichungen:

- Es wurden zwei Formeln zur Berechnung d. Kovarianz d. Schätzfehlers $\underline{\tilde{P}}(k)$ hergeleitet.
  Gleichung (41): $\underline{\tilde{P}}(k) = \big(\underline{I} - \underline{K}(k)\cdot\underline{C}\big)\cdot\underline{\hat{P}}(k)\cdot\big(\underline{I} - \underline{K}(k)\cdot\underline{C}\big)^T + \underline{K}(k)\cdot\underline{R}(k)\cdot\underline{K}(k)^T$
  Gleichung (47): $\underline{\tilde{P}}(k) = \big(\underline{I} - \underline{K}(k)\cdot\underline{C}\big)\cdot\underline{\hat{P}}(k)$
  In welchem Fall würden Sie die eine und wann die andere Formel benutzen?
- Gelten die Kalman-Filter Gleichungen auch bei nicht normalverteilten Rauschen?

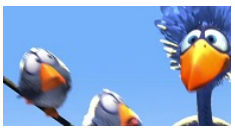
Lösung:

Folie 4.47

Lernkontrolle: Zustandsraumbeschreibung

- Sie sollten die *Struktur* eines Kalman-Filter *zeichnen* und *erklären* können.
- Sie sollten in der Lage sein d. Gleichungen eines *klassischen Kalman-Filters herzuleiten*.
- Sie sollten die *Annahmen* kennen unter denen die *Kalman-Filter-Gleichungen gelten*.

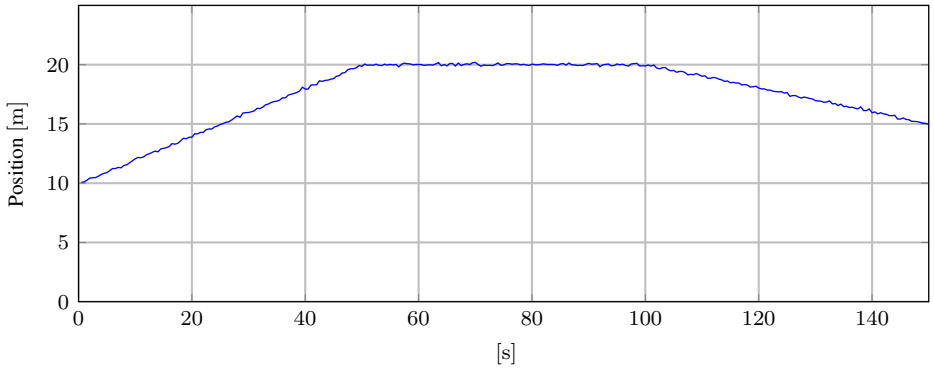
Folie 4.48



7.2 Beispielentwurf eines Kalman-Filters (Beta-Filter)

Problemstellung

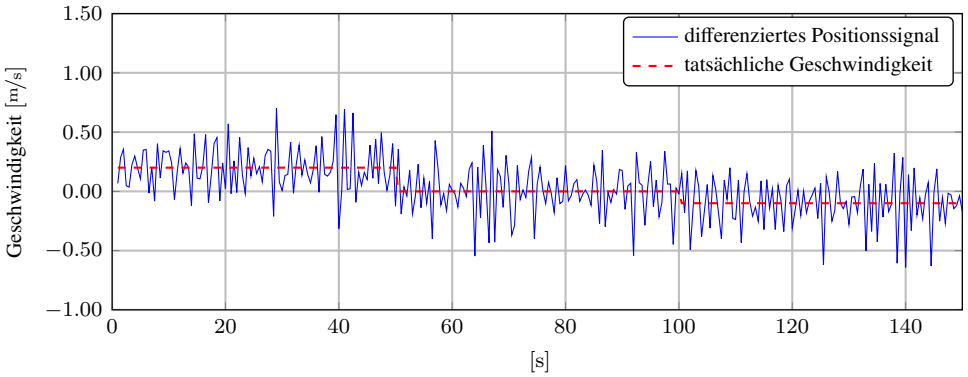
- Für ein Fahrzeug soll die zurückgelegte *Strecke* und die *Geschwindigkeit* abgeschätzt werden.
- Es kann lediglich durch einen ungenauen Videosensor alle *0.5s* die *Position* des Fahrzeugs erfasst werden.
- Die *Geschwindigkeit* kann *messtechnisch nicht erfasst* werden.



Folie 4.50

Bestimmung der Geschwindigkeit durch Differenzierung des Positionssignals

- Eine Bestimmung der Geschwindigkeit durch *Differenzierung* der gemessenen Strecke führt zu unakzeptablen Ergebnisse



Folie 4.51

Systembeschreibung

- Wird die komplette Masse des Fahrzeugs in einem *Massepunkt* vereint, so lässt sich das dynamische Verhalten dieses Massepunkts modellieren durch:

$$v(t) = \dot{s}(t) \tag{48}$$

- *Wählt* man den *Zustandsvektor* $\underline{x}(t)$ zu:

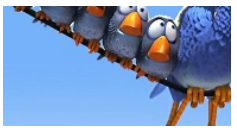
$$\underline{x}(t) = \begin{bmatrix} s(t) \\ v(t) \end{bmatrix} \tag{49}$$

- Ergibt die *Ableitung der Zustandsvariablen* $\dot{\underline{x}}(t)$:

$$\dot{\underline{x}}(t) = \begin{bmatrix} \dot{s}(t) \\ \dot{v}(t) \end{bmatrix} = \begin{bmatrix} v(t) \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} \cdot z(t) \tag{50}$$

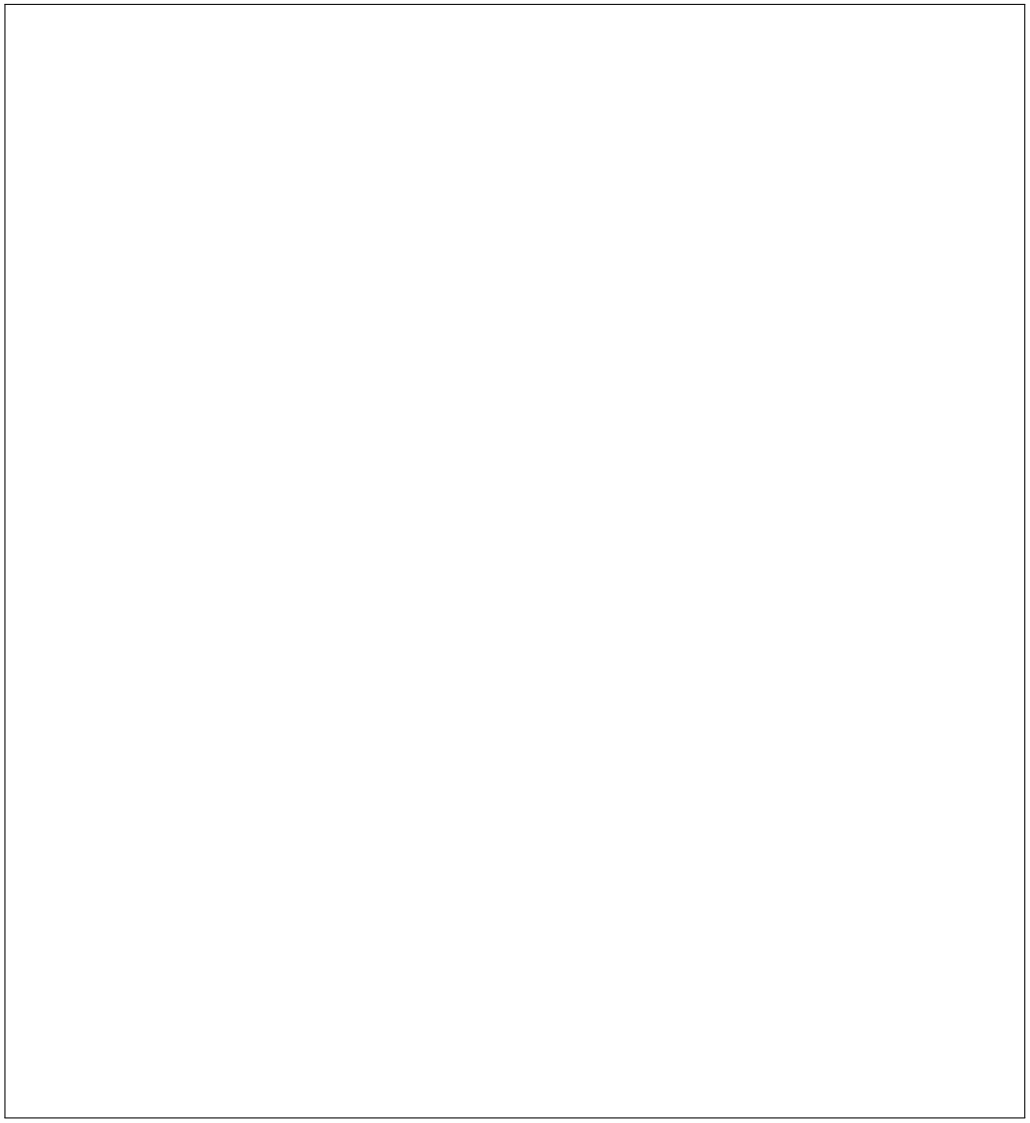
- Mögliche *Änderungen der Geschwindigkeit* werden durch die *Zufallsvariable* $z(t)$ berücksichtigt

Folie 4.52



Zeitkontinuierliche Systembeschreibung

Wie lautet die zeitkontinuierliche Zustandsraumbeschreibung eines solchen Modells?



Folie 4.53

Zeitdiskrete Systembeschreibung I

- Ein lineares zeitdiskretes System wird allgemein im Zustandsraum beschrieben durch:

$$\underline{A}_d = e^{\underline{A} \cdot T_s}, \qquad \underline{B}_d = \int_0^{T_s} e^{\underline{A} \cdot \nu} \cdot \underline{B} \, d\nu, \qquad \underline{G}_d = \underline{A}_d \cdot \underline{G}$$

- Dies lässt sich mit einer Reihenentwicklung der e-Funktion annähern:

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!} \qquad \text{für } n = 0 \text{ gilt: } \frac{x^0}{0!} = 1$$

- Es gilt für Matrizen:

$$e^{\underline{A} \cdot T_s} = \sum_{n=0}^{\infty} \frac{1}{n!} \cdot \underline{A}^n \cdot T_s^n \qquad \text{für } n = 0 \text{ gilt: } \frac{1}{0!} \cdot \underline{A}^0 \cdot T_s^0 = \underline{I}$$

Folie 4.54

Zeitdiskrete Systembeschreibung II

Bestimmen Sie die Matrizen $\underline{A}_d$, $\underline{B}_d$ und $\underline{G}_d$



Folie 4.55

Zeitdiskrete Systembeschreibung III

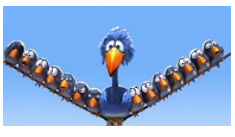
- Alternativ lässt sich die e-Funktion mit der Laplace-Transformation berechnen. Siehe auch Anhang C, Kalman-Filter [1]
- Allgemein gilt:

$$\mathcal{L}\left\{e^{a\cdot t}\right\} = \frac{1}{s-a} \qquad e^{\underline{A}\cdot t} = \mathcal{L}^{-1}\left\{(s\cdot \underline{I} - \underline{A})^{-1}\right\}$$

- Somit gilt mit:

$$e^{\underline{A}\cdot T_s} = \mathcal{L}^{-1}\left\{(s\cdot \underline{I} - \underline{A})^{-1}\right\} = \mathcal{L}^{-1}\left\{\left(\begin{bmatrix} s & -1 \\ 0 & s \end{bmatrix}\right)^{-1}\right\}$$

- Invertierung der Matrix mit dem Gaußschen Eliminationsverfahren:



s	-1	1	0	$\cdot s$
0	s	0	1	
s^2	0	s	1	$\cdot \frac{1}{s^2}$
0	s	0	1	$\cdot \frac{1}{s}$
1	0	$\frac{1}{s}$	$\frac{1}{s^2}$	
0	1	0	$\frac{1}{s}$	

Folie 4.56

Zeitdiskrete Systembeschreibung IV

Orignalfunktion $f(t) = \mathcal{L}^{-1}\{F(s)\}$	Bildfunktion $F(s) = \mathcal{L}\{f(t)\}$
1	$\frac{1}{s}$
$\frac{t^n}{n!}$	$\frac{1}{s^{n+1}}$

Tabelle 1: Umrechnung Laplace-Transformation

- Somit folgt mithilfe der Laplace-Transformierten:

$$e^{\underline{A} \cdot T_s} = \mathcal{L}^{-1}\left\{(s \cdot \underline{I} - \underline{A})^{-1}\right\} = \mathcal{L}^{-1}\left\{\begin{bmatrix} \frac{1}{s} & \frac{1}{s^2} \\ 0 & \frac{1}{s} \end{bmatrix}\right\} = \begin{bmatrix} 1 & T_s \\ 0 & 1 \end{bmatrix}$$

Folie 4.57

Zeitdiskrete Systembeschreibung V

- Mithilfe von Matlab lassen sich auch die Matrizen berechnen:

```
syms Ts 'real';

A = [0 1; 0 0];
B = [0; 0];
G = [0; 1];

Ad = simplify(expm(Ts*A))
Bd = simplify(int(expm(Ts*A)*B))
Gd = Ad*G
```

Folie 4.58

Zeitdiskrete Systembeschreibung VI

- Für die zeitdiskrete Systembeschreibung gilt:

$$\underline{x}(k+1) = \begin{bmatrix} s(k+1) \\ v(k+1) \end{bmatrix} = \begin{bmatrix} 1 & T_s \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} s(k) \\ v(k) \end{bmatrix} + \begin{bmatrix} T_s \\ 1 \end{bmatrix} \cdot z(k)$$

$$y(k) = s(k) = \begin{bmatrix} 1 & 0 \end{bmatrix} \cdot \begin{bmatrix} s(k) \\ v(k) \end{bmatrix}$$

- Ausgeschrieben gilt somit:

$$v(k+1) = v(k) + z(k)$$
$$s(k+1) = s(k) + T_s \cdot (v(k) + z(k))$$

Folie 4.59

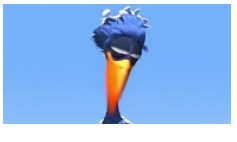


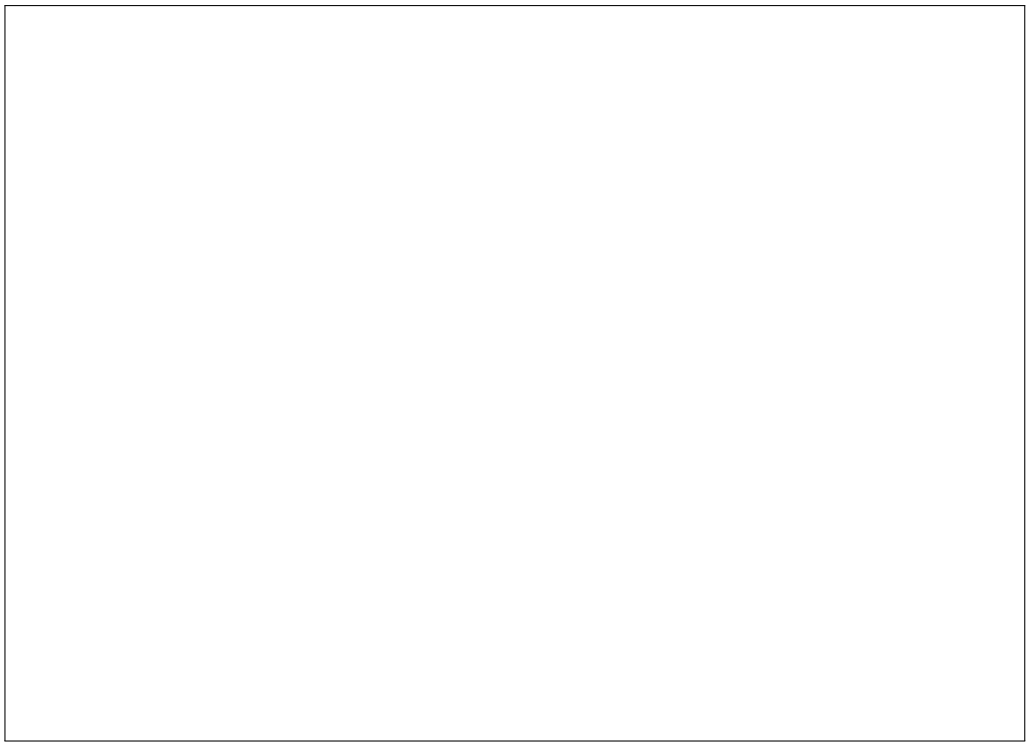
Beobachtbarkeit

Überprüfen Sie, ob das Modell beobachtbar ist.

Messrauschen $\underline{R}$

- Bestimmen Sie die Kovarianz des Messrauschens $\underline{R}$.
- Die Varianz des Messrauchens des Videosensors lässt sich z.B. in dem Intervall in dem das Objekt sich nicht bewegt gut abschätzen.
- Es wurden folgende Größen ermittelt: 19.8689, 20.0476, 19.9527, 19.9717, 19.9525, 20.0407, 19.9450, 19.9248, 20.0391, 19.9701, 20.0256

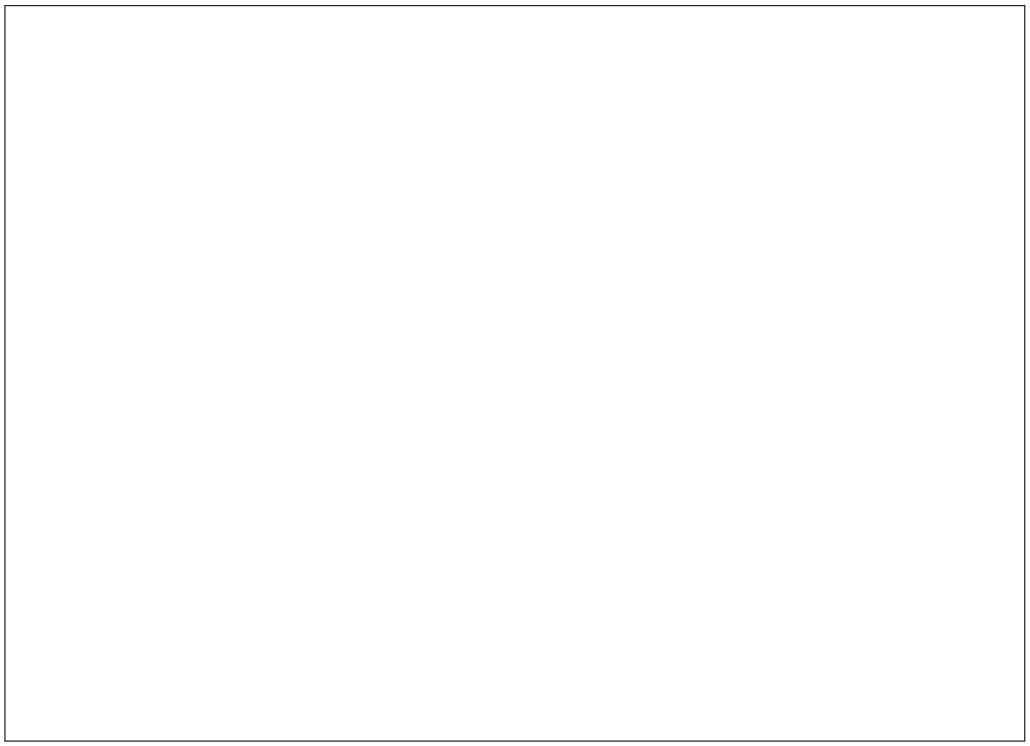




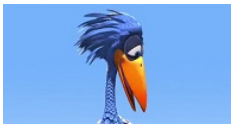
Folie 4.61

Systemrauschen Q

Überlegen Sie wie man die Größe des Systemrauschens Q für die Methode 1 bestimmen (abschätzen) könnte.



Folie 4.62



Kalman-Filtergleichungen

Mit $\underline{B} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ und $D = 0$ folgt:

Korrektur:

$$\hat{y}(k) = \underline{C} \cdot \hat{\underline{x}}(k) \tag{51}$$

$$\Delta y(k) = y(k) - \hat{y}(k) \tag{52}$$

$$\underline{K}(k) = \hat{\underline{P}}(k) \cdot \underline{C}^T \cdot \left(\underline{C} \cdot \hat{\underline{P}}(k) \cdot \underline{C}^T + R\right)^{-1} \tag{53}$$

$$\tilde{\underline{x}}(k) = \hat{\underline{x}}(k) + \underline{K}(k) \cdot \Delta \underline{y}(k) \tag{54}$$

$$\tilde{\underline{P}}(k) = \left(\underline{I} - \underline{K}(k) \cdot \underline{C}\right) \cdot \hat{\underline{P}}(k) \tag{55}$$

Prädiktion:

$$\hat{\underline{x}}(k+1) = \underline{A}_d \cdot \tilde{\underline{x}}(k) \tag{56}$$

$$\hat{\underline{P}}(k+1) = \underline{A}_d \cdot \tilde{\underline{P}}(k) \cdot \underline{A}_d^T + \underline{G}_d \cdot Q \cdot \underline{G}_d^T \tag{57}$$

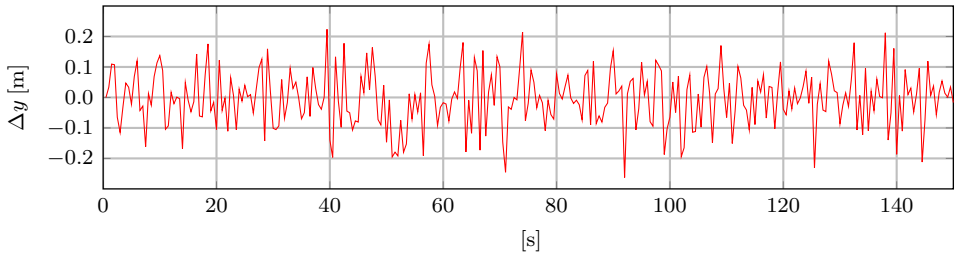
Folie 4.63

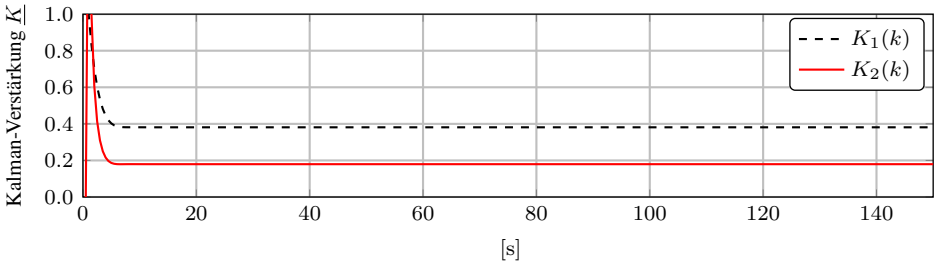
Auszug aus den Berechnungsergebnissen

k = 57		
$\hat{x}_1(k)$ = 15.7108m	$\sqrt{\hat{P}_{1,1}}(k)$ = 0.0444m	$r_{\hat{P}_{1,1}\ \hat{P}_{2,2}}(k)$ = 0.7860
$\hat{x}_2(k)$ = 0.2304m/s	$\sqrt{\hat{P}_{2,2}}(k)$ = 0.0266m/s	
$\hat{y}(k)$ = 15.7108m	$\sqrt{\hat{P}_{1,1}}(k)$ = 0.0444m	
$y(k)$ = 15.5679m	$\sqrt{R}$ = 0.0566m	
$\Delta y(k)$ = -0.1429m	K_1 = 0.3812	K_2 = 0.1795
$\tilde{x}_1(k)$ = 15.6563m	$\sqrt{\tilde{P}_{1,1}}(k)$ = 0.0349m	$r_{\tilde{P}_{1,1}\ \tilde{P}_{2,2}}(k)$ = 0.7071
$\tilde{x}_2(k)$ = 0.2048m/s	$\sqrt{\tilde{P}_{2,2}}(k)$ = 0.0233m/s	
k = 58		
$\hat{x}_1(k)$ = 15.7587m	$\sqrt{\hat{P}_{1,1}}(k)$ = 0.0444m	$r_{\hat{P}_{1,1}\ \hat{P}_{2,2}}(k)$ = 0.7860
$\hat{x}_2(k)$ = 0.2048m/s	$\sqrt{\hat{P}_{2,2}}(k)$ = 0.0266m/s	
...	...	

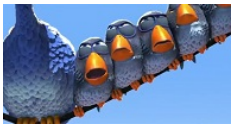
Folie 4.64

Residuum Δy und Kalman-Verstärkung $\underline{K}$

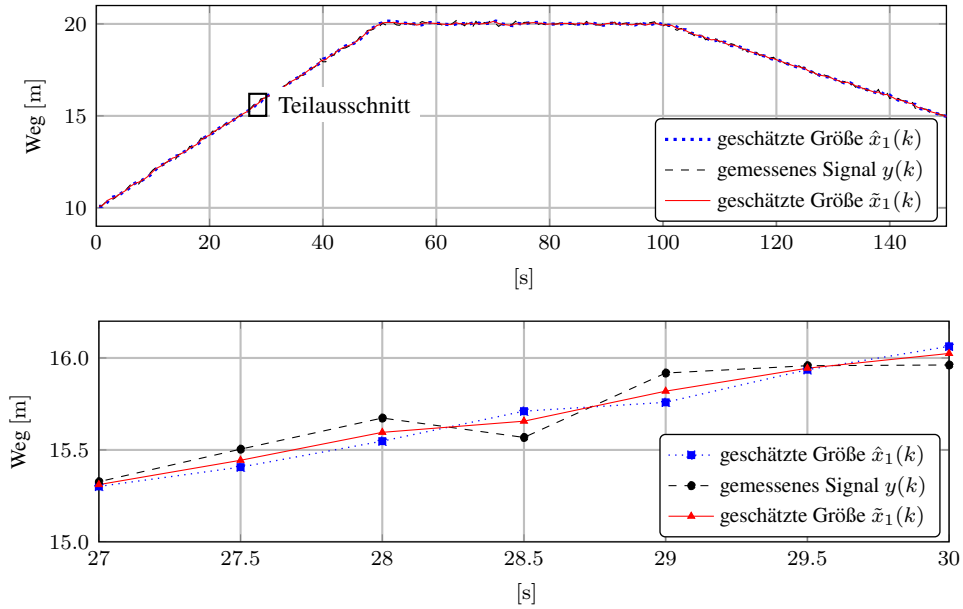




Folie 4.65

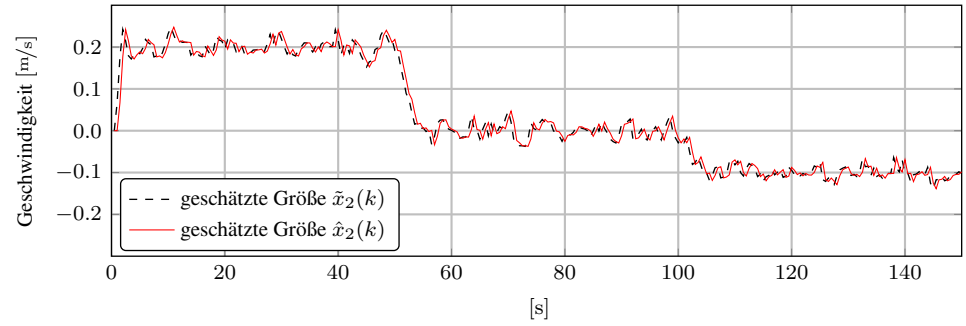


Geschätzte Zustandsgröße Weg $\tilde{x}_1$, $\hat{x}_1$ und Wegmessung y



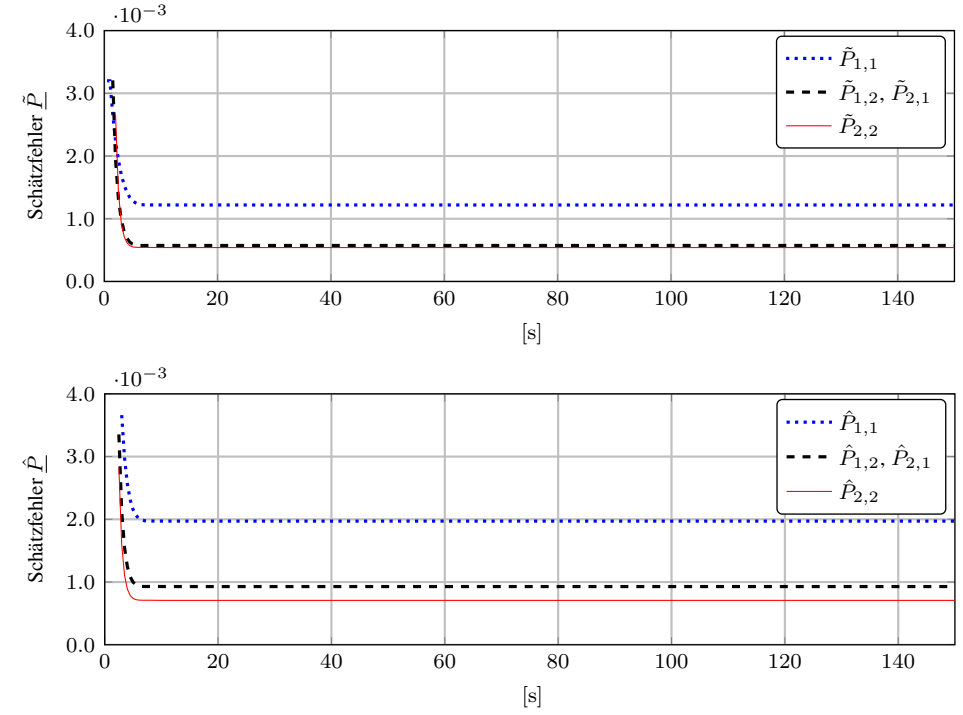
Folie 4.66

Geschätzte Zustandsgröße Geschwindigkeit $\tilde{x}_2$ und $\hat{x}_2$

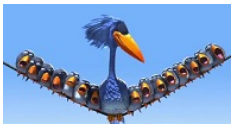


Folie 4.67

Kovarianz des Schätzfehler $\underline{\tilde{P}}$ und $\underline{\hat{P}}$



Folie 4.68



Matlab-Code

```
clearvars;
load -ascii data_in_t_y_s_v_a.dat;
y=data_in_t_y_s_v_a(:,2); u=zeros(1,length(y));

R  = 0.0032;
Q  = 0.00016667;
Ts = 0.5;
Ad = [1  Ts; 0  1];
Bd = [0; 0];
C  = [1  0];
D  = [0];
G  = [Ts; 1];

%%% Init %%%
x_dach = [y(1); 0];
P_dach = 30*[1 0; 0 1];

%%% Kalman %%%
for k=1:length(y)
  y_dach(k) = C*x_dach + D*u(k);
  d_y(k) = y(k) - y_dach(k);
  K = P_dach*C'*pinv(C*P_dach*C' + R);
  x_tilde = x_dach + K*d_y(:,k);
  P_tilde = (eye(length(Bd)) - K*C)*P_dach;

  x_dach = Ad*x_tilde + Bd*u(k);
  P_dach = Ad*P_tilde*Ad' + G*Q*G';

  s(k)=x_tilde(1); v(k)=x_tilde(2);
end
```

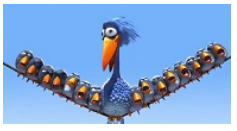
Folie 4.69

Fragen

1. Welche Dimensionen haben die Matrizen $\underline{K}$, $\underline{\tilde{P}}$ und $\underline{\hat{P}}$
2. Was beschreibt die Größe $\underline{\hat{P}}$
3. Was ist der Unterschied zwischen den Größen $\underline{\hat{P}}$ und $\underline{\tilde{P}}$?
4. Welche der beiden Größen $\underline{\hat{P}}$ und $\underline{\tilde{P}}$ hat in der Regel größere Werte?
   In welchen Fällen ist es nicht der Fall?
5. Was ist der Unterschied zwischen den Größen $\Delta\underline{y}$ und $\underline{P}$?

Lösung:

Folie 4.70



Lernkontrolle

- Sie sollten das *verwendete kinematische Modell*, welchem dem Kalman-Filter zugrunde liegt verinnerlicht haben.
- Sie sollten abwägen können, welche der *verschiedenen Formeln* zur Berechnung des *Systemrauschens* passend ist. (Siehe Kap. 7.5 in Kalman-Filter - Einführung in die Zustandsschätzung und ihre Anwendung für eingebettete Systeme [1])
- Sie sollten in der Lage sein die *Kovarianz des Messrauchens* und die *Kovarianz des Systemrauschens* zu bestimmen.

Folie 4.71

7.3 Kochrezept

Übersicht

I. Zeitkontinuierliche Systembeschreibung
II. Zeitdiskrete Systembeschreibung
III. Überprüfung der Beobachtbarkeit
IV. Bestimmung des System- und Messrauschens

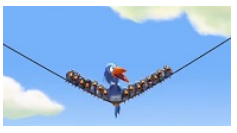
Folie 4.73

I. Zeitkontinuierliche Systembeschreibung

- Modellierung eines *physikalischen Systems* in Form von *Differentialgleichungen*
- Alle messtechnisch *erfassbaren rauschbehafteten* Größen werden durch den *Ausgangsvektor* $\underline{y}(t)$ festgelegt.
- *Nicht rauschbehaftete Größen* werden dem *Eingangsvektor* $\underline{u}(t)$ zugewiesen.
- *Wahl* der *Zustandsvariable* $\underline{x}(t)$
- Hierdurch ergeben sich die *Systemmatrix* $\underline{A}$, die *Eingangsmatrix* $\underline{B}$, die Ausgangsmatrix $\underline{C}$, die *Durchgangsmatrix* $\underline{D}$ und die Matrix $\underline{G}$ des *Systemrauschens*.
- Es gilt somit ein System beschrieben durch die *Zustandsdifferentialgleichung* und der *Ausgangsgleichung*:

$$\dot{\underline{x}}(t) = \underline{A} \cdot \underline{x}(t) + \underline{B} \cdot \underline{u}(t) + \underline{G} \cdot \underline{z}(t)$$
$$\underline{y}(t) = \underline{C} \cdot \underline{x}(t) + \underline{D} \cdot \underline{u}(t)$$

Folie 4.74



II. Zeitdiskrete Systembeschreibung

- Bei Abtastung des kontinuierlichen Signals alle T_s gilt:

$$\underline{A}_d = e^{\underline{A}\cdot T_s}, \qquad \underline{B}_d = \int_0^{T_s} e^{\underline{A}\cdot\nu}\cdot\underline{B}\,d\nu \quad \text{bzw.} \quad \underline{B}_d = \underline{A}_d\cdot\underline{B}$$

- Die Matrizen $\underline{C}$ und $\underline{D}$ bleiben im Zeitdiskreten unverändert.
- Berechnung der Matrix $\underline{G}_d$:

Methode	Modellannahme im Abtastintervall $\mathbf{n\cdot T_s \le t < (n+1)\cdot T_s}$	Berechnung
1	Abtastung durch Dirac-Impuls $z_d(t) = z(n\cdot T_s)\cdot\delta(t - n\cdot T_s)$	$\underline{G}_d = e^{\underline{A}\cdot T_s}\cdot\underline{G}$
2	Systemrauschen innerhalb Abtastintervalls konstant	$\underline{G}_d = \int_0^{T_s} e^{\underline{A}\cdot\nu}\cdot\underline{G}\,d\nu$
3	weißes, mittelwertfreies Systemrauschen, dessen Autokorrelationsfunktion ein Dirac-Impuls mit $\underline{q}(k)\cdot\delta(t-\tau)$ ist	$\underline{G}_d\cdot\underline{Q}(k)\cdot\underline{G}_d^T = \int_0^{T_s} e^{\underline{A}\cdot\nu_1}\cdot\underline{G}\cdot\underline{G}^T\cdot\left(e^{\underline{A}\cdot\nu_1}\right)^T d\nu_1\cdot\underline{q}(k)$

Quelle: Marchthaler, Kalman-Filter [1]

Folie 4.75

III. Überprüfung der Beobachtbarkeit

- Nach R. E. Kalman ist ein lineares zeitinvariantes System der Ordnung n dann beobachtbar, wenn die *Beobachtbarkeitsmatrix* S_B bzw. S_B^* den *Rang n* besitzt.
- *Nicht jedes System* ist im Zeitkontinuierlichen und im Zeitdiskreten *beobachtbar*.
- Es ist deshalb sinnvoll, die Überprüfung der Beobachtbarkeit mit der *Beobachtbarkeitsmatrix* S_B^* durchzuführen.

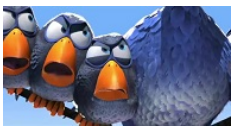
$$\text{Rang}\left(\underline{S}_B^*\right) = \text{Rang}\left(\begin{bmatrix}\underline{C}\\ \vdots \\ \underline{C}\cdot\underline{A}_d^{n-1}\end{bmatrix}\right)$$

Folie 4.76

IV. Bestimmung des System- und Messrauschens

- *Modellungenauigkeiten* werden durch das *Systemrauschen* beschrieben. Charakterisierung findet durch dessen Kovarianz $\underline{Q}(k) = \text{Var}\left(\underline{z}(k)\right)$ statt.
- *Abschätzung* der *Kovarianz des Systemrauschens* $\underline{Q}(k)$.
- Überlegung, ob die Kovarianz des Systemrauschens $\underline{Q}(k)$ und die Kovarianz des Messrauschens $\underline{R}(k)$ sich stark ändern. Bei *starker zeitlicher Invarianz*, sollte auf ein adaptives Kalman-Filter, wie z.B. das *ROSE-Filter* zurück gegriffen werden.
- Bei *zeitinvarianter* Varianz des Messrauschens $\underline{R}(k) = \text{Var}\left(\underline{v}(k)\right)$ lässt sich diese über eine *vorige Messung bestimmen*.
- Bei *zeitinvarianter* Varianz des *Messrauschens* und zeitinvarianter Varianz des *Systemrauschens* lässt sich die *Kalman-Verstärkung* $\underline{K}$ und der *Kovarianzmatrix* $\hat{\underline{P}}$ bzw. $\tilde{\underline{P}}$ *vorab bestimmen*. Dies *reduziert* im erheblichen Maße die *Rechenzeit* des Kalman-Filters in Echtzeit.
- Beim *Messrauschen* liegt die Annahme zugrunde, dass der *Erwartungswert des Messrauschens* $E\left(\underline{v}(k)\right) = \underline{0}$ ist. Ist dies nicht der Fall kann bei einem Messrauschen mit einem Erwartungswert $\text{E}\left(\underline{v}(k)\right) \neq \underline{0}$, das Messrauschen in einen *mittelwertfreien* Teil und in einen *unbekannten Offset* aufgeteilt werden. Die *Zustandsvariable* $\underline{x}(k)$ wird dann um den *Offset* des Messrauschens *erweitert*.

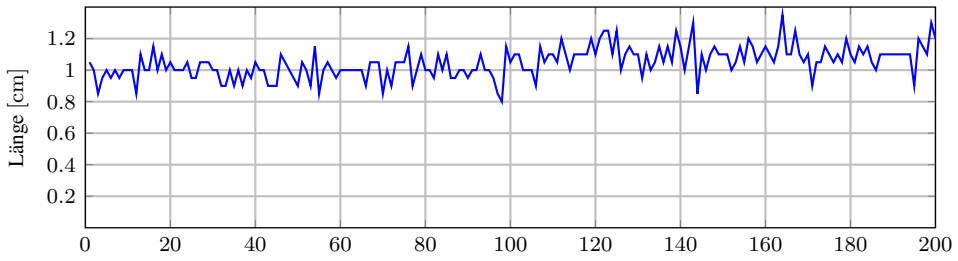
Folie 4.77



7.4 Beispielentwurf eines einfachen Kalman-Filters (Alpha-Filter)

Problemstellung

- In einer Fertigung sollen aus einer Stange genau gleich lange Stifte abgesägt werden.
- Die Sägeeinrichtung verändert sich über der Zeit langsam und muss somit laufend nachgeführt werden.
- Zur Bestimmung der Stiftlänge wird ein Videosensor eingesetzt, welcher leider die Genauigkeitsanforderungen nicht erfüllt.
- Aufgrund dessen wird die Länge jedes Stifts 100x vermessen und soll mittels Datenfusion die Genauigkeitsanforderungen erfüllen.
- Eine einfache Mittelwertbildung ist nicht möglich, da der Videosensor nicht erkennen kann, ob es sich um den selben Stift handelt.



Folie 4.79

Zeitkontinuierliche Systembeschreibung

- Da sich die unbekannte Länge nur sehr langsam ändert, lässt sich ein einfaches Modell des physikalischen Systems entwerfen.
- Die unbekannte Konstante (Länge) wird der Zustandsvariablen $x(t)$ zugeordnet

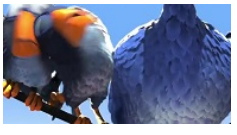
$$x(t) = \text{const.}$$

- Die Ableitung der Zustandsvariablen $\dot{x}(t)$ ist null.
- Mögliche kleinere Änderungen (Systemungenauigkeiten) werden durch die Zufallsvariable $z(t)$ berücksichtigt

$$\dot{x}(t) = 0 + z(t)$$

- Wie lautet die zeitkontinuierliche Zustandsraumbeschreibung eines solchen Modells?

Folie 4.80



Zeitdiskrete Systembeschreibung

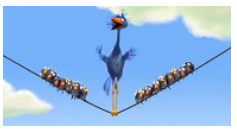
Bestimmen Sie die zeitdiskrete Zustandsraumbeschreibung unter der Annahme, dass das Signal alle T_s Sekunden abgetastet wird

Folie 4.81

Beobachtbarkeit

Überprüfen Sie, ob das Modell beobachtbar ist.

Folie 4.82



Messrauschen R

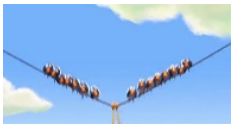
- Zur Bestimmung des Messrauchens wurde eine Stichprobe von 20 Längenmessungen erstellt. 1.05, 1.00, 0.85, 0.95, 1.00, 0.95, 1.00, 0.95, 1.00, 1.00, 1.00, 0.85, 1.1, 1.0, 1.00, 1.15, 1.00, 1.10, 1.00, 1.05
- Bestimmen Sie die Kovarianz des Messrauschens R.
- Wie kann sicher gestellt werden, dass bei der Stichprobe alle Messungen von einen Stift stammen?

Folie 4.83

Systemrauschen Q

Überlegen Sie wie man die Größe des Systemrauschens Q für die Methode 1 bestimmen (abschätzen) könnte.

Folie 4.84



Kalman-Filter Gleichungen

Mit den Größen $A_d = 1$, $B_d = 0$, $C = 1$, $D = 0$ und $G_d = 1$ und der Annahme, dass sich die Varianz des Systemrauschens Q und die Varianz des Messrauschens R nicht über die Zeit verändert, folgt:

$$\begin{aligned}
\underline{K}(k) &= \underline{\hat{P}}(k) \cdot \underline{C}^T \cdot \left(\underline{C} \cdot \underline{\hat{P}}(k) \cdot \underline{C}^T + \underline{R}(k)\right)^{-1} \\
&= \hat{P}(k) \cdot \left(\hat{P}(k) + R\right)^{-1} && (58) \\
\underline{\tilde{x}}(k) &= \underline{\hat{x}}(k) + \underline{K}(k) \cdot \left(\underline{y}(k) - \underline{C} \cdot \underline{\hat{x}}(k) - \underline{D} \cdot \underline{u}(k)\right) \\
&= \hat{x}(k) + K(k) \cdot \left(y(k) - \hat{x}(k)\right) && (59) \\
\underline{\tilde{P}}(k) &= \left(\underline{I} - \underline{K}(k) \cdot \underline{C}\right) \cdot \underline{\hat{P}}(k) = \left(1 - K(k)\right) \cdot \hat{P}(k) && (60) \\
\underline{\hat{x}}(k+1) &= \underline{A}_d \cdot \underline{\tilde{x}}(k) + \underline{B}_d \cdot \underline{u}(k) = \tilde{x}(k) && (61) \\
\underline{\hat{P}}(k+1) &= \underline{A}_d \cdot \underline{\tilde{P}}(k) \cdot \underline{A}_d^T + \underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T = \tilde{P}(k) + Q && (62)
\end{aligned}$$

Setzt man Gleichung (59) in Gleichung (61) und Gleichung (60) in Gleichung (62) ein, reduziert sich die Berechnung auf drei Gleichungen:

$$\begin{aligned}
K(k) &= \hat{P}(k) \cdot \left(\hat{P}(k) + R\right)^{-1} && (63) \\
\hat{x}(k+1) &= \hat{x}(k) + K(k) \cdot \left(y(k) - \hat{x}(k)\right) && (64) \\
\hat{P}(k+1) &= \left(1 - K(k)\right) \cdot \hat{P}(k) + Q && (65)
\end{aligned}$$

Mit dem Startwert: $\hat{x}(1) = y(1)$ und $\hat{P}(1) = 100 \cdot G_d \cdot Q \cdot G_d = 100 \cdot Q$

Folie 4.85

Matlab-Code

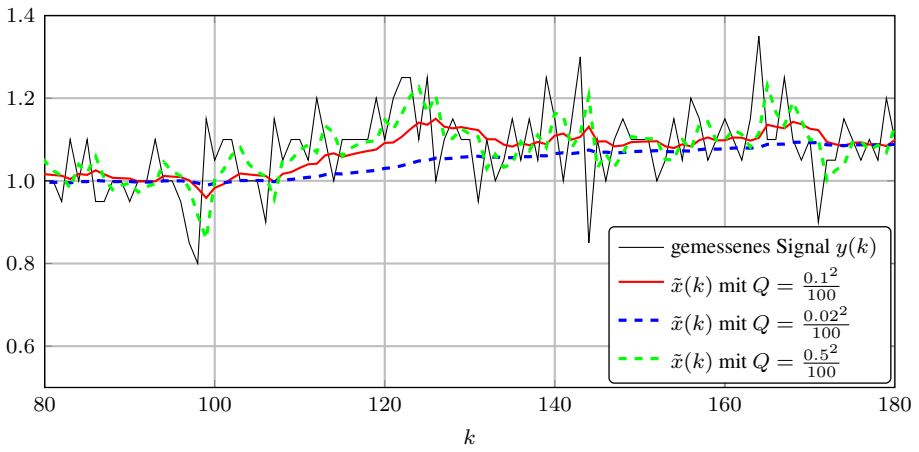
```
load -ascii data_k_t_y_z_a_v.dat;
y = data_k_t_y_z_a_v(:,3);

%%% INITIALISIERUNG KALMAN-FILTER %%%
R = 0.0053;
Delta = 0.1;
Q = 0.01*(Delta^2);
x(1) = y(1);
P(1) = 100*Q;

%%% ZYKLISCHE BERECHNUNG KALMAN-FILTER %%%
for k=1:length(y)
  K(k) = P(k)/(P(k) + R);
  x(k+1) = x(k) + K(k)*(y(k) - x(k));
  P(k+1) = (1 - K(k))*P(k) + Q;
end
```

Folie 4.86

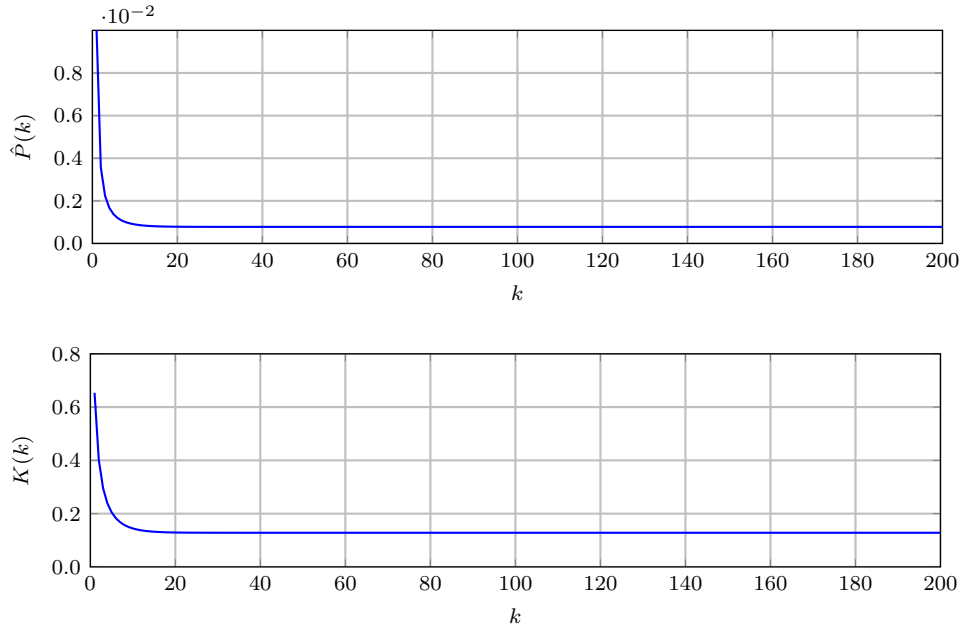
Geschätzte Zustandsgröße $\tilde{x}$



Folie 4.87



Verlauf der Kalman-Verstärkung $K(k)$ und der Kovarianz des Schätzfehlers $\hat{P}(k)$



Folie 4.88

Fragen

- Wie würde sich die geschätzte Größe $\hat{x}$ ändern, wenn man fälschlicherweise R deutlich zu klein abschätzen würde?
- Wie ist ein Wert von $\hat{P} \approx 0.001$ zu deuten?
- Unter welchen Bedingungen konvergiert die Kalman-Verstärkung $K(k)$ und $\hat{P}(k)$ gegen einen festen Wert?

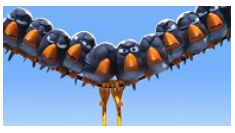
Lösung:

Folie 4.89

Bestimmung von $\hat{P}$ und K bei konstantem R und Q

- Ist R und Q zeitinvariant, streben die Kalmanverstärkung K und die Kovarianz des Schätzfehler $\hat{P}$ gegen einen festen Wert.
- Im eingeschwungenen Zustand gilt: $\hat{P}(k+1) = \hat{P}(k) = \hat{P}$ und $K(k) = K$.
- Mit diesen beiden Zusammenhängen lässt sich Gleichung (65) schreiben zu:

$$\hat{P} = (1 - K) \cdot \hat{P} + Q = \hat{P} - K \cdot \hat{P} + Q$$
$$\hat{P} = \frac{Q}{K} \tag{66}$$



- Setzt man Gleichung (66) in Gleichung (63) ein und multipliziert die Gleichung mit K/R, folgt für $R \neq 0$:

$$K = \frac{\hat{P}}{\hat{P} + R} = \frac{\frac{Q}{K}}{\frac{Q}{K} + R} = \frac{\frac{Q}{R}}{\frac{Q}{R} + K}$$

- Umgeformt erhält man:

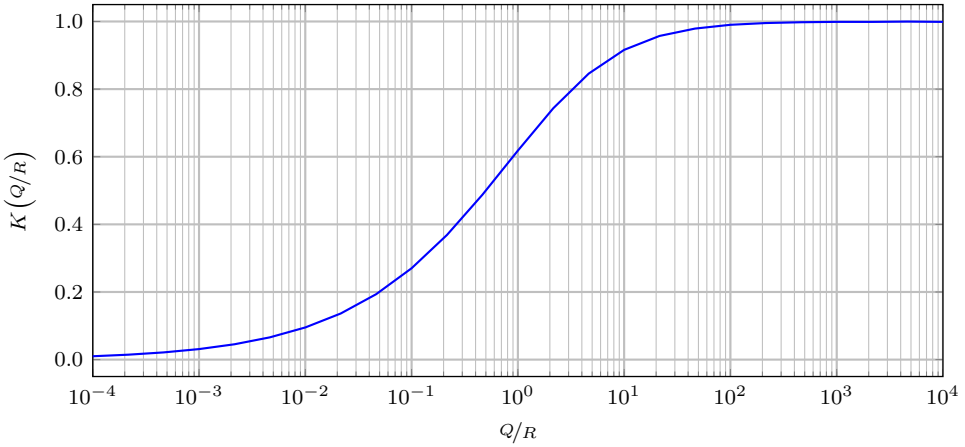
$$K^2 + \frac{Q}{R} \cdot K - \frac{Q}{R} = 0$$

- Da K nur positive Werte annehmen kann, hat diese quadratische Gleichung die Lösung:

$$K = -\frac{1}{2} \cdot \frac{Q}{R} + \sqrt{\frac{1}{4} \cdot \left(\frac{Q}{R}\right)^2 + \frac{Q}{R}} \tag{67}$$

Folie 4.90

Verlauf der Kalman-Verstärkung K in Abhängigkeit der Größe Q/R



Quelle: Marchthaler, Kalman-Filter [1]

Folie 4.91

Formel Alpha-Filter

- Für $R = 0.0053$ und $Q = 0.0001$ konvergiert die Kalman-Verstärkung K gegen: $K \approx 0.1283$
- Die Kovarianz des Schätzfehlers $\hat{P}$ konvergiert gegen:

$$\hat{P} = \frac{Q}{K} \approx \frac{0.0001}{0.1283} \approx 0.000780$$

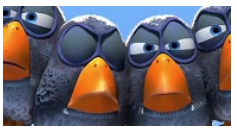
- Die Kalman-Verstärkung hängt somit im eingeschwungenen Zustand nur von dem Verhältnis Q/R ab.
- Man bezeichnet dieses Verhältnis auch als „*Target Maneuvering Index*“ oder „*Target Tracking Index*“ (siehe [4], [5]).
- Da Q und R jeweils Varianzen repräsentieren, ist das Verhältnis Q/R stets positiv.
- Da im eingeschwungenen Zustand die Kalmanverstärkung zeitinvariant ist, ist es nicht notwendig diese adaptiv zu bestimmen.
- Die Berechnung des Kalman-Filters (*Alpha-Filter*) reduziert sich in diesem Beispiel auf die Gleichungen:

$$\hat{x}(k+1) = \hat{x}(k) + K \cdot \left(y(k) - \hat{x}(k)\right) \tag{68}$$

mit $$K = -0.5 \cdot Q/R + \sqrt{0.25 \cdot (Q/R)^2 + Q/R} \tag{69}$$

und $$\hat{P} = \frac{Q}{K} \tag{70}$$

Folie 4.92



Übergang in IIR-Filter 1. Ordnung

- Hätte ein herkömmliches Tiefpass-Filter bei diesem Beispiel nicht dasselbe Ergebnisse geliefert?
- Formt man Gleichung (68) um, folgt:

$$\hat{x}(k+1) = \hat{x}(k) + K \cdot \big(y(k) - \hat{x}(k)\big) = K \cdot y(k) + \big(1-K\big) \cdot \hat{x}(k) \tag{71}$$

$$\text{mit} \qquad K = -0.5 \cdot {}^{Q}/_{R} + \sqrt{0.25 \cdot \left({}^{Q}/_{R}\right)^2 + {}^{Q}/_{R}}$$

- Somit entspricht das Kalman-Filter in diesem Beispiel ein *IIR-Filter* (englisch: *infinite impulse response filter*) 1. Ordnung.
- Der *„Filtergrad“* wird durch die *Kalman-Verstärkung* K bzw. durch das Verhältnis ${}^{Q}/_{R}$ *festgelegt*.
- Bei Werten von $Q \ll R$ ergibt sich eine Kalman-Verstärkung von $K \approx 0$ und das Filter *berücksichtigt nur unwesentlich aktuelle Messergebnisse*, es ist $\hat{x}(k+1) \approx \hat{x}(k)$.
- Ist $Q \gg R$ folgt für die Kalman-Verstärkung ein Wert $K \approx 1$ und $\hat{x}(k+1) \approx y(k)$. In diesem Fall „vertraut“ das Filter fast ausschließlich den aktuellen Messergebnissen und nicht dem gefilterten Wert. Mit anderen Worten: das *Modell ist zu schlecht*. In solchen Fällen sollte das Modell verfeinert werden. Das Ziel sollte sein, ein Modell zu finden, bei dem $Q < R$ ist.

Folie 4.93

Lernkontrolle: Alpha-Filter

- Sie sollten das *verwendete Modell*, welchem dem *Alpha-Filter* zugrunde liegt verinnerlicht haben.
- Sie sollten abwägen können, welche der *verschiedenen Formeln* zur Berechnung des *Systemrauschens* passend ist.
- Sie sollten in der Lage sein die *Kovarianz des Messrauchens* und die *Kovarianz des Systemrauschens* zu bestimmen.
- Sie sollten verstanden haben, dass ein *Alpha-Filter* mit einem *IIR-Filter 1. Ordnung* identisch ist.

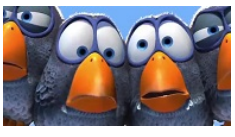
Folie 4.94

7.5 Beispielentwurf eines Kalman-Filters (Gamma-Filter)

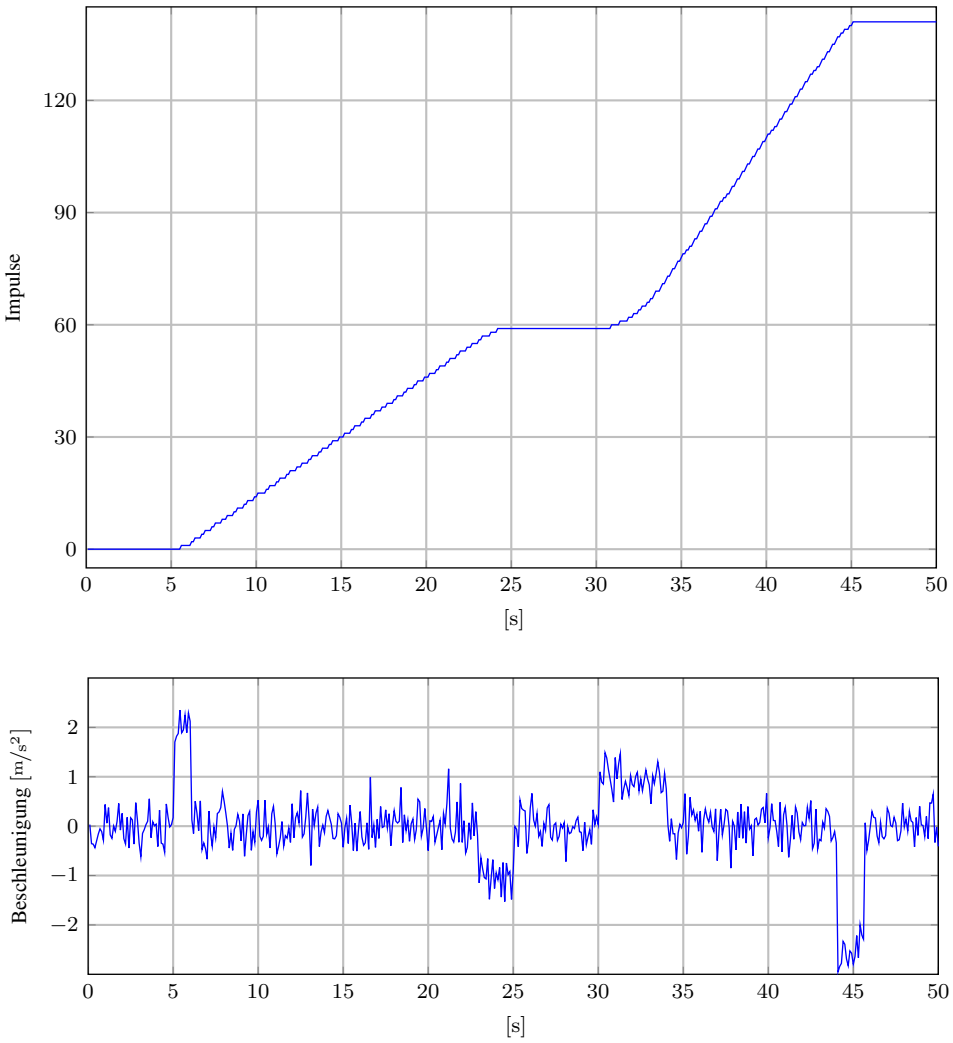
Problemstellung

- Für ein Fahrzeug soll die zurückgelegte *Strecke* und die *Geschwindigkeit* abgeschätzt werden.
- Hierzu wurde in zwei Rädern ein Impulsgeber eingebaut, der bei jeder Radumdrehung einen Impuls liefert und somit die Anzahl der Impulse (Radumdrehungen) zählt. Der Umfang eines Rades beträgt 1.25m. Die beiden *Zählerstände* werden addiert und liefern somit im Mittel *alle 0.625m* einen neuen Wert.
- Zusätzlich existiert im Fahrzeug verbaut ein *Beschleunigungssensor* der die Beschleunigung in Längsrichtung erfasst.
- Beide messtechnisch erfassbare Größen werden alle *0.1s* zeitgleich abgetastet.

Folie 4.96



Messtechnisch erfassbare Größen



Folie 4.97

Systembeschreibung

- Wird die komplette Masse des Fahrzeugs in einem *Massepunkt* vereint, so lässt sich das dynamische Verhalten dieses Massepunkts modellieren durch:

$$a(t) = \dot{v}(t) = \ddot{s}(t) \tag{72}$$

- *Wählt* man den *Zustandsvektor* $\underline{x}(t)$ zu:

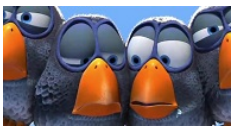
$$\underline{x}(t) = \begin{bmatrix} s(t) \\ v(t) \\ a(t) \end{bmatrix} \tag{73}$$

- Ergibt die *Ableitung der Zustandsvariablen* $\dot{\underline{x}}(t)$:

$$\dot{\underline{x}}(t) = \begin{bmatrix} \dot{s}(t) \\ \dot{v}(t) \\ \dot{a}(t) \end{bmatrix} = \begin{bmatrix} v(t) \\ a(t) \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \cdot z(t) \tag{74}$$

- Mögliche *Änderungen der Beschleunigung* werden durch die *Zufallsvariable* $z(t)$ berücksichtigt

Folie 4.98



Zeitkontinuierliche Systembeschreibung

Wie lautet die zeitkontinuierliche Zustandsraumbeschreibung eines solchen Modells?

Folie 4.99

Zeitdiskrete Systembeschreibung I

- Ein lineares zeitdiskretes System wird allgemein im Zustandsraum beschrieben durch:

$$\underline{A}_d = e^{\underline{A} \cdot T_s}, \qquad \underline{B}_d = \int_0^{T_s} e^{\underline{A} \cdot \nu} \cdot \underline{B} \, d\nu, \qquad \underline{G}_d = \underline{A}_d \cdot \underline{G}$$

- Mithilfe von Matlab lassen sich die Matrizen berechnen:

```
syms Ts 'real';

A = [0 1 0;
     0 0 1;
     0 0 0];
B = [0; 0; 0];
G = [0; 0; 1];

Ad = simplify(expm(Ts*A))
Bd = simplify(int(expm(Ts*A)*B))
Gd = Ad*G
```

Folie 4.100



Zeitdiskrete Systembeschreibung II

- Die Berechnung ergibt:

$$\underline{A}_d = \begin{bmatrix} 1 & T_s & \frac{T_s^2}{2} \\ 0 & 1 & T_s \\ 0 & 0 & 1 \end{bmatrix}, \quad \underline{B}_d = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \quad \underline{G}_d = \begin{bmatrix} \frac{T_s^2}{2} \\ T_s \\ 1 \end{bmatrix}$$

- Somit folgt:

$$\underline{x}(k+1) = \begin{bmatrix} s(k+1) \\ v(k+1) \\ a(k+1) \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & T_s & \frac{T_s^2}{2} \\ 0 & 1 & T_s \\ 0 & 0 & 1 \end{bmatrix}}_{\underline{A}_d} \cdot \begin{bmatrix} s(k) \\ v(k) \\ a(k) \end{bmatrix} + \underbrace{\begin{bmatrix} \frac{T_s^2}{2} \\ T_s \\ 1 \end{bmatrix}}_{\underline{G}_d} \cdot z(k)$$

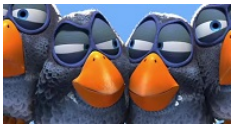
$$\underline{y}(k) = \begin{bmatrix} \text{Impulse}(k) \\ a(k) \end{bmatrix} = \underbrace{\begin{bmatrix} 1.6 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{\underline{C}} \cdot \begin{bmatrix} s(k) \\ v(k) \\ a(k) \end{bmatrix}$$

Folie 4.101

Beobachtbarkeit

Überprüfen Sie, ob das Modell beobachtbar ist.

Folie 4.102



Messrauschen $\underline{R}$

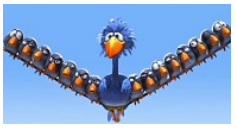
- Bestimmen Sie die Kovarianz des Messrauschens $\underline{R}$.
- Die Varianz des Messrauchens des Beschleunigungssensors lässt sich mit den ersten 10 Messungen abschätzen: 0.0316, -0.3551, -0.3646, -0.4365, -0.2969, -0.1584, -0.0532, -0.1132, -0.2838, 0.4389
- Hinweis: Zur Abschätzung der Varianz des Messrauchens des Impulsgebers sind keine Messdaten notwendig ☺

Folie 4.103

Systemrauschen Q

Überlegen Sie wie man die Größe des Systemrauschens Q für die Methode 1 bestimmen (abschätzen) könnte.

Folie 4.104



Matlab-Code

```
load -ascii data_in_t_y_s_v_a.dat;
t = data_in_t_y_s_v_a(:,1);
y = data_in_t_y_s_v_a(:,2:3);
u = zeros(1,length(y));
clear data_in_t_y_s_v_a;

Ts = 0.1;
R = [0.083 0; 0 0.085];
Q = 0.06;

Ad = [1  Ts  0.5*Ts^2; 0  1  Ts; 0  0  1];
Bd = [0; 0; 0];
C  = [1.6  0  0; 0  0  1];
G  = [0.5*Ts^2; Ts; 1];

%%% Init %%%
x = [y(1,1); 0; y(1,2)];
P = 3*[1 0 0; 0 1 0; 0 0 1];

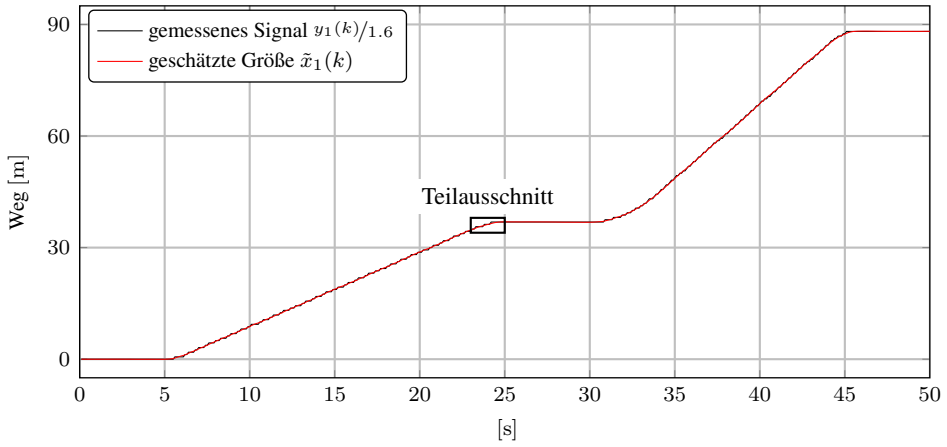
%%% Kalman-Filter %%%
for k=1:length(y)
  K = P*C'*pinv(C*P*C' + R);
  x = x + K*(y(k,:)' - C*x);
  P = (eye(length(Bd)) - K*C)*P;

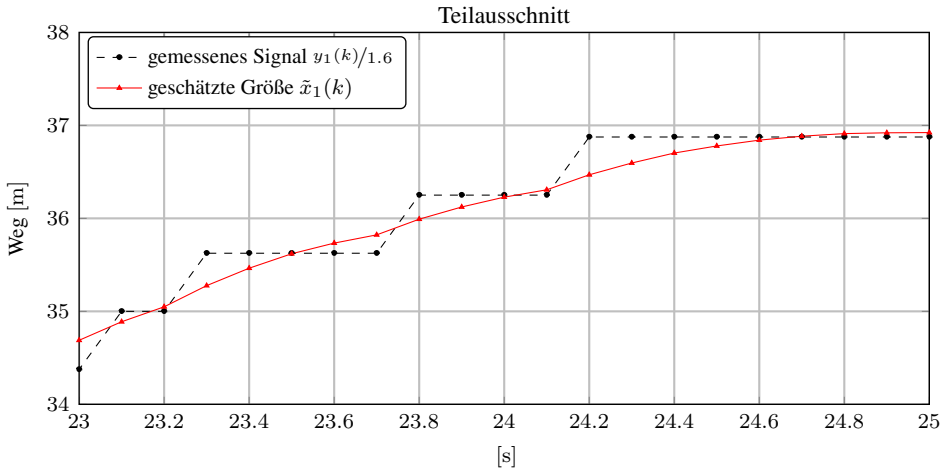
  s(k) = x(1);  v(k) = x(2);  a(k) = x(3);

  x = Ad*x + Bd*u(k);
  P = Ad*P*Ad' + G*Q*G';
end
```

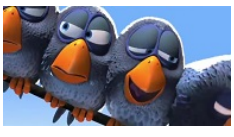
Folie 4.105

Geschätzte Zustandsgröße Weg $\tilde{x_1}$

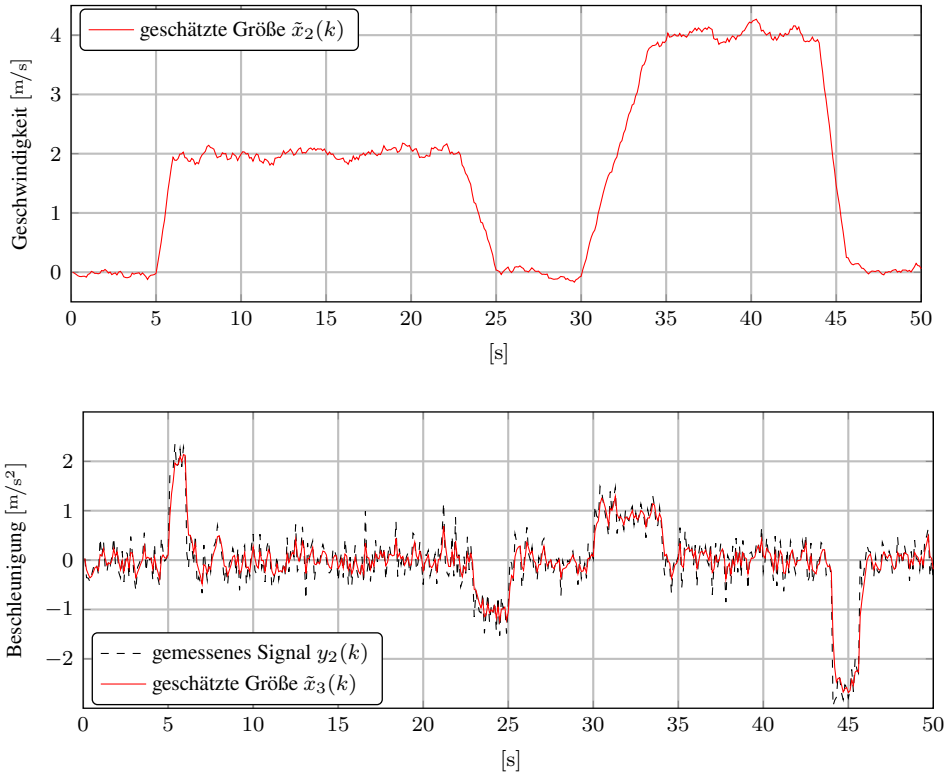




Folie 4.106



Geschätzte Zustandsgröße Geschwindigkeit $\tilde{x}_2$ und Beschleunigung $\tilde{x}_3$



Folie 4.107

Fragen

- Warum wird die geschätzte Beschleunigung fast identisch mit der gemessenen Beschleunigung?
- Was müsst man tun, um die Beschleunigung besser zu filtern?
- Wie schafft das Kalman-Filter das Wegsignal so gut abzuschätzen?

Lösung:

Folie 4.108



7.6 Modellierung Systemrauschens

Zeitdiskrete Systembeschreibung

- Der Kalman-Filters basiert auf das zeitdiskrete Modell:

$$\underline{x}(k+1) = \underbrace{\underline{A}_d \cdot \underline{x}(k) + \underline{B}_d \cdot \underline{u}(k)}_{\text{Systemmodell}} + \underbrace{\underline{G}_d \cdot \underline{z}(k)}_{\text{Rauschmodell}}$$

- Kalman-Filter besteht aus den zwei wichtigen Berechnungen:
  Korrektur- und *Prädiktionsschritt*
- Je verrauschter die messtechnisch erfassbaren Größen sind, desto besser sollte das verwendete Modell sein.
- Im Prädiktionsschritt werden die Matrizen $\underline{A}_d$, $\underline{B}_d$ und $\underline{G}_d$ verwendet:

$$\hat{\underline{x}}(k+1) = \underline{A}_d \cdot \tilde{\underline{x}}(k) + \underline{B}_d \cdot \underline{u}(k)$$
$$\hat{\underline{P}}(k+1) = \underline{A}_d \cdot \tilde{\underline{P}}(k) \cdot \underline{A}_d^T + \underbrace{\underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T}_{\text{Systemrauschen}}$$

- Das Systemrauschen wird durch:

$$\underline{Q}^*(k) = \underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T$$

Folie 4.110

Verbesserung Modellierung des Systemrauchens

- Ein Beta-Filter kann durch folgende zeitkontinuierliche Systembeschreibung verbessert werden:

$$\dot{\underline{x}}(t) = \begin{bmatrix} \dot{s}(t) \\ \dot{v}(t) \end{bmatrix} = \underbrace{\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}}_{\underline{A}} \cdot \begin{bmatrix} s(t) \\ v(t) \end{bmatrix} + \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}}_{\underline{G}} \cdot \begin{bmatrix} z_1(t) \\ z_2(t) \end{bmatrix}$$

- $z_1(t)$ modelliert, dass der Zusammenhang $\dot{s}(t) = v(t)$ nicht exakt stimmt (z.B. bei mechanischen Systemen durch Reibung)
- $z_2(t)$ modelliert, dass die Geschwindigkeitsänderung nicht immer null ist.
- Für $\underline{A}_d = e^{\underline{A} \cdot T_s} = \begin{bmatrix} 1 & T_s \\ 0 & 1 \end{bmatrix}$ folgt mit: $\underline{G}_d = \underline{A}_d \cdot \underline{G} = \begin{bmatrix} 1 & T_s \\ 0 & 1 \end{bmatrix}$
- Unterstellt man, dass $z_1(t)$ und $z_2(t)$ unkorreliert sind, folgt mit:

$$Q(k) = \mathrm{Var}\big(\underline{z}(k)\big) = \begin{bmatrix} \mathrm{Var}\big(z_1(k)\big) & 0 \\ 0 & \mathrm{Var}\big(z_2(k)\big) \end{bmatrix} = \begin{bmatrix} Q_1(k) & 0 \\ 0 & Q_2(k) \end{bmatrix}$$

$$\underline{Q}^*(k) = \underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T = \begin{bmatrix} Q_1(k) + Q_2(k) \cdot T_s^2 & Q_2(k) \cdot T_s \\ Q_2(k) \cdot T_s & Q_2(k) \end{bmatrix}$$

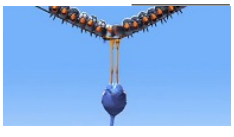
Folie 4.111

7.7 Lernziele

Lernkontrolle

- Sie sollten das *verwendete kinematische Modell*, welchem dem Kalman-Filter zugrunde liegt verinnerlicht haben.
- Sie sollten abwägen können, welche der *verschiedenen Formeln* zur Berechnung des *Systemrauschens* passend ist. (Siehe Kap. 7.5 in Kalman-Filter - Einführung in die Zustandsschätzung und ihre Anwendung für eingebettete Systeme [1])
- Sie sollten in der Lage sein die *Kovarianz des Messrauschens* und die *Kovarianz des Systemrauschens* zu bestimmen.

Folie 4.113



Teil V

ROSE-Filter

8 ROSE-Filter

8.1 Kalman-Verstärkung

Alternative Berechnung der Kalman-Verstärkung I

- Mit $\underline{\hat{y}}(k) = \underline{C}\cdot\underline{\hat{x}}(k) + \underline{D}\cdot\underline{u}(k)$ gilt für die Fehler $\Delta\underline{y}(k)$:

$$\begin{aligned}\Delta\underline{y}(k) &= \underline{y}(k) - \underline{\hat{y}}(k)\\ \Delta\underline{y}(k) &= \underline{y}(k) - \underline{C}\cdot\underline{\hat{x}}(k) - \underline{D}\cdot\underline{u}(k)\end{aligned} \tag{75}$$

- Mithilfe der Gleichung $\underline{y}(k) = \underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k) + \underline{v}(k)$ folgt:

$$\begin{aligned}\Delta\underline{y}(k) &= \underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k) + \underline{v}(k) - \underline{C}\cdot\underline{\hat{x}}(k) - \underline{D}\cdot\underline{u}(k)\\ &= \underline{C}\cdot\underbrace{\left(\underline{x}(k) - \underline{\hat{x}}(k)\right)}_{\underline{\varepsilon}(k)} + \underline{v}(k)\\ &= \underline{C}\cdot\underline{\varepsilon}(k) + \underline{v}(k)\end{aligned} \tag{76}$$

- Für die Kovarianz $\underline{M}(k)$ der Größe $\Delta\underline{y}(k)$ gilt:

$$\begin{aligned}\underline{M}(k) &= \mathrm{Cov}\left(\Delta\underline{y}(k), \Delta\underline{y}(k)\right)\\ &= \mathrm{Var}\left(\Delta\underline{y}(k)\right)\\ &= \mathrm{Var}\left(\underline{C}\cdot\underline{\varepsilon}(k) + \underline{v}(k)\right)\\ &= \mathrm{Var}\left(\underline{C}\cdot\underline{\varepsilon}(k)\right) + \mathrm{Var}\left(\underline{v}(k)\right) + 2\cdot\underbrace{\mathrm{Cov}\left(\underline{C}\cdot\underline{\varepsilon}(k), \underline{v}(k)\right)}_{=\underline{0}\text{, da unkorreliert}}\\ &= \underline{C}\cdot\underbrace{\mathrm{Var}\left(\underline{\varepsilon}(k)\right)}_{\underline{P}(k)}\cdot\underline{C}^T + \underbrace{\mathrm{Var}\left(\underline{v}(k)\right)}_{\underline{R}(k)}\\ &= \underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + \underline{R}(k)\end{aligned} \tag{77}$$

Folie 5.4

Alternative Berechnung der Kalman-Verstärkung II

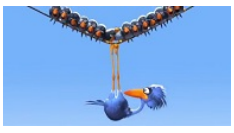
- Mit der Annahme, dass $\underline{\hat{\varepsilon}}(k)$ und $\underline{v}(k)$ unkorreliert sind und somit die Kovarianz $\mathrm{Cov}\left(\underline{C}\cdot\underline{\hat{\varepsilon}}(k), \underline{v}(k)\right) = \underline{0}$ ist. Sowie mit
  Gleichung (76): $\Delta\underline{y}(k) = \underline{C}\cdot\underline{\hat{\varepsilon}}(k) + \underline{v}(k)$,
  Gleichung (127): $\mathrm{E}\left(\underline{A}\cdot\underline{X}\right) = \underline{A}\cdot\mathrm{E}\left(\underline{X}\right)$
  und der Annahme, dass die Größen $\underline{\hat{\varepsilon}}(k)$, $\underline{v}(k)$ mittelwertfrei sind, gilt für den Erwartungswert $\mathrm{E}\left(\Delta\underline{y}(k)\right)$:

$$\begin{aligned}\mathrm{E}\left(\Delta\underline{y}(k)\right) &= \mathrm{E}\left(\underline{C}\cdot\underline{\hat{\varepsilon}}(k) + \underline{v}(k)\right)\\ &= \underline{C}\cdot\underbrace{\mathrm{E}\left(\underline{\hat{\varepsilon}}(k)\right)}_{=\underline{0}} + \underbrace{\mathrm{E}\left(\underline{v}(k)\right)}_{=\underline{0}} = \underline{0}\end{aligned} \tag{78}$$

- Die Kovarianz $\underline{M}(k)$ lässt sich mit Gleichung (78) und
  Gleichung (132): $\mathrm{Cov}\left(\underline{X}, \underline{X}\right) = \mathrm{E}\left(\underline{X}\cdot\underline{X}^T\right) - \mathrm{E}\left(\underline{X}\right)\cdot\mathrm{E}\left(\underline{X}^T\right)$ schreiben zu:

$$\begin{aligned}\underline{M}(k) &= \mathrm{Cov}\left(\Delta\underline{y}(k), \Delta\underline{y}(k)\right)\\ &= \mathrm{E}\left(\Delta\underline{y}(k)\cdot\Delta\underline{y}(k)^T\right) - \underbrace{\mathrm{E}\left(\Delta\underline{y}(k)\right)\cdot\mathrm{E}\left(\Delta\underline{y}(k)^T\right)}_{=\underline{0}}\\ &= \mathrm{E}\left(\Delta\underline{y}(k)\cdot\Delta\underline{y}(k)^T\right)\end{aligned} \tag{79}$$

Folie 5.5



Alternative Berechnung der Kalman-Verstärkung III

- Mit Gleichung (77) und Gleichung (79) folgt:

$$\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + \underline{R}(k) = \mathrm{E}\left(\Delta\underline{y}(k)\cdot\Delta\underline{y}(k)^T\right) \tag{80}$$

- Die Kalman-Verstärkung lässt sich hiermit schreiben zu:

$$\underline{K}(k) = \underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\left(\underline{C}\cdot\underline{\hat{P}}(k)\cdot\underline{C}^T + \underline{R}(k)\right)^{-1}$$

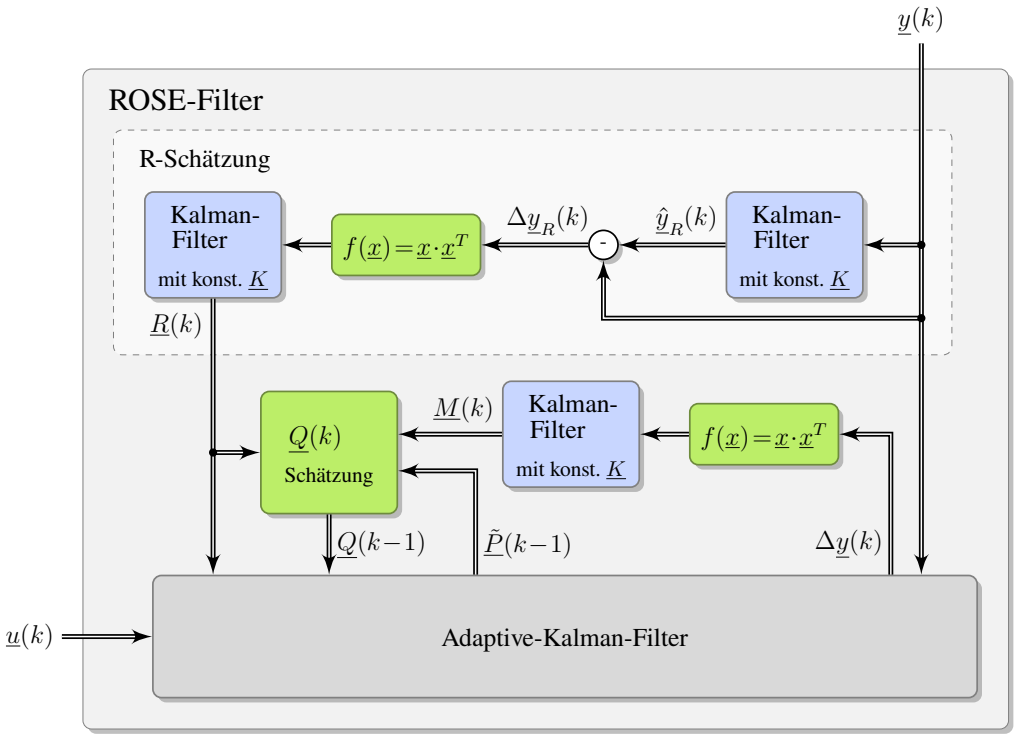
$$\boxed{\underline{K}(k) = \underline{\hat{P}}(k)\cdot\underline{C}^T\cdot\underline{M}(k)^{-1} \quad \text{mit} \quad \underline{M}(k) = \mathrm{E}\left(\Delta\underline{y}(k)\cdot\Delta\underline{y}(k)^T\right)} \tag{81}$$

- Bei dieser alternativen Berechnung muss statt der Größe $\underline{R}(k)$, die Größe $\underline{M}(k) = \mathrm{E}\left(\Delta\underline{y}(k)\cdot\Delta\underline{y}(k)^T\right)$ bestimmt werden.

Folie 5.6

8.2 Aufbau ROSE-Filter

Struktur ROSE-Filter



Quelle: Marchthaler, Kalman-Filter [1]

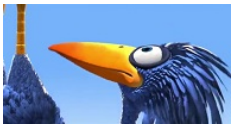
Folie 5.8

Adaptive Bestimmung des Messrauschens

- Mit $\underline{y}(k) = \underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k) + \underline{v}(k)$ und der Annahme, dass die Größe $\underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k)$ und das Messrauschen $\underline{v}(k)$ unkorreliert sind, folgt:

$$\begin{aligned}\mathrm{Var}\left(\underline{y}(k)\right) &= \mathrm{Var}\left(\underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k) + \underline{v}(k)\right)\\ &= \underbrace{\mathrm{Var}\left(\underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k)\right)}_{=0} + \mathrm{Var}\left(\underline{v}(k)\right)\end{aligned} \tag{82}$$

- Der Term $\underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k)$ kann zum Zeitpunkt k für die Varianzberechnung als eine Konstante betrachtet werden, folglich ist $\mathrm{Var}\left(\underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k)\right) = 0$.



- Es folgt:

$$\underline{R}(k) = \mathrm{Var}\big(\underline{v}(k)\big) = \mathrm{Var}\big(\underline{y}(k)\big) \tag{83}$$
$$= \mathrm{E}\Big(\big(\underline{y}(k) - \mathrm{E}\big(\underline{y}(k)\big)\big) \cdot \big(\underline{y}(k) - \mathrm{E}\big(\underline{y}(k)\big)\big)^T\Big) \tag{84}$$
$$\approx \mathrm{E}\Big(\big(\underline{y}(k) - \underline{\hat{y}}_R(k)\big) \cdot \big(\underline{y}(k) - \underline{\hat{y}}_R(k)\big)^T\Big) \tag{85}$$
$$\approx \mathrm{E}\Big(\Delta\underline{\hat{y}}_R(k) \cdot \Delta\underline{\hat{y}}_R(k)^T\Big) \tag{86}$$

- Alternativ lässt sich die Kovarianz des Messrauschens berechnen mit:

$$\underline{R}(k) = \mathrm{Var}\big(\underline{y}(k)\big) = \mathrm{E}\big(\underline{y}(k) \cdot \underline{y}(k)^T\big) - \mathrm{E}\big(\underline{y}(k)\big) \cdot \mathrm{E}\big(\underline{y}(k)\big)^T \tag{87}$$

- Betrachtet man ein kurzes Zeitintervall, so kann man innerhalb diesen Intervallen die Annahme eines ergodischen Prozesses treffen. Unter dieser Annahme lässt sich der Erwartungswert durch eine Mittelwertbildung annähern.

Folie 5.9

Adaptive Bestimmung des Systemrauschens

- Mithilfe der Kovarianz $\underline{M}(k)$ und der Größe $\Delta\underline{y}(k)$ ist es möglich, das Systemrauschen zu bestimmen.
- Mit Gleichung $\underline{M}(k) = \mathrm{E}\big(\Delta\underline{y}(k) \cdot \Delta\underline{y}(k)^T\big) = \underline{C} \cdot \underline{\hat{P}}(k) \cdot \underline{C}^T + \underline{R}(k)$ folgt:

$$\underline{\hat{P}}(k) = \underline{C}^T \cdot \big(\underline{M}(k) - \underline{R}(k)\big) \cdot \underline{C} \tag{88}$$

- Formt man Gleichung $\underline{\hat{P}}(k+1) = \underline{A}_d \cdot \underline{\tilde{P}}(k) \cdot \underline{A}_d^T + \underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T$ mithilfe der obigen Gleichung um und nimmt man eine Indexverschiebung vor, so folgt:

$$\begin{aligned} \underline{Q}^*(k-1) &= \underline{G}_d \cdot \underline{Q}(k-1) \cdot \underline{G}_d^T = \underline{\hat{P}}(k) - \underline{A}_d \cdot \underline{\tilde{P}}(k-1) \cdot \underline{A}_d^T \\ \underline{C} \cdot \underline{Q}^*(k-1) \cdot \underline{C}^T &= \underline{M}(k) - \underline{R}(k) - \underline{C} \cdot \underline{A}_d \cdot \underline{\tilde{P}}(k-1) \cdot \underline{A}_d^T \cdot \underline{C}^T \end{aligned} \tag{89}$$

- Unter der Annahme, dass es sich in einem kurzen Beobachtungsintervall um einen ergodischen Prozess handelt, kann der Erwartungswert, bei der Bestimmung von $\underline{M}(k)$, durch eine Mittelwertbildung (z. B. ein IIR-Filter 1. Ordnung) ersetzt werden.
- Die Berechnung der Varianz des Systemrauschens $\underline{Q}^*$ geschieht durch Koeffizientenvergleich der einzelnen Elemente der linken und rechten Seite der Gleichung (89).

Folie 5.10

Algorithmus

- Berechnung von $\underline{R}(k)$ und $\underline{Q}(k)$:

$$\begin{aligned} \underline{R}(k) &= \mathrm{E}\big(\underline{y}(k) \cdot \underline{y}(k)^T\big) - \mathrm{E}\big(\underline{y}(k)\big) \cdot \mathrm{E}\big(\underline{y}(k)\big)^T \quad \text{bzw.} && (90) \\ &= \mathrm{E}\Big(\big(\underline{y}(k) - \mathrm{E}\big(\underline{y}(k)\big)\big) \cdot \big(\underline{y}(k) - \mathrm{E}\big(\underline{y}(k)\big)\big)^T\Big) && (91) \\ \Delta\underline{y}(k) &= \underline{y}(k) - \underline{C} \cdot \underline{\hat{x}}(k) - \underline{D} \cdot \underline{u}(k) && (92) \\ \underline{M}(k) &= \mathrm{E}\big(\Delta\underline{y}(k) \cdot \Delta\underline{y}(k)^T\big) && (93) \\ \underline{C} \cdot \underline{Q}^*(k-1) \cdot \underline{C}^T &= \underline{M}(k) - \underline{R}(k) - \underline{C} \cdot \underline{A}_d \cdot \underline{\tilde{P}}(k-1) \cdot \underline{A}_d^T \cdot \underline{C}^T && (94) \end{aligned}$$

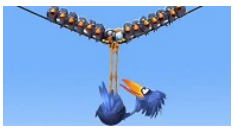
- Prädiktion:

$$\begin{aligned} \underline{\hat{x}}(k) &= \underline{A}_d \cdot \underline{\tilde{x}}(k-1) + \underline{B}_d \cdot \underline{u}(k-1) && (95) \\ \underline{\hat{P}}(k) &= \underline{A}_d \cdot \underline{\tilde{P}}(k-1) \cdot \underline{A}_d^T + \underline{Q}^*(k-1) && (96) \end{aligned}$$

- Korrektur:

$$\begin{aligned} \underline{K}(k) &= \underline{\hat{P}}(k) \cdot \underline{C}^T \cdot \big(\underline{C} \cdot \underline{\hat{P}}(k) \cdot \underline{C}^T + \underline{R}(k)\big)^{-1} && (97) \\ \underline{\tilde{x}}(k) &= \underline{\hat{x}}(k) + \underline{K}(k) \cdot \Delta\underline{y}(k) && (98) \\ \underline{\tilde{P}}(k) &= \big(\underline{I} - \underline{K}(k) \cdot \underline{C}\big) \cdot \underline{\hat{P}}(k) && (99) \end{aligned}$$

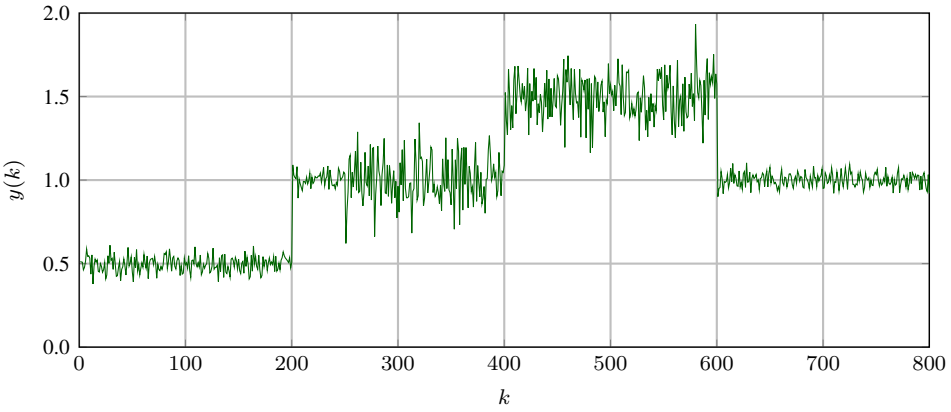
Folie 5.11



8.3 Beispiel ROSE-Filter

Problemstellung

- Kovarianz des Messrauschens und des Systemrauschens ist nicht konstant.



Folie 5.13

Schätzung der Kovarianzen des Messrauschens und des Systemrauschens

- Berechnung der Größe M(k) durch ein Alpha-Filter (IIR-Filter 1. Ordnung)

$$M(k) = \mathrm{E}\left(\Delta\underline{y}(k) \cdot \Delta\underline{y}(k)^T\right) \approx \alpha_M \cdot \Delta y(k)^2 + (1-\alpha_M) \cdot M(k-1) \tag{100}$$

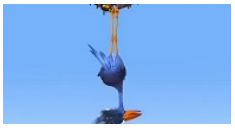
- Die Näherung der beiden Erwartungswerte für die Bestimmung der Varianz des Messrauschens ist:

$$E1(k) = \mathrm{E}\left(\underline{y}(k)\right) \approx \alpha_R \cdot y(k) + (1-\alpha_R) \cdot E1(k-1) \tag{101}$$

$$EE1(k) = \mathrm{E}\left(\underline{y}(k) \cdot \underline{y}(k)^T\right) \approx \alpha_R \cdot y(k)^2 + (1-\alpha_R) \cdot EE1(k-1) \tag{102}$$

- Mit α stellt man die *Grenzfrequenz des Tiefpass-Filters* ein.
- Ein *kleiner Wert* für α bedeutet, dass das Filter *langsam auf Änderungen des Erwartungswerts reagiert*.
- Ein *großer Wert* für α führt dazu, dass der Erwartungswert zu *ungenau bestimmt* wird und somit das Kalman-Filter nicht mehr optimal arbeitet.
- Bei *stark sich ändernden Erwartungswerten* (Varianzen des Messrauschens) sollte ein Wert von α *maximal* 0.5 gewählt werden.
- Bei sich langsam ändernden Varianzen können kleinere Werte als 0.5 gewählt werden.
- Ein Wert von $\alpha = K = 0.5$ entspricht einem Verhältnis von Q/R=0.5.

Folie 5.14



Matlab-Code Teil 1/2

```
Faktor_minR = 9.0;      % Verstärkungsfaktor Messrauschen
Alpha_R = 0.5;          % Kalman-Verstärkung Varianz Messrauschen
Alpha_M = 0.3;          % Kalman-Verstärkung Varianz M
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
Ts = 0.1;               % Abtastzeit
Ad = 1;                 % Systemmatrix
Bd = 0;                 % Eingangsmatrix
C  = 1;                 % Ausgangsmatrix
D  = 0;                 % Durchgangsmatrix
G  = 1;                 % Systemfehlermatrix

%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
%%%   M E S S D A T E N - G E N E R A T O R
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
t  = Ts*(1:1:800);
ao = [.5*ones(1,200) +1*ones(1,200) 1.5*ones(1,200) +1*ones(1,200)];
Rg = 2E-3;
v  = [sqrt(1*Rg)*randn(1,250) sqrt(10*Rg)*randn(1,350) sqrt(1*Rg)*randn(1,200)];
y  = [ao + v];
u = zeros(1,length(y));

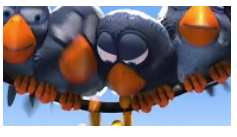
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
%%%   I N I T   R O S E - F I L T E R
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
x_dach = [y(1)];
p_tilde = 100;
E1  = y(1);
EE1 = y(:,1)*y(:,1)';
M   = 0;
```

Folie 5.15

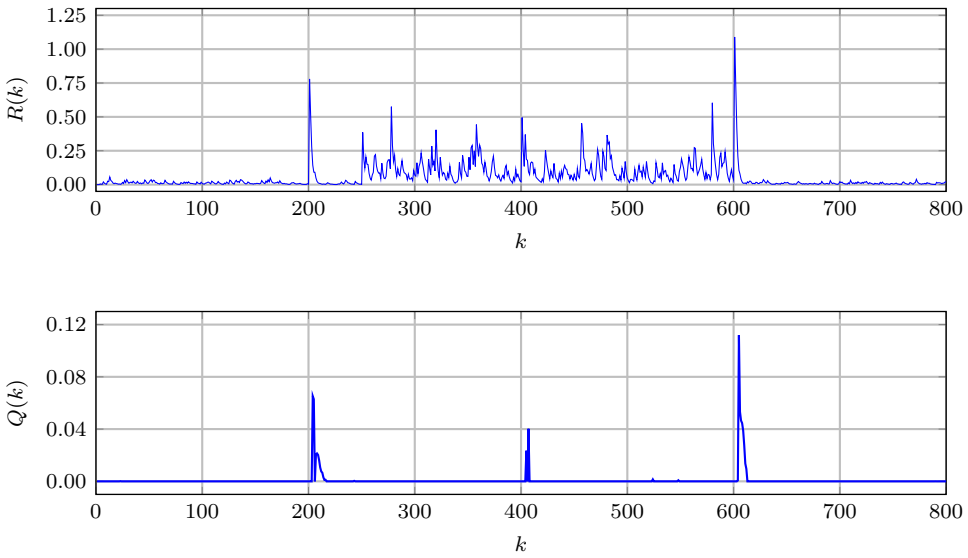
Matlab-Code Teil 2/2

```
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
%%%   R O S E - F I L T E R
%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
for k=1:length(y)
  %-------------------------------------------------------------------------
  % Bestimmung R mit IIR-Filter 1. Ordnung
  %-------------------------------------------------------------------------
  E1  = Alpha_R*y(:,k)          + (1-Alpha_R)*E1;
  EE1 = Alpha_R*y(:,k)*y(:,k)' + (1-Alpha_R)*EE1;
  R   = Faktor_minR*(EE1 - E1*E1');
  %-------------------------------------------------------------------------
  % Bestimmung M mit IIR-Filter 1. Ordnung
  %-------------------------------------------------------------------------
  dy = y(:,k) - x_dach - D*u(k);
  M = Alpha_M.*dy*dy' + (1-Alpha_M).*M;
  %-------------------------------------------------------------------------
  % Bestimmung Q
  %-------------------------------------------------------------------------
  Q(k)= (M - R) - p_tilde;
  if Q(k)<0
      Q(k)=0;
  end;
  %-------------------------------------------------------------------------
  % Kalman Gleichungen
  %-------------------------------------------------------------------------
  p_dach = Ad*p_tilde*Ad' + Q(k);
  K = p_dach*C'*pinv(C*p_dach*C' + R);
  x_tilde = x_dach + K*dy;
  p_tilde = (eye(length(Bd)) - K*C)*p_dach;
  x_dach = Ad*x_tilde + Bd*u(k);
end
```

Folie 5.16

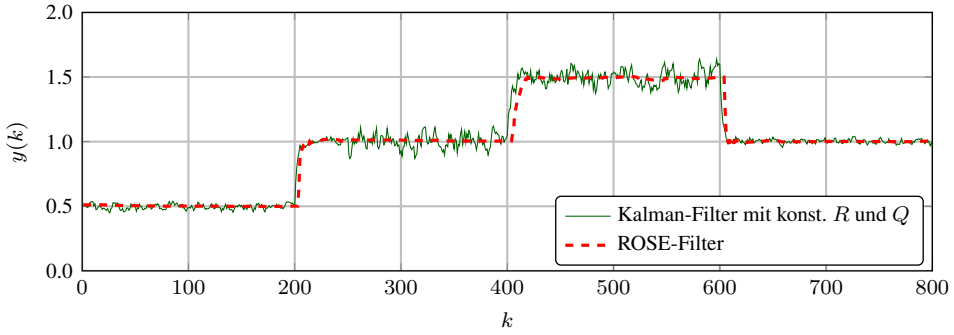


Verlauf der Varianz des Messrauschens $R(k)$ und der des Systemrauschens $Q(k)$



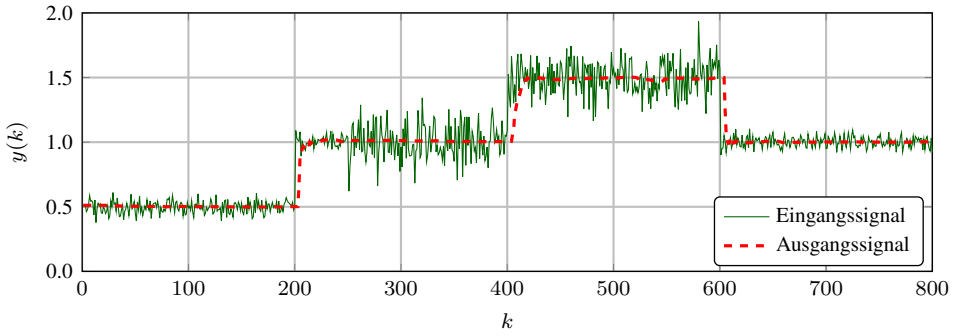
Folie 5.17

Vergleich Kalman-Filter mit festen Werten für R und Q und ROSE-Filter



Folie 5.18

Vergleich Eingangsdaten und ROSE-Filter

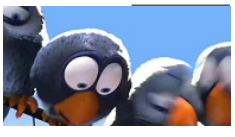


Folie 5.19

Lernkontrolle: ROSE-Filter

- Sie sollten die Idee des *ROSE-Filters* zur Abschätzung der Kovarianz des Mess- und Systemrauschens mittels eines *Alpha-Filters* verstanden haben.
- Sie sollten wissen, was durch die Änderung der Größen α_R *und* α_M geschieht.
- Darüber hinaus sollten Sie die Einführung der Größe *Faktor*$_{minR}$ verstanden haben.

Folie 5.20



Teil VI

Nichtlineare-Filter

9 Spezielle Gauß-Filter

9.1 Extended Kalman-Filter (EKF)

Problemstellung

- Das bisher betrachtete klassische lineare Kalman-Filter gehört auch zur Gruppe d. *Gauß-Filter*. Neben dieses Filters existieren noch viele weitere Filter die im Folgenden kurz angesprochen werden.
- Das bisher betrachtete *klassische lineare Kalman-Filter* wurde durch die folgende lineare Zustandsraumbeschreibung modelliert:

$$\begin{aligned}\underline{x}(k+1) &= \underline{A}\cdot\underline{x}(k) + \underline{B}\cdot\underline{u}(k) + \underline{G}\cdot\underline{z}(k)\\ \underline{y}(k) &= \underline{C}\cdot\underline{x}(k) + \underline{D}\cdot\underline{u}(k) + \underline{v}(k)\end{aligned}$$

- Bei einigen Problemstellung, wird das System durch *nichtlineare Differentialgleichungen* beschrieben. Hierdurch geht die Systembeschreibung über in:

$$\begin{aligned}\underline{x}(k+1) &= \underline{f}\left(\underline{x}(k),\underline{u}(k)\right) + \underline{G}\cdot\underline{z}(k)\\ \underline{y}(k) &= \underline{h}\left(\underline{x}(k),\underline{u}(k)\right) + \underline{v}(k)\end{aligned}$$

  Beschrieben durch die beiden nichtlineare Funktionen $\underline{f}\left(\underline{x}(k),\underline{u}(k)\right)$ und $\underline{h}\left(\underline{x}(k),\underline{u}(k)\right)$.
- Zu solchen nichtlinearen Funktionen zählen z. B. alle *trigonometrischen* Funktionen, *Expotential*-Funktionen oder Funktionen *höherer Ordnung*.

Folie 6.4

Filtergleichungen EKF

- Prädiktion:

$$\hat{\underline{x}}(k+1) = \underline{f}\left(\tilde{\underline{x}}(k),\underline{u}(k)\right) \tag{103}$$

$$\hat{\underline{P}}(k+1) = \underline{A}_J\cdot\tilde{\underline{P}}(k)\cdot\underline{A}_J^T + \underline{G}_d\cdot\underline{Q}(k)\cdot\underline{G}_d^T \quad \text{mit } \underline{Q}(k) = \mathrm{Var}\big(\underline{z}(k)\big) \tag{104}$$

- Korrektur:

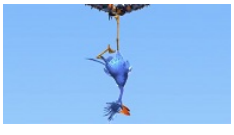
$$\underline{K}(k) = \hat{\underline{P}}(k)\cdot\underline{C}_J^T\cdot\left(\underline{C}_J\cdot\hat{\underline{P}}(k)\cdot\underline{C}_J^T + \underline{R}(k)\right)^{-1} \quad \text{mit } \underline{R}(k) = \mathrm{Var}\big(\underline{v}(k)\big) \tag{105}$$

$$\tilde{\underline{x}}(k) = \hat{\underline{x}}(k) + \underline{K}(k)\cdot\left(\underline{y}(k) - \underline{h}\left(\hat{\underline{x}}(k),\underline{u}(k)\right)\right) \tag{106}$$

$$\tilde{\underline{P}}(k) = \left(\underline{I} - \underline{K}(k)\cdot\underline{C}_J\right)\cdot\hat{\underline{P}}(k) \tag{107}$$

- $\underline{A}_J$ und $\underline{C}_J$ sind die Jacobi-Matrizen von $\underline{A}_d$ und $\underline{C}$
- $\underline{A}_J = \begin{bmatrix}\frac{\partial \underline{f}}{\partial\tilde{x}_1} & \cdots & \frac{\partial \underline{f}}{\partial\tilde{x}_n}\end{bmatrix} = \begin{bmatrix}\frac{\partial\,\underline{f}(1)}{\partial\tilde{x}_1} & \cdots & \frac{\partial\,\underline{f}(1)}{\partial\tilde{x}_n}\\ \vdots & \ddots & \vdots\\ \frac{\partial\,\underline{f}(n)}{\partial\tilde{x}_1} & \cdots & \frac{\partial\,\underline{f}(n)}{\partial\tilde{x}_n}\end{bmatrix}$

Folie 6.5



Beispiel Filtergleichungen EKF

Für ein Kalman-Filter (Gamma-Filter) gilt:

$$\underline{x}(k+1) = \begin{bmatrix} s(k+1) \\ v(k+1) \\ a(k+1) \end{bmatrix} = \underbrace{\begin{bmatrix} s(k) + T_s \cdot v(k) + \frac{T_s^2}{2} \cdot a(k) \\ v(k) + T_s \cdot a(k) \\ a(k) \end{bmatrix}}_{\underline{f}(\underline{\hat{x}}(k))} + \underbrace{\begin{bmatrix} \frac{T_s^2}{2} \\ T_s \\ 1 \end{bmatrix}}_{\underline{G}_d} \cdot z(k)$$

$$\underline{A}_J = \begin{bmatrix} \frac{\partial \underline{f}(1)}{\partial s(k)} & \frac{\partial \underline{f}(1)}{\partial v(k)} & \frac{\partial \underline{f}(1)}{\partial a(k)} \\ \frac{\partial \underline{f}(2)}{\partial s(k)} & \frac{\partial \underline{f}(2)}{\partial v(k)} & \frac{\partial \underline{f}(2)}{\partial a(k)} \\ \frac{\partial \underline{f}(3)}{\partial s(k)} & \frac{\partial \underline{f}(3)}{\partial v(k)} & \frac{\partial \underline{f}(3)}{\partial a(k)} \end{bmatrix} = \begin{bmatrix} 1 & T_s & \frac{T_s^2}{2} \\ 0 & 1 & T_s \\ 0 & 0 & 1 \end{bmatrix}$$

Folie 6.6

Eigenschaften EKF

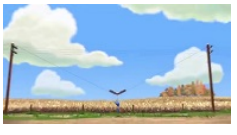
- Das EKF löst das Problem der *Nichtlinearitäten*, indem es die entsprechenden Gleichungen linearisiert.
- Dies geschieht durch eine *Taylor-Reihenentwicklung* um den *letzten Schätzwert*.
- In der Regel wird nach dem *ersten Glied* der Taylor-Reihe *abgebrochen*.
- Modell- und Messungenauigkeiten werden durch *additives Rauschen* modelliert, obwohl viele Rauschgrößen nichtlinear sind.
- Die Berechnungen der *Jacobi-Matrizen* sind sehr *rechenintensiv*.
- Die *Güte* des EKF hängt im Wesentlichen von zwei Faktoren ab:
  1. Der Unsicherheit der Schätzung
  2. Der Größe der lokalen Nichtlinearität
- Für die *Praxis* gilt:
  1. *Abtastzeit* sollte so *klein* als möglich sein, um den Linearitätsfehler gering zu halten.
  2. Der *Initialzustand* muss *gut* gewählt werden, sonst können Konvergenzproblem auftreten.
  3. Aufgrund von *Prädiktionsfehlern* besteht die *Gefahr von Divergenzen*.
  4. Die *Kovarianzen der Schätzfehler* sind *ungenauer* als die beim klassischen Kalman-Filter.

Folie 6.7

9.2 Unscented Kalman Filter (UKF)

Grundidee

- Die *Linearisierung* stellt eine *große Fehlerquelle* beim EKF dar.
- Der Übergang zu einer *Taylor-Reihenentwicklung 2. Ordnung* wäre möglich, dies eröffnet jedoch neue Probleme, z.B. die *Berechnung* von *Hesse-Matrizen*, die bei vielen Systemen *schwierig* ist. Schon die Berechnung der Jacobi-Matrizen erfordert oft (z.B. durch Singularitäten) einen *beträchtlichen Aufwand* und Fallunterscheidungen.
- Der Ansatz ist es anstatt der Taylor-Reihenentwicklung eine *stochastische Linearisierung* durchzuführen.
- In der Literatur wird dieses Verfahren als *Sigma-Punkt-Filter* oder *Unscented Kalman-Filter (UKF)* bezeichnet.



- Prinzipiell sind die Punkte für die Linearisierung beliebig, aber in der Regel werden die *Scheitelpunkte* einer festen *Unsicherheitsellipse* um den *Schätzwert* gewählt, die man als *Sigma-Punkte* bezeichnet.
- Die *Grundidee* besteht also darin nicht die nichtlineare Systemgleichung, sondern die *Wahrscheinlichkeitsdichtefunktion* selbst *zu approximieren*.

Folie 6.9

Vorteile

- Der *Vorteil* des UKF ist, dass er genauso *effizient* ist wie ein *EKF 2. Ordnung*
- Der *Rechenaufwand* beträgt etwa dem eines *EKF 1. Ordnung*
- Bei *stark nichtlinearen* Systemen liefert das UKF *bessere Ergebnisse*.
- Die nicht einfache *Berechnung* der *Jacobi-Matrix entfällt*
- Optimal arbeitet das UKF (und das EKF) bei *normalverteiltem Rauschen*
- Das UKF hat große *Ähnlichkeit* mit dem *Partikel-Filter* und funktioniert für normalverteiltes Rauschen besser
- Bei *nicht normalverteiltem Rauschen* ist das *Partikel-Filter* zu bevorzugen.

Folie 6.10

9.3 Informations-Filter (IF)

Filtergleichungen

- Bei klassischen linearen Kalman-Filtern und bei nichtlinearen Kalman-Filtern EKF und UKF wird das System durch die *Erwartungswerte* und die *Kovarianzen* beschrieben.
- Das Informations-Filter wird stattdessen durch eine *Informations-Matrix* und *Information-Vektor* beschrieben.
- Es gilt: $\underline{\Omega} = \underline{P}^{-1}$ und $\underline{\epsilon} = \underline{P}^{-1} \cdot \underline{x}$
- Mit $\underline{D} = \underline{0}$ gilt für die Prädiktion:

$$\hat{\underline{\Omega}}(k) = \left(\underline{A}_d \cdot \tilde{\underline{\Omega}}(k-1)^{-1} \cdot \underline{A}_d^T + \underline{G}_d \cdot \underline{Q}(k) \cdot \underline{G}_d^T\right)^{-1} \quad \text{mit} \quad \underline{Q}(k) = \mathrm{Var}\left(\underline{z}(k)\right) \tag{108}$$

$$\hat{\underline{\epsilon}}(k) = \hat{\underline{\Omega}} \cdot \left(\underline{A}_d \cdot \tilde{\underline{\Omega}}(k-1)^{-1} \cdot \tilde{\underline{\epsilon}}(k) + \underline{B}_d \cdot \underline{u}(k-1)\right) \tag{109}$$

- Mit $\underline{D} = \underline{0}$ gilt für die Korrektur:

$$\tilde{\underline{\Omega}}(k) = \underline{C}^T \cdot \underline{R}(k)^{-1} \cdot \underline{C} + \hat{\underline{\Omega}}(k) \quad \text{mit} \quad \underline{R}(k) = \mathrm{Var}\left(\underline{v}(k)\right) \tag{110}$$

$$\tilde{\underline{\epsilon}}(k) = \underline{C}^T \cdot \underline{R}(k)^{-1} \cdot \underline{y}(k) + \hat{\underline{\epsilon}}(k) \tag{111}$$

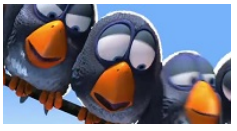
Folie 6.12

9.4 Lernziele

Lernkontrolle: Spezielle Gauß-Filter

- Sie sollten die *Eigenschaften* weiterer Gauß-Filter wie das *EKF*, das *UKF* und das *IF* kennen.
- Darüber hinaus sollten Sie die *Vor- und Nachteile* dieser Filter gegenüber dem *klassischen linearen Kalman-Filter* kennen.

Folie 6.14



10 Partikelfilter (Parameterfreie Filter)

10.1 Algorithmus

Merkmale eines Partikelfilters

- Die Filtergleichungen

$$\underline{x}(k) = f\left(k, \underline{x}(k-1), \underline{u}(k-1)\right) + \underline{G} \cdot \underline{z}(k-1)$$
$$\underline{y}(k) = h\left(k, \underline{x}(k), \underline{u}(k)\right) + \underline{v}(k)$$

  Beschrieben durch die beiden nichtlineare Funktionen $f\left(k, \underline{x}(k), \underline{u}(k)\right)$ und $h\left(k, \underline{x}(k), \underline{u}(k)\right)$ werden mit Hilfe einer *Monte-Carlo-Analyse* gelöst.
- Somit können *beliebige Gleichungen* mit beliebig *verteiltem Prozess- und Messrauschen* modelliert werden
- Bezugnehmend auf das *Alpha-Filter*, bei dem

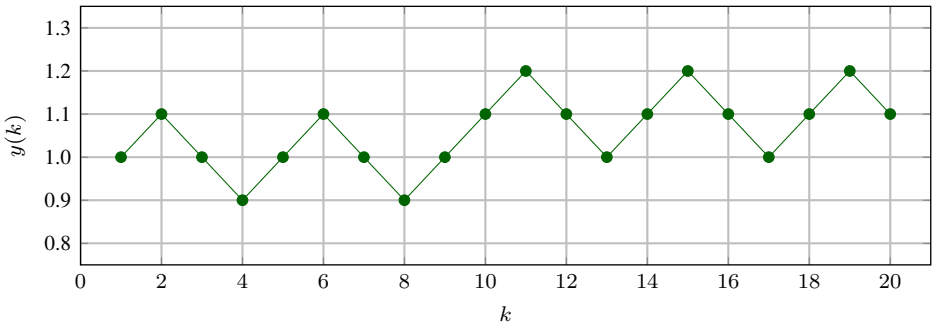
$$\hat{\underline{x}}(k+1) = \tilde{x}(k) + z(k)$$
$$y(k) = \hat{x}(k) + v(k)$$

  ist, wird diese beiden Gleichungen bei einem Partikelfilter mit N Partikel durch den folgenden MATLAB-Code beschrieben:

```
for i = 1:N
    x_P_dach(i) = x_P_tilde(k-1,i) + sqrt(Q)*randn;
    y_dach(i) = x_P_dach(i);
end
```

Folie 6.18

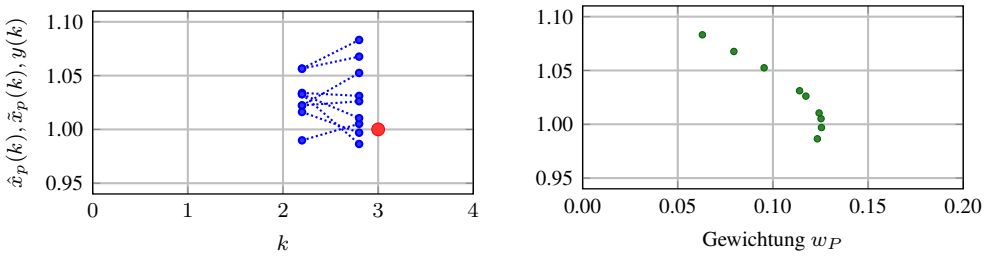
Beispielsequenz



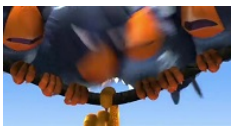
- Die Kovarianz des Messrauschens beträgt: $R \approx \frac{1}{2} \cdot 0.1^2$
- Die Kovarianz des Systemrauschens $Q \approx \frac{1}{20} \cdot 0.1^2$

Folie 6.19

Prädiktion und Gewichtung



- Im Anschluss wird die *Differenz* (Error) jedes der N prädizierten Partikel $\hat{x}_P$ mit der *vorliegenden Messung* $y(k)$ bestimmt



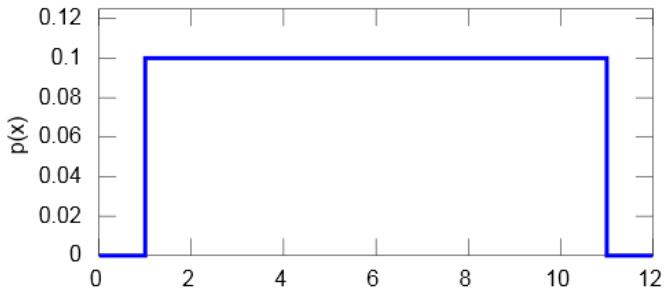
- Mit Hilfe einer *Gewichtungsfunktion* (z.B. der Normalverteilung) wird jedem Partikel in Abhängigkeit der Differenz ein *Gewichtungswert* w_P zugewiesen, sodass die *Summe der Gewichtungswerte* $\sum w_P = 1$ ist.
- Bei dem beschriebenen Beispiel lautet der MATLAB-Code:

```
for i = 1:N
    x_P_dach(i) = x_P_tilde(k-1,i) + sqrt(Q)*randn;
    y_dach(i) = x_P_dach(i);
    error = y(k) - y_dach(i);
    w_P(i) = (1/sqrt(2*pi*R)) * exp(-error^2/(2*R));
end
w_P = w_P./sum(w_P);
```

Folie 6.20

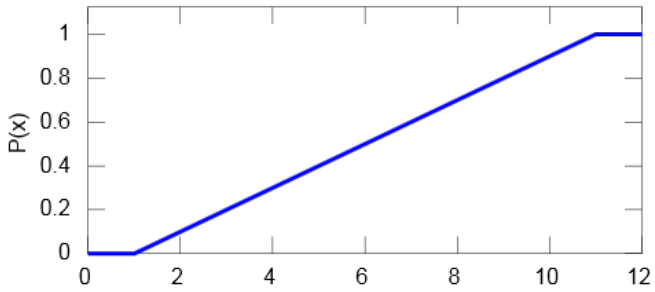
Hintergrund: Resampling I

- Wahrscheinlichkeitsdichte einer Gleichverteilung



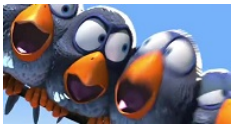
Quelle: Feqyver [6]

- Verteilungsfunktion einer Gleichverteilung



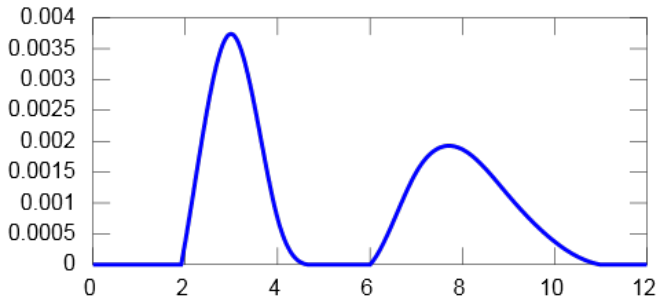
Quelle: Feqyver [6]

Folie 6.21



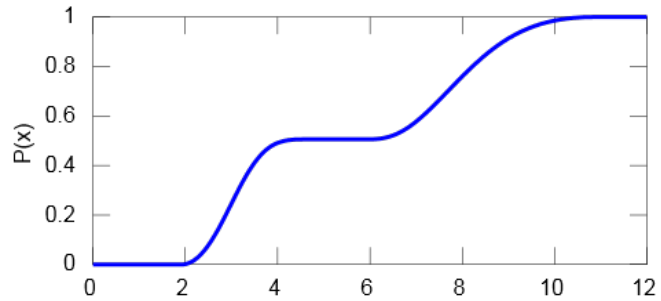
Hintergrund: Resampling II

- Wahrscheinlichkeitsdichte



Quelle: Feqyver [6]

- Verteilungsfunktion

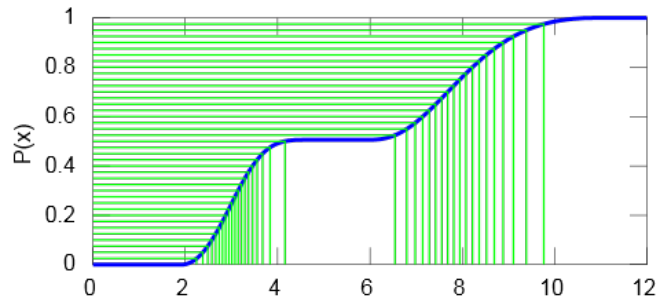


Quelle: Feqyver [6]

Folie 6.22

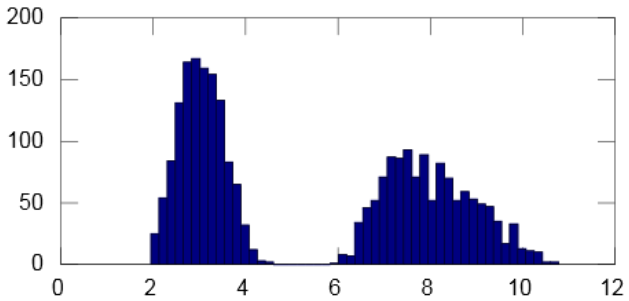
Hintergrund: Resampling III

- Projektion mithilfe einer Gleichverteilung



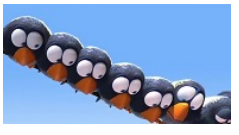
Quelle: Feqyver [6]

- Histogramm



Quelle: Feqyver [6]

Folie 6.23



Resampling

- In Abhängigkeit der Gewichtungen wird eine *neue Verteilung* erstellt.
- Ein Partikel mit *hoher Gewichtung* wird dupliziert.
- Ein Partikel mit *niedriger Gewichtung* wird gelöscht.
- Die Schätzung des *unbekannten Werts* $\tilde{x}(k)$ geschieht über ein *gewichtetes Mittel*.
- Bei dem beschriebenen Beispiel lautet der MATLAB-Code:

```
for i = 1:N
    x_P_dach(i) = x_P_tilde(k-1,i) + sqrt(Q)*randn;
    y_dach(i) = x_P_dach(i);
    error = y(k) - y_dach(i);
    w_P(i) = (1/sqrt(2*pi*R)) * exp(-error^2/(2*R));
end
w_P = w_P./sum(w_P);

%-- Resampling --%
r = -.001/N;
for i = 1:N
    r = r + 1/N;   %r = rand;
    x_P_tilde(k,i) = x_P_dach(find(r <= cumsum(w_P),1));
end
x_tilde(k) = w_P*x_P_dach';
```

Folie 6.24

Kompletter Algorithmus

```
clear all

R = 1/2*0.1^2;
Q = 1/20*0.1^2;
N = 100;

y = [1 1.1 1 .9 1 1.1 1.0 .9 1 1.1 1.2 1.1 1 1.1 1.2 1.1 1 1.1 1.2 1.1];
T = length(y);

x_tilde(1) = 1;
for i = 1:N
  x_P_tilde(1,i) = x_tilde(1) + sqrt(2*Q)*randn;
end

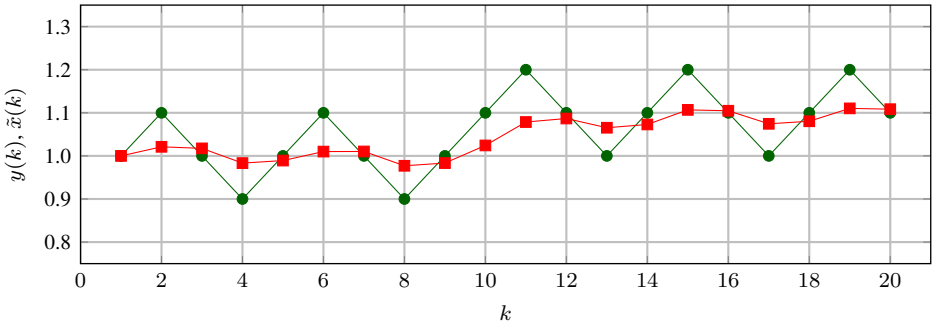
for k = 2:T
  for i = 1:N
    x_P_dach(i) = x_P_tilde(k-1,i) + sqrt(Q)*randn;
    y_dach(i) = x_P_dach(i);
    error = y(k) - y_dach(i);
    w_P(i) = (1/sqrt(2*pi*R)) * exp(-error^2/(2*R));
  end
  w_P = w_P./sum(w_P);

  r = -.001/N;
  for i = 1:N
    r = r + 1/N;
    x_P_tilde(k,i) = x_P_dach(find(r <= cumsum(w_P),1));
  end
  x_tilde(k) = w_P*x_P_dach';
end
```

Folie 6.25



Filterergebnis

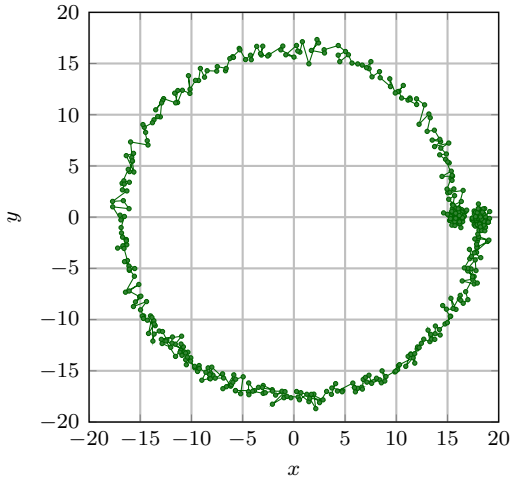


Folie 6.26

10.2 Beispiel: nichtlineare Funktion

Problemstellung

- Messtechnisch ist die Trajektorie eines Fahrzeugs erfassbar
- Das Fahrzeug fährt auf einer unbekannten Kreisbahn.
- Hierbei variiert das Fahrzeug die Geschwindigkeit und durch Lenken den gefahrenen Kurvenradius.



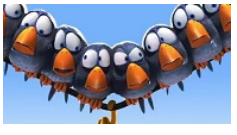
Folie 6.28

Modellierung

- Für die zeitdiskrete Systembeschreibung gilt:

$$\underline{x}(k+1) = \begin{bmatrix} s(k+1) \\ v(k+1) \\ R(k+1) \end{bmatrix} = \begin{bmatrix} 1 & T_s & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} s(k) \\ v(k) \\ R(k) \end{bmatrix} + \begin{bmatrix} T_s & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} z_1(k) \\ z_2(k) \end{bmatrix}$$

$$\underline{y}(k) = \begin{bmatrix} R(k) \cdot \sin\left(\frac{s(k)}{R(k)}\right) \\ R(k) \cdot \cos\left(\frac{s(k)}{R(k)}\right) \end{bmatrix} + \begin{bmatrix} v_1(k) \\ v_2(k) \end{bmatrix}$$



- Ausgeschrieben gilt somit:

$$
\begin{aligned}
s(k+1) &= s(k) + T_s \cdot (v(k) + z_1(k)) \\
v(k+1) &= v(k) + z_1(k) \\
R(k+1) &= R(k) + z_2(k)
\end{aligned}
$$

$$
\begin{aligned}
y_1(k) &= R(k) \cdot \sin\left(\frac{s(k)}{R(k)}\right) + v_1(k) \\
y_2(k) &= R(k) \cdot \cos\left(\frac{s(k)}{R(k)}\right) + v_2(k)
\end{aligned}
$$

Folie 6.29

Kompletter Algorithmus (Teil 1: Initialisierung)

```
R  = 0.3;
Q1 = 1.0e-1;
Q2 = 5.0e-4;
N  = 400;
Ts = 0.1;

load -ascii data2_in_t_y_s_v_a.dat;
y = data2_in_t_y_s_v_a(:,2:3)';  clear data2_in_t_y_s_v_a;
T = length(y);

s_tilde(1) = y(1,1);
v_tilde(1) = 0;
Radius_tilde(1) = sqrt(y(1,1)^2+y(2,1)^2);
for i = 1:N
    z1 = sqrt(10*Q1)*randn; %(2*rand-1);
    z2 = sqrt(100*Q2)*randn;
    s_P_tilde(1,i) = s_tilde(1) + Ts*z1;
    v_P_tilde(1,i) = v_tilde(1) + z1;
    Radius_P_tilde(1,i) = Radius_tilde(1) + z2;
end
```

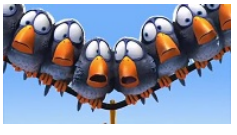
Folie 6.30

Kompletter Algorithmus (Teil 2: Hauptroutine)

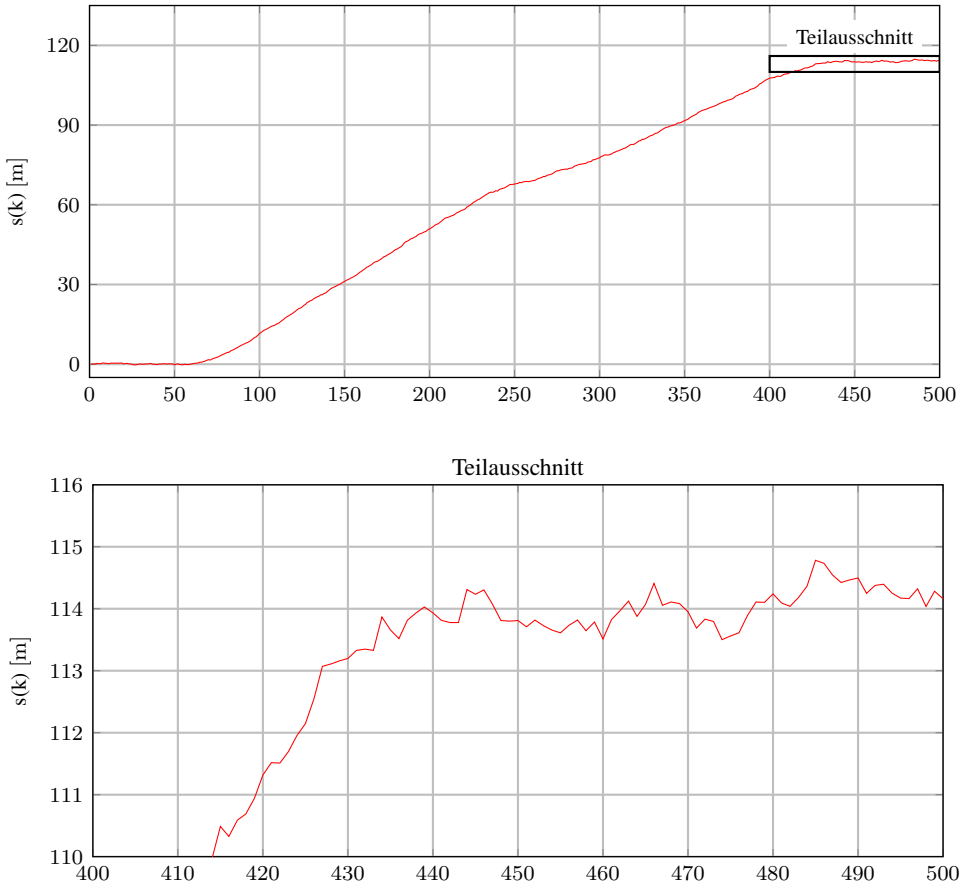
```
for t = 2:T
    for i = 1:N
       z1 = sqrt(Q1)*randn;
       s_P_dach(i) = s_P_tilde(t-1,i) + Ts*(v_P_tilde(t-1,i) + z1);
       v_P_dach(i) = v_P_tilde(t-1,i) + z1;
       z2 = sqrt(Q2)*randn;
       Radius_P_dach(i) = Radius_P_tilde(t-1,i) + z2;
       y1_dach(i) = Radius_P_dach(i)*sin(s_P_dach(i)/Radius_P_dach(i));
       y2_dach(i) = Radius_P_dach(i)*cos(s_P_dach(i)/Radius_P_dach(i));
       error = sqrt((y(1,t)-y1_dach(i))^2 + (y(2,t)-y2_dach(i))^2);
       w_P(i) = (1/sqrt(2*pi*R)) * exp(-(error)^2/(2*R));
    end
    w_P = w_P./sum(w_P);

    r = -.001/N;
    for i = 1:N
       r = r + 1/N; %r = rand;
       s_P_tilde(t,i) = s_P_dach(find(r <= cumsum(w_P),1));
       v_P_tilde(t,i) = v_P_dach(find(r <= cumsum(w_P),1));
       Radius_P_tilde(t,i) = Radius_P_dach(find(r <= cumsum(w_P),1));
    end
    s_tilde(t) = w_P*s_P_dach';
    v_tilde(t) = w_P*v_P_dach';
    Radius_tilde(t) = w_P*Radius_P_dach';
end
```

Folie 6.31

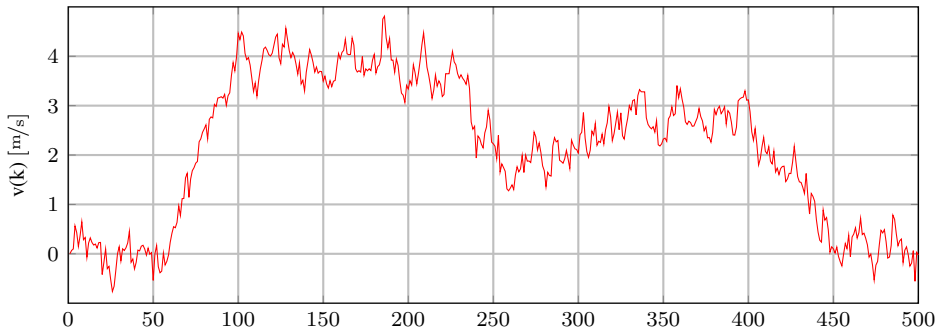


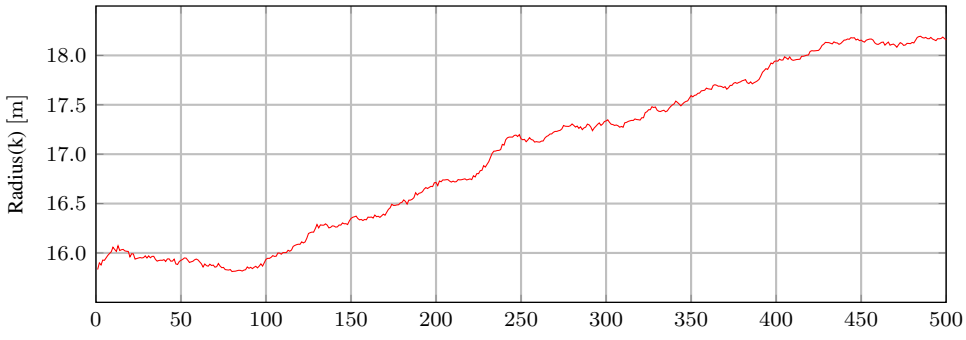
Geschätzte Zustandsgröße Weg $\tilde{x_1}$



Folie 6.32

Geschätzte Zustandsgröße Geschwindigkeit $\tilde{x}_2$ und Beschleunigung $\tilde{x}_3$

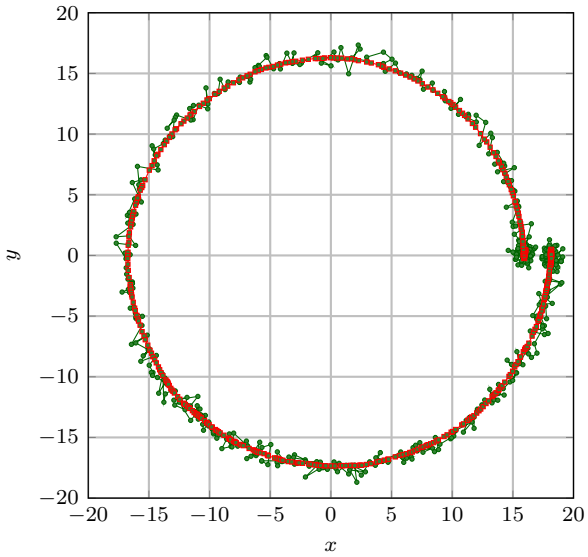




Folie 6.33

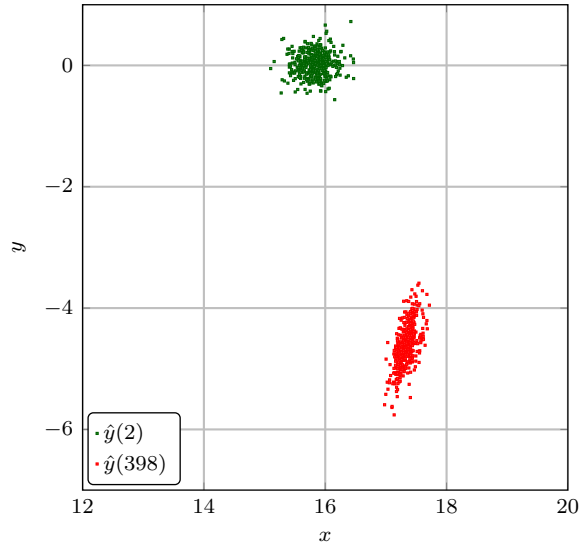


Filterergebnis



Folie 6.34

Verteilung der Partikel über der Zeit



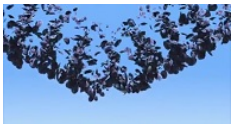
Folie 6.35

10.3 Lernziele

Lernkontrolle: Partikelfilter

- Sie sollten die Idee des *Partikel-Filters* zur Berechnung der Differentialgleichung mittels einer *Monte-Carlo-Analyse* (Partikel) verstanden haben und in der Lage sein *beliebige* Gleichungen mittels eines Partikel-Filters zu modellieren.
- Sie sollten die *Gewichtung* der Partikel verstanden haben und diese mittels *geeigneter Gewichtungsfunktion* durchführen können.
- Darüber hinaus sollten Sie den Mechanismus zur Erzeugung neuer Partikel (*Resampling*) nachvollziehen können.
- Ebenso sollten Sie verstanden haben wie man durch eine geeignete Funktion (*gewichtetes Mittel*) aus den einzelnen Partikeln die *unbekannten Größen abschätzt*.

Folie 6.37



Teil VII

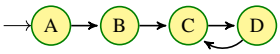
Markov-Ketten

11 Grundlagen

11.1 Deterministischer Automat

Definitionen und Darstellungsformen

- In der Automatentheorie wird das Verhalten eines Systems durch die Beschreibung der *Zustände*, in dem das System sich befinden kann modelliert.
- Im Gegensatz zur Zustandsraumbeschreibung, kann hier jeder Zustand nur den den Wert *„aktiv“* (1) oder *„inaktiv“*(0) annehmen.
- Die Modellierung geschieht grafisch mithilfe eines Automatengrafen:



- Der aktive Zustand, in welchem sich der Automat (System) gerade befindet, wird durch einen *Zustandsvektor* $\underline{z}(k)$ beschrieben.
  Für das Beispiel gilt: $\underline{z}(0) = \begin{bmatrix} 1 & 0 & 0 & 0 \end{bmatrix}^T$
- Das dynamische Verhalten wird durch die folgende Gleichung beschrieben:

$$\underline{z}(k+1) = \underline{E} \cdot \underline{z}(k) \tag{112}$$

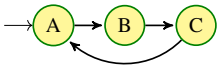
.

Mit $\underline{E}$: $\underline{z}(1) = \begin{bmatrix} & & & \\ & & & \\ & & & \\ & & & \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$

Folie 7.4

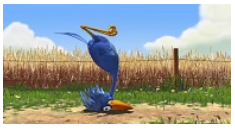
Beispiel Automaten I

- Gegeben ist der folgende Automat:



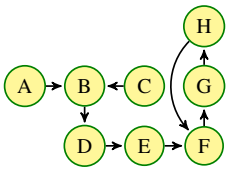
- Bestimmen Sie zum Zeitpunkt $k = 5$ den Zustandsvektor $\underline{z}(5)$

Folie 7.5



Beispiel Automaten II

- Bestimmen Sie die Matrix $\underline{E}$:



- Bestimmen Sie den Automatengrafen:

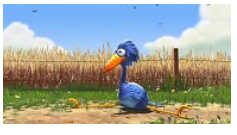
$$\underline{E} = \begin{array}{c} \\ A \\ B \\ C \\ D \\ E \\ F \end{array} \begin{array}{c} \begin{array}{cccccc} A & B & C & D & E & F \end{array} \\ \begin{pmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix} \end{array}$$

Folie 7.6

Fragen: Automaten

1. Was ist der Hauptunterschied bei der Beschreibung eines Systems im Zustandsraum gegenüber der Beschreibung eines Automaten?
2. Was ist bei der Beschreibung eines Systems im Zustandsraum und der Beschreibung eines Automaten gleich?

Folie 7.7



11.2 Bedingte Wahrscheinlichkeit

Bedingte Wahrscheinlichkeit: Einführendes Beispiel

- In einer Fertigung gibt es zwei Fehler
- Ereignis A bezeichnet das Auftreten des Fehlers F_A.
- Ereignis B bezeichnet das Auftreten des Fehlers F_B.
- Es werden 50 fehlerhafte Teile untersucht.
- Bei 35 Teilen wird der Fehler F_A festgestellt.
- Bei 25 Teilen wird der Fehler F_B festgestellt.
- Hinweis: Es gilt $P(A \cap B) = P(A) + P(B) - P(A \cup B)$

Wie viel der untersuchten Teile ist der Fehler F_A und F_B aufgetreten?

Wie groß ist d. Wahrscheinlichkeit, dass bei d. untersuchten Teil d. Fehler F_A festgestellt wurde, wenn wir wissen, dass dieses Teil den Fehler F_B hat?

Folie 7.9

Bedingte Wahrscheinlichkeit: Definition

Bedingte Wahrscheinlichkeit: $$P(A|B) = \frac{P(A \wedge B)}{P(B)} \quad \text{für } P(B) \neq 0$$

Wahrscheinlichkeit für das Eintreten von A, wenn B bereits eingetreten ist.

Mit Zufallsvariablen schreibt man:

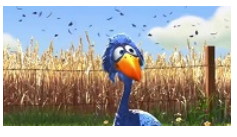
$$P(X=x_i|Y=y_j) = \frac{P(X=x_i, Y=y_j)}{P(Y=y_j)} \quad \text{für } P(Y=y_j) \neq 0$$

Des Weiteren gilt:

$$P(\Omega) = P(X \times Y) = \sum_i \sum_j P(X=x_i, Y=y_j) = 1$$

$$\sum_i P(X=x_i|Y=y_j) = 1 \quad \text{bzw.} \quad \sum_j P(Y=y_j|X=x_i) = 1$$

Folie 7.10

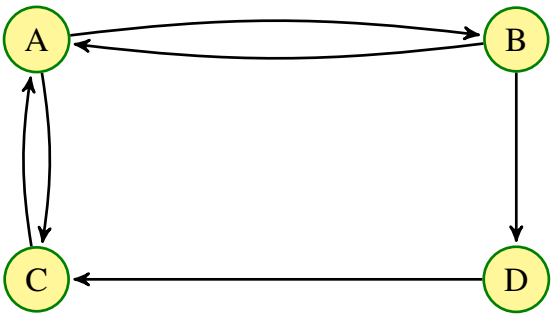


12 Markov-Kette (Nichtdeterministischer Automat)

12.1 Zeitdiskrete Markov-Kette

Stochastischer Prozess

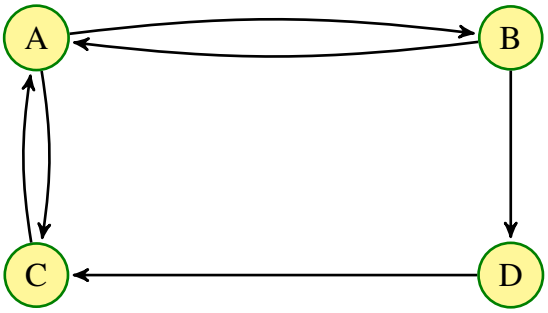
- Bei der diskreten Markov-Kette wird jedem *Zustand* eine *Wahrscheinlichkeit zugewiesen*.
- So befindet sich z. B. ein System mit der Wahrscheinlichkeit: $P\left(z(k) = A\right)$ im Zustand A.
- Man spricht in diesem Zusammenhang von einem *stochastischen Prozess*



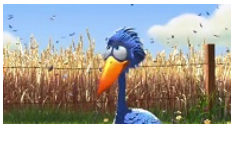
Folie 7.12

Stochastischer Automat

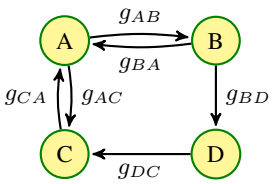
- Die *Transitionen* werden mithilfe von *bedingten Wahrscheinlichkeit* beschrieben.
- So wechselt eine Markov-Kette (Automat/System), unter der Bedingung es befindet sich im Zustand A, in den Zustand B mit der Wahrscheinlichkeit: $P(z(k+1)=B\,|\,z(k)=A)$
- Man spricht dann von einem *stochastischen Automaten*



Folie 7.13



Dynamisches Verhalten (Chapman-Kolmogorov-Gleichung)



$$
\begin{aligned}
g_{AB} &= P(z(k+1)=B \,|\, z(k)=A) \\
g_{AC} &= P(z(k+1)=C \,|\, z(k)=A) \\
g_{BD} &= P(z(k+1)=D \,|\, z(k)=B) \\
g_{BA} &= P(z(k+1)=A \,|\, z(k)=B) \\
g_{CA} &= P(z(k+1)=A \,|\, z(k)=C) \\
g_{DC} &= P(z(k+1)=C \,|\, z(k)=D)
\end{aligned}
$$

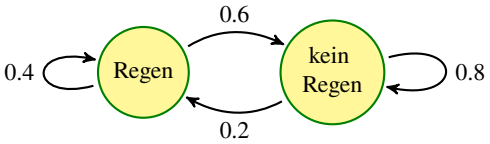
- Das *dynamische Verhalten* wird allgemein beschrieben durch

$$\underline{p}(k+1) = \underline{\underline{H}}_d \cdot \underline{p}(k) \tag{113}$$

- Mit $\sum_i P(z(k+1)=z_i \mid z(k)=z_j)=1$ folgt:
  $g_{AB}+g_{AC}=1, \quad g_{BA}+g_{BD}=1, \quad g_{CA}=1, \quad g_{DC}=1$
- Somit folgt für die Übergangsmatrix $\underline{\underline{H}}_d$:

Folie 7.14

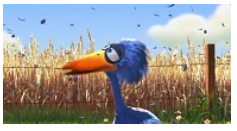
Beispiel: Regenvorhersage



Mit welcher Wahrscheinlichkeit regnet es in zwei Tagen (k=2 Zyklen), wenn:

1. es heute regnet ($\underline{p}(0) = [1,0]^T$)
2. es heute nicht regnet ($\underline{p}(0) = [0,1]^T$)?

Folie 7.15



Stationäre Verteilung

- *Konvergiert* die Größe $\underline{p}(k)$ einer Markov-Kette gegen bestimmte Werte, so lässt sich diese *stationäre Verteilung* berechnen
- Es gilt: $\underline{p}(k+1) = \underline{\underline{H}}_d \cdot \underline{p}(k) \quad \Rightarrow \quad \underline{\overline{p}} = \underline{\underline{H}}_d \cdot \underline{\overline{p}}$
- Es folgt: $\boxed{(\underline{\underline{H}}_d - \underline{\underline{I}}) \cdot \underline{\overline{p}} = \underline{0} \quad \text{mit:} \quad \sum_{i=1}^{N} \overline{p}_i = 1}$
- Für das Beispiel mit der Regenvorhersage folgt:

$$(\underline{\underline{H}}_d - \underline{\underline{I}}) \cdot \underline{\overline{p}} = \left(\begin{bmatrix} 0.4 & 0.2 \\ 0.6 & 0.8 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right) \cdot \begin{bmatrix} \overline{p}_1 \\ \overline{p}_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$-0.6\overline{p}_1 + 0.2\overline{p}_2 = 0 \tag{114}$$
$$0.6\overline{p}_1 - 0.2\overline{p}_2 = 0 \tag{115}$$
$$\overline{p}_1 + \overline{p}_2 = 1 \tag{116}$$
$$\overline{p}_1 = 1 - \overline{p}_2 \tag{117}$$

(117) in (114): $0.6\overline{p}_1 - 0.2(1 - \overline{p}_1) = 0.6\overline{p}_1 - 0.2 + 0.2\overline{p}_1) = 0.8\overline{p}_1 - 0.2 = 0$

$$\overline{p}_1 = \frac{0.2}{0.8} = \underline{\underline{\mathbf{25}\%}} \tag{118}$$

(118) in (116): $0.25 + \overline{p}_2 = 1 \quad \Rightarrow \quad \overline{p}_2 = 1 - 0.25 = \underline{\underline{\mathbf{75}\%}}$

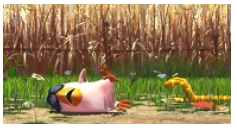
Folie 7.16

12.2 Zeitkontinuierliche Markov-Kette

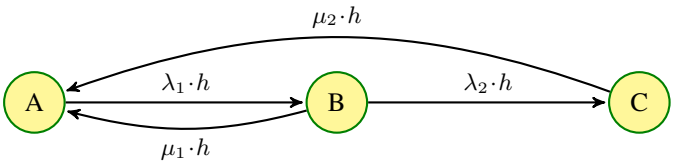
Beispiel Roboter: Problematik

- In einer Fertigung wird *ein autonom fahrender, batteriebetriebener Roboter* eingesetzt.
- Dieser erkennt automatisch, wenn sich der Ladezustand seiner Akkubatterie in einen kritischen Zustand fällt und fährt dann selbstständig zur Ladestation.
- Die *mittlere Betriebsdauer* des Roboters, bis der Akku wieder geladen werden muss, beträgt 60 min. λ_1 **= 1 pro h**.
- Die *mittlere Ladezeit* des Roboters in der Ladestation ist 30 min. μ_1 **= 2 pro h**.
- *Alle 10 Stunden* wird der Roboter (nachdem er aufgeladen wurde) *gewartet*.
- Somit beträgt die mittlere Dauer bis der Roboter gewartet werden muss 600 min. λ_2 **= 0.1 pro h**.
- Die *mittlere Wartungsdauer* des Roboters beträgt 30 min. μ_2 **= 2 pro h**.
- Der Verhalten lässt sich mit den folgenden drei Zuständen beschreiben:
  - A) *Ladestation* ist *leer* und der *Roboter arbeitet*.
  - B) *Ladestation* ist *besetzt* und der *Roboter wird geladen*.
  - C) *Roboter* wird *gewartet*.

Folie 7.18



Beispiel Roboter: Automatengraf und Differentialgleichungen



Aus dieser Markov-Kette ergeben sich die folgenden 3 Differentialgleichungen:

$$P_A(t+h) = P_A(t) - \lambda_1 \cdot h \cdot P_A(t) + \mu_1 \cdot h \cdot P_B(t) + h \cdot \mu_2 \cdot P_C(t)$$

$$\frac{P_A(t+h) - P_A(t)}{h} = -\lambda_1 \cdot P_A(t) + \mu_1 \cdot P_B(t) + \mu_2 \cdot P_C(t)$$

$$\dot{P}_A(t) = -\lambda_1 \cdot P_A(t) + \mu_1 \cdot P_B(t) + \mu_2 \cdot P_C(t)$$

$$\dot{P}_B(t) = -(\lambda_2 + \mu_1) \cdot P_B(t) + \lambda_1 \cdot P_A(t)$$

$$\dot{P}_C(t) = -\mu_2 \cdot P_C(t) + \lambda_2 \cdot P_B(t)$$

$$\begin{bmatrix} \dot{P}_A(t) \\ \dot{P}_B(t) \\ \dot{P}_C(t) \end{bmatrix} = \begin{bmatrix} -\lambda_1 & \mu_1 & \mu_2 \\ \lambda_1 & -\lambda_2 - \mu_1 & 0 \\ 0 & \lambda_2 & -\mu_2 \end{bmatrix} \cdot \begin{bmatrix} P_A(t) \\ P_B(t) \\ P_C(t) \end{bmatrix}$$

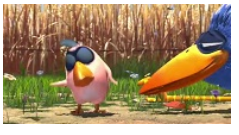
$$\boxed{\underline{\dot{p}}(t) = \underline{\underline{H}} \cdot \underline{p}(t)}$$

Folie 7.19

Beispiel ECU: Problematik

- Ein Rechner (ECU) liest die Werte *dreier Sensoren* ein.
- *Ankunftsrate*: Ein Sensor sendet im Mittel $\lambda = 2^{\text{Werte}}/_{\text{s}}$ an die ECU.
- *Bedienrate*: Die ECU kann $\mu = 10^{\text{Werte}}/_{\text{s}}$ einlesen.
- Möchte z. B. ein Sensor (II) einen Wert senden, während die ECU mit dem Einlesen eines Sensorwerts (I) *beschäftigt* ist, so *unterbricht* die ECU das Einlesen des aktuellen Sensors (I) und liest zuerst den Sensor (II) ein. Sobald dieser eingelesen wurde, *startet* sie mit dem Einlesen des während des Einlesens unterbrochenen Sensors (I) *erneut*.
- Prinzipiell ist es möglich, dass die ECU während er Sensor (II) ausliest von einem dritten Sensor (III) *erneut unterbrochen wird*. In diesem Fall unterbricht der Rechner das Auslesen des aktuellen Sensors (II) nicht erneut, sondern *ignoriert* diesen Interrupt des Sensors (III). Der Sensorwert des Sensors (III) geht verloren.
- 1. Der Zustand 0 beschreibt den Zustand, dass die ECU gerade *keine Sensorwerte* einlesen muss.
  2. Der Zustand 1 beschreibt den Zustand, dass die ECU im Augenblick Werte von *einem Sensor* einliest.
  3. Der Zustand 2 beschreibt, dass die ECU im Augenblick Werte von einem *zweiten Sensor einliest* und beim Auslesen eines Sensors kurz vorher *unterbrochen* wurde.
  4. Der Zustand 3 beschreibt, dass die ECU im Augenblick Werte von einem *zweiten Sensor* einliest, beim Auslesen eines Sensors kurz vorher unterbrochen wurde und den Interrupt des *dritten Sensors* gerade *ignoriert*.

Folie 7.20



Beispiel ECU: Automatengraf

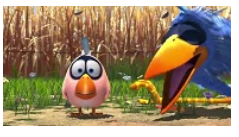
Modellieren Sie das beschriebene Verhalten der ECU indem Sie den Automatengraf zeichnen!

Folie 7.21

Beispiel ECU: Differentialgleichungen

Leiten Sie aus dem Automatengrafen die vier Differentialgleichungen her, die diese Markov-Kette beschreiben.

Folie 7.22



Zusammenfassung Markov-Kette

- Allgemein wird eine *zeitkontinuierliche Markov-Kette* beschrieben mit:

$$\dot{\underline{p}}(t) = \underline{H} \cdot \underline{p}(t) \tag{119}$$

- Allgemein wird eine *zeitdiskrete Markov-Kette* beschrieben mit:

$$\underline{p}(k+1) = \underline{H}_d \cdot \underline{p}(k) \tag{120}$$

Markov Prozess: $\underline{p}(0) \xrightarrow{\underline{H}_d} \underline{p}(1) \xrightarrow{\underline{H}_d} \underline{p}(2) \xrightarrow{\underline{H}_d} \cdots \xrightarrow{\underline{H}_d} \underline{p}(T+1)$

- Die *Umrechnung* der beiden Matrizen geschieht mit:

$$\underline{H}_d = e^{\underline{H} \cdot T_s} \tag{121}$$

Folie 7.23

12.3 Lernziele

Lernkontrolle: Markov-Ketten

- Sie sollten die Beschreibung von *zeitdiskreten* und *zeitkontinuierlichen Markov-Ketten* kennen.
- Sie sollten in der Lage sein auf Basis einer *Problembeschreibung* eine *zeitdiskrete* und *zeitkontinuierliche Markov-Kette* aufzustellen.
- Sie sollten verstanden haben, für welche Problemstellung es *einfacher* ist eine Beschreibung einer *zeitdiskreten* bzw. *zeitkontinuierlichen Markov-Kette* zu erstellen.
- Darüber hinaus sollten Sie in der Lage sein eine *zeitdiskrete* in eine *zeitkontinuierliche Markov-Kette* (bzw. auch umgekehrt) umzurechnen.

Folie 7.25

13 Hidden-Markov-Kette (Hidden-Markov-Modell)

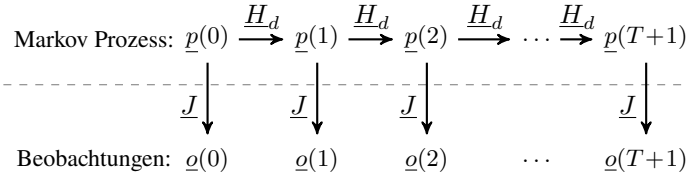
13.1 Allgemeines

Definitionen und Darstellungsformen

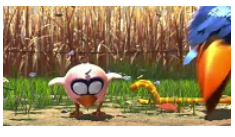
- Eine *Hidden-Markov-Kette* (Hidden-Markov-Modell) besitzt wie eine Markov-Kette *Zustände* z denen eine Wahrscheinlichkeit *P(z(k))* zugeordnet ist.
- Diese *Zustände* z sind jedoch *verborgen* und somit nicht sichtbar.
- *Beobachtbar* sind nur die *Zustände* y, denen die Wahrscheinlichkeit *P(y(k))* zugeordnet ist.
- Allgemein wird eine *zeitdiskrete Hidden-Markov-Kette* beschrieben mit:

$$\underline{p}(k+1) = \underline{H}_d \cdot \underline{p}(k) \tag{122}$$

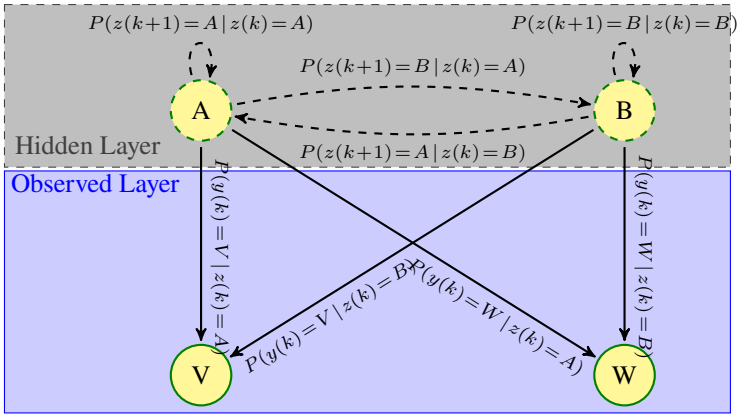
$$\underline{o}(k) = \underline{J} \cdot \underline{p}(k) \tag{123}$$



Folie 7.27



Beispielhafter Aufbau einer Hidden-Markov-Kette



$$\underline{H}_d = \begin{bmatrix} P(z(k+1)=A\,|\,z(k)=A) & P(z(k+1)=A\,|\,z(k)=B) \\ P(z(k+1)=B\,|\,z(k)=A) & P(z(k+1)=B\,|\,z(k)=B) \end{bmatrix}$$

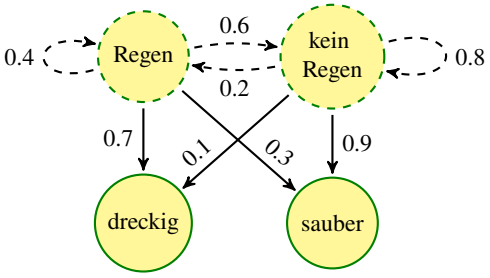
$$\underline{J} = \begin{bmatrix} P(y(k)=V\,|\,z(k)=A) & P(y(k)=V\,|\,z(k)=B) \\ P(y(k)=W\,|\,z(k)=A) & P(y(k)=W\,|\,z(k)=B) \end{bmatrix}$$

Folie 7.28

13.2 Schätzung der unbekannten Zustände

Beispiel: Regenvorhersage

- Ein Gefangener sieht nur die Schuhe der Wachen.
- Die Schuhe sind entweder *„dreckig“* oder *„sauber“*
- Das Wetter kann er nicht beobachten.
- Das Wetter hat den Zustand A=*„Regen“* bzw. B=*„kein Regen“*.
- Der Anfangszustand lautet: $\underline{p}(0) = \begin{bmatrix} 0.25 & 0.75 \end{bmatrix}^T$
- Der Gefangene beobachtet folgende Sequenz:
  o(1)=„sauber“, o(2)=„sauber“ und o(3)=„dreckig“
- Gesucht ist $P(z(k) = A\,|\,y(k) = o(k))$ und $P(z(k) = B\,|\,y(k) = o(k))$

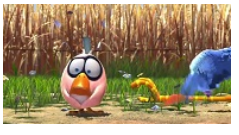


Folie 7.30

Beispiel: Lösungsansatz

- Basierend auf einen *Anfangszustand* $\underline{p}(0)$ wird für *jeden Zeitschritt* k basierend auf jeder *Beobachtung o(k)*
- a) *Korrektur*: $P(z(k)=z_i\,|\,y(k) = o(k))$ berechnet und anschließend
- b) *Prädiktion*: $P(z(k+1)=z_i\,|\,y(k) = o(k))$

Folie 7.31



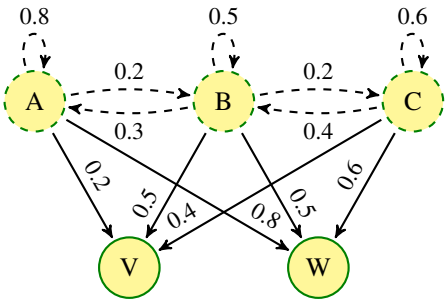
Lösung: Regenvorhersage

	k=0	k=1 o(1)=“sauber“	k=2 o(2)=“sauber“	k=3 o(3)=“dreckig“
$P(z(k)=A\,\|\,y=o(k))$		$0.25 \cdot 0.3 =$ $0.075 \rightarrow 0.10$	$0.22 \cdot 0.3 =$ $0.066 \rightarrow 0.09$	$0.22 \cdot 0.7 =$ $0.154 \rightarrow 0.65$
$P(z(k)=B\,\|\,y=o(k))$		$0.75 \cdot 0.9 =$ $0.675 \rightarrow 0.90$	$0.78 \cdot 0.9 =$ $0.702 \rightarrow 0.91$	$0.78 \cdot 0.1 =$ $0.078 \rightarrow 0.35$
$P(z(k+1)=A\,\|\,y=o(k))$	0.25	$0.10 \cdot 0.4 +$ $0.90 \cdot 0.2 = 0.22$	$0.09 \cdot 0.4 +$ $0.91 \cdot 0.2 = 0.22$	
$P(z(k+1)=B\,\|\,y=o(k))$	0.75	$0.90 \cdot 0.8 +$ $0.10 \cdot 0.6 = 0.78$	$0.91 \cdot 0.8 +$ $0.09 \cdot 0.6 = 0.78$	

Folie 7.32

Übungsbeispiel Hidden-Markov-Kette

- Es wurde die Sequenz $o = \{V, V, W, W\}$ beobachtet.
- Berechnen Sie die $P(z(5) = A\,|\,y(k) = o(k))$ für d. Anfangszustand $\underline{p}(0) = \begin{bmatrix}1 & 0 & 0\end{bmatrix}^T$

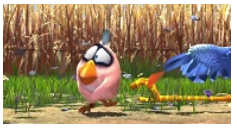


Folie 7.33

Lösung Übungsbeispiel Hidden-Markov-Kette

	k=0	k=1 o(1)=“V“	k=2 o(2)=“V“	k=3 o(3)=“W“	k=4 o(4)=“W“
$P(z(k)=A\,\|\,y=o(k))$					
$P(z(k)=B\,\|\,y=o(k))$					
$P(z(k)=C\,\|\,y=o(k))$					
$P(z(k+1)=A\,\|\,y=o(k))$	1.0				
$P(z(k+1)=B\,\|\,y=o(k))$	0.0				
$P(z(k+1)=C\,\|\,y=o(k))$	0.0				

Folie 7.34



13.3 Ausblick

Weitere typische Fragestellungen

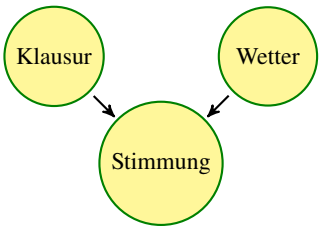
1. Bei einem *gegebenen Hidden-Markov-Modell* $(\underline{H}_d, \underline{J}, \underline{p}(0))$ und einer *Beobachtungssequenz* (o) werden die *unbekannten Zustände* der Markov-Kette *bestmöglich abgeschätzt* (siehe voriges Beispiel).
2. Bei einem *gegebenen Hidden-Markov-Modell* $(\underline{H}_d, \underline{J}, \underline{p}(0))$ und einer *Beobachtungssequenz* (o) wird die *Wahrscheinlichkeit* berechnet, dass diese Sequenz mit diesem Modell erzeugt wurde.
3. *Gegeben* ist eine *Beobachtungssequenz* (o). *Gesucht* wird das *Hidden-Markov-Modell* $(\underline{H}_d, \underline{J}, \underline{p}(0))$ (Baum-Welch-Algorithmus).

Folie 7.36

Bayes Netz

bestanden	durchgefallen
0.9	0.1

Sonne	Regen
0.75	0.25



	gut	schlecht
bestanden, Sonne	0.9	0.1
bestanden, Regen	0.8	0.2
durchgefallen, Sonne	0.3	0.7
durchgefallen, Regen	0.2	0.8

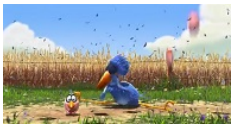
Folie 7.37

13.4 Lernziele

Lernkontrolle: Markov-Ketten

- Sie sollten den Aufbau eines *Hidden-Markov-Modells* $(\underline{H}_d, \underline{J}, \underline{p}(0))$ wiedergeben können.
- Sie sollten in der Lage sein aus einer *gegebenen Beobachtungssequenz* die *Wahrscheinlichkeit* der *unbekannten(verborgenen) Zustände* der Markov-Kette abzuschätzen.

Folie 7.39



Teil VIII

Anhang

Vektor- und Matrizenrechnung

Definitionen

Matrix

Besitzt eine Matrix m Spalten und n Zeilen, wird diese als $(n \times m)$–Matrix bezeichnet. Jedes Element der Matrix ist durch den Zeilenindex i und den Spaltenindex j bestimmt.

$$\underline{A} = \left[a_{i,j}\right]_{n\times m} = \begin{bmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,m} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & a_{n,2} & \cdots & a_{n,m} \end{bmatrix}$$

Vektor

Ein Vektor stellt einen Spezialfall einer Matrix dar und hat entweder nur eine Spalte (Spaltenvektor) bzw. eine Zeile (Zeilenvektor).

$$\underline{B} = \left[b_i\right]_{n\times 1} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} \qquad \underline{C} = \left[c_j\right]_{1\times m} = \begin{bmatrix} c_1 & c_2 & \cdots & c_m \end{bmatrix}$$

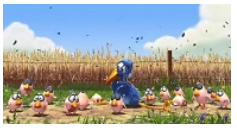
Folie 6.3

Addition zweier $(n \times m)$–Matrizen

Bei gleicher Matrizengröße ist eine Addition zweier Matrizen möglich.

$$\begin{aligned} \underline{E} + \underline{F} &= \left[e_{i,j}\right]_{n\times m} + \left[f_{i,j}\right]_{n\times m} = \left[e_{i,j} + f_{i,j}\right]_{n\times m} \\ &= \begin{bmatrix} e_{1,1} & e_{1,2} & \cdots & e_{1,m} \\ e_{2,1} & e_{2,2} & \cdots & e_{2,m} \\ \vdots & \vdots & \ddots & \vdots \\ e_{n,1} & e_{n,2} & \cdots & e_{n,m} \end{bmatrix} + \begin{bmatrix} f_{1,1} & f_{1,2} & \cdots & f_{1,m} \\ f_{2,1} & f_{2,2} & \cdots & f_{2,m} \\ \vdots & \vdots & \ddots & \vdots \\ f_{n,1} & f_{n,2} & \cdots & f_{n,m} \end{bmatrix} \\ &= \begin{bmatrix} e_{1,1} + f_{1,1} & e_{1,2} + f_{1,2} & \cdots & e_{1,m} + f_{1,m} \\ e_{2,1} + f_{2,1} & e_{2,2} + f_{2,2} & \cdots & e_{2,m} + f_{2,m} \\ \vdots & \vdots & \ddots & \vdots \\ e_{n,1} + f_{n,1} & e_{n,2} + f_{n,2} & \cdots & e_{n,m} + f_{n,m} \end{bmatrix} \end{aligned}$$

Folie 6.4



Multiplikation mit Skalar k

$$k \cdot \underline{A} = k \cdot \left[a_{i,j}\right]_{n\times m} = \left[k \cdot a_{i,j}\right]_{n\times m} = \begin{bmatrix} k\cdot a_{1,1} & k\cdot a_{1,2} & \cdots & k\cdot a_{1,m} \\ k\cdot a_{2,1} & k\cdot a_{2,2} & \cdots & k\cdot a_{2,m} \\ \vdots & \vdots & \ddots & \vdots \\ k\cdot a_{n,1} & k\cdot a_{n,2} & \cdots & k\cdot a_{n,m} \end{bmatrix}$$

$$k \cdot \underline{B} = k \cdot \left[b_i\right]_{n\times 1} = \left[k \cdot b_i\right]_{n\times 1} = \begin{bmatrix} k\cdot b_1 \\ k\cdot b_2 \\ \vdots \\ k\cdot b_n \end{bmatrix}$$

$$k \cdot \underline{C} = k \cdot \left[c_j\right]_{1\times m} = \left[k \cdot c_j\right]_{1\times m} = \begin{bmatrix} k\cdot c_1 & k\cdot c_2 & \cdots & k\cdot c_m \end{bmatrix}$$

Folie 6.5

Multiplikation $(n \times r)$–Matrix mit $(r \times m)$–Matrix

$$\underline{A} = \underline{E} \cdot \underline{H} = \left[a_{i,j}\right]_{n\times m} = \left[e_{i,j}\right]_{n\times r} \cdot \left[h_{i,j}\right]_{r\times m}$$

$$= \begin{bmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,m} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & a_{n,2} & \cdots & a_{n,m} \end{bmatrix}$$

$$= \begin{bmatrix} e_{1,1} & e_{1,2} & \cdots & e_{1,r} \\ e_{2,1} & e_{2,2} & \cdots & e_{2,r} \\ \vdots & \vdots & \ddots & \vdots \\ e_{n,1} & e_{n,2} & \cdots & e_{n,r} \end{bmatrix} \cdot \begin{bmatrix} h_{1,1} & h_{1,2} & \cdots & h_{1,m} \\ h_{2,1} & h_{2,2} & \cdots & h_{2,m} \\ \vdots & \vdots & \ddots & \vdots \\ h_{r,1} & h_{r,2} & \cdots & h_{r,m} \end{bmatrix}$$

$$\text{mit} \quad a_{i,j} = \sum_{k=1}^{r} e_{i,k} \cdot h_{k,j} \qquad i = 1 \ldots n, \;\; j = 1 \ldots m$$

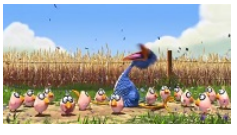
Folie 6.6

Beispiel Multiplikation

$$\underline{A} = \underline{E} \cdot \underline{H} = \left[a_{i,j}\right]_{2\times 1} = \left[e_{i,j}\right]_{2\times 3} \cdot \left[h_{i,j}\right]_{3\times 1}$$

$$= \begin{bmatrix} a_{1,1} \\ a_{2,1} \end{bmatrix} = \begin{bmatrix} o & p & q \\ r & s & t \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} o\cdot x + p\cdot y + q\cdot z \\ r\cdot x + s\cdot y + t\cdot z \end{bmatrix}$$

$$\text{mit} \quad a_{i,j} = \sum_{k=1}^{3} e_{i,k} \cdot h_{k,j} \qquad i = 1, 2, \;\; j = 1$$



Alternatives Rechenschema:

$$\begin{array}{c|c} & \begin{bmatrix} x \\ y \\ z \end{bmatrix} \\ \hline \begin{bmatrix} o & p & q \\ r & s & t \end{bmatrix} & \begin{bmatrix} o \cdot x + p \cdot y + q \cdot z \\ r \cdot x + s \cdot y + t \cdot z \end{bmatrix} \end{array}$$

Folie 6.7

Transponierte

$$\underline{A}^T = \left[a_{i,j}\right]^T_{n\times n} = \left[a_{j,i}\right]_{n\times n}$$

$$= \begin{bmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & a_{n,2} & \cdots & a_{n,n} \end{bmatrix}^T = \begin{bmatrix} a_{1,1} & a_{2,1} & \cdots & a_{n,1} \\ a_{1,2} & a_{2,2} & \cdots & a_{n,2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1,n} & a_{2,n} & \cdots & a_{n,n} \end{bmatrix}$$

$$\underline{B}^T = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}^T = \begin{bmatrix} b_1 & b_2 & \cdots & b_n \end{bmatrix} \qquad \underline{C}^T = \begin{bmatrix} c_1 & c_2 & \cdots & c_m \end{bmatrix}^T = \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_m \end{bmatrix}$$

Folie 6.8

Symmetrie $(n \times n)$–Matrix

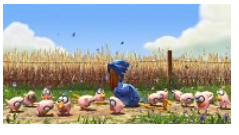
Eine Symmetrie existiert nur bei einer quadratischen $(n \times n)$–Matrix.

$$\underline{A} = \underline{A}^T = \left[a_{i,j}\right]_{n\times n} = \left[a_{i,j}\right]^T_{n\times n} \qquad \text{mit} \quad a_{i,j} = a_{j,i} \quad \forall\, i,j$$

Beispiel Symmetrie

$$\underline{A} = \underline{A}^T = \begin{bmatrix} 0 & 1 & 2 & 3 \\ 1 & 4 & 5 & 6 \\ 2 & 5 & 7 & 8 \\ 3 & 6 & 8 & 9 \end{bmatrix}$$

Folie 6.9



Inverse $(n \times n)$–Matrix

Die Inverse lässt sich nur bei einer quadratischen $(n \times n)$–Matrix bilden.

$$\underline{A}^{-1} = \left[a_{i,j}\right]_{n\times n}^{-1} = \frac{1}{\mathrm{Det}(\underline{A})} \cdot \Big(\mathrm{Adj}(\underline{A})\Big)^T \qquad \text{mit} \quad \mathrm{Det}(\underline{A}) \neq 0$$

$\mathrm{Det}(\underline{A})$: Determinante[1] von $\underline{A}$ $\mathrm{Adj}(\underline{A})$: Adjunkte[1] von $\underline{A}$

Beispiel Inverse:

$$\underline{A}^{-1} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{a\cdot d - b\cdot c} \cdot \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

$$\underline{A}^{-1} = \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix}^{-1} = \mathrm{Det}(\underline{A}) \cdot \begin{bmatrix} e\cdot i - f\cdot h & c\cdot h - b\cdot i & b\cdot f - c\cdot e \\ f\cdot g - d\cdot i & a\cdot i - c\cdot g & c\cdot d - a\cdot f \\ d\cdot h - e\cdot g & b\cdot g - a\cdot h & a\cdot e - b\cdot d \end{bmatrix}$$

$$\mathrm{Det}(\underline{A}) = \frac{1}{a\cdot e\cdot i + b\cdot f\cdot g + c\cdot d\cdot h - c\cdot e\cdot g - b\cdot d\cdot i - a\cdot f\cdot h}$$

Folie 6.10

Spur $(n \times n)$–Matrix

Die Spur lässt sich nur bei einer quadratischen $(n \times n)$–Matrix bilden.

$$\mathrm{Tr}(\underline{A}) = \sum_{i=1}^{n} a_{i,i} = a_{1,1} + a_{2,2} + \cdots + a_{n,n} \qquad \text{mit} \quad \underline{A} = \left[a_{i,j}\right]_{n\times n}$$

Beispiel Spur:

$$\underline{A} = \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix} \qquad \mathrm{Tr}(\underline{A}) = a + e + i$$

Folie 6.11

Einheitsmatrix $(n \times n)$–Matrix

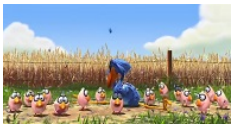
Die Einheitsmatrix existiert nur bei einer quadratischen $(n \times n)$–Matrix.

$$\underline{I} = \left[a_{i,j}\right]_{n\times n} \qquad \text{mit} \quad a_{i,j} = \begin{cases} 1 & \text{falls } i = j \\ 0 & \text{falls } i \neq j \end{cases}$$

$$\underline{I} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}$$

Folie 6.12

[1] Zur Berechnung der Determinante und der Adjunkte siehe z. B. Strampp, W. „Lineare Algebra mit Mathematica und Maple“ [7].



Definitheit von Matrizen

Für $\underline{A} = \left[a_{i,j}\right]_{n\times n}$ $\underline{X} = \left[x_j\right]_{1\times m}$ gilt falls:

- $\underline{X}\cdot\underline{A}\cdot\underline{X}^T > 0$: Matrix $\underline{A}$ positiv definit
- $\underline{X}\cdot\underline{A}\cdot\underline{X}^T \geq 0$: Matrix $\underline{A}$ positiv semidefinit
- $\underline{X}\cdot\underline{A}\cdot\underline{X}^T < 0$: Matrix $\underline{A}$ negativ definit
- $\underline{X}\cdot\underline{A}\cdot\underline{X}^T \leq 0$: Matrix $\underline{A}$ negativ semidefinit

Beispiel: Definitheit

$$\underline{A} = \begin{bmatrix} 1 & -2 \\ 2 & 3 \end{bmatrix}$$

$$\underline{X}\cdot\underline{A}\cdot\underline{X}^T = \begin{bmatrix} x_1 & x_2 \end{bmatrix}\cdot\begin{bmatrix} 1 & -2 \\ 2 & 3 \end{bmatrix}\cdot\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1^2 + 3\cdot x_2^2$$

Die Matrix $\underline{A}$ ist positiv semidefinit.

Folie 6.13

Wichtige Rechenregeln für Matrizen

Für $\underline{A} = \left[a_{i,j}\right]_{n\times m}$ $\underline{B} = \left[b_{i,j}\right]_{n\times m}$ $\underline{C} = \left[c_{i,j}\right]_{n\times m}$ k : skalar gilt:

$$\underline{A}-\underline{A} = \underline{0} \qquad \underline{A}+\underline{0} = \underline{A}$$

$$\underline{A}+\underline{B} = \underline{B}+\underline{A} \qquad (\underline{A}+\underline{B})+\underline{C} = \underline{A}+(\underline{B}+\underline{C})$$

$$k\cdot(\underline{A}+\underline{B}) = k\cdot\underline{A}+k\cdot\underline{B} \qquad \underline{A}\cdot\underline{B} \neq \underline{B}\cdot\underline{A}$$

Für $\underline{D} = \left[d_{i,j}\right]_{n\times n}$ $\underline{E} = \left[e_{i,j}\right]_{n\times n}$ $\underline{F} = \left[f_{i,j}\right]_{n\times n}$ k : skalar gilt:

$$(\underline{D}\cdot\underline{E})\cdot\underline{F} = \underline{D}\cdot(\underline{E}\cdot\underline{F}) \qquad \underline{D}\cdot\underline{E} \neq \underline{E}\cdot\underline{D}$$

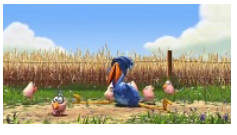
$$\underline{D}\cdot(\underline{E}+\underline{F}) = \underline{D}\cdot\underline{E}+\underline{D}\cdot\underline{F} \qquad (\underline{E}+\underline{F})\cdot\underline{D} = \underline{E}\cdot\underline{D}+\underline{F}\cdot\underline{D}$$

$$(\underline{D}^T)^T = \underline{D} \qquad (\underline{D}+\underline{E})^T = \underline{D}^T+\underline{E}^T$$

Folie 6.14

$$\underline{I}\cdot\underline{D} = \underline{D} \qquad \underline{D}\cdot\underline{D}^{-1} = \underline{I}$$

$$(k\cdot\underline{D})^T = k\cdot\underline{D}^T \qquad (\underline{D}\cdot\underline{E})^T = \underline{E}^T\cdot\underline{D}^T$$



Sammlung wichtiger verwendeter Formeln für Matrizen

$$(\underline{X}+\underline{Y})^T = \underline{X}^T + \underline{Y}^T \tag{124}$$
$$(\underline{X}\cdot\underline{Y})^T = \underline{Y}^T \cdot \underline{X}^T \tag{125}$$
$$\mathrm{E}(\underline{X}+\underline{Y}) = \mathrm{E}(\underline{X}) + \mathrm{E}(\underline{Y}) \tag{126}$$
$$\mathrm{E}(\underline{A}\cdot\underline{X}) = \underline{A}\cdot\mathrm{E}(\underline{X}) \tag{127}$$
$$\mathrm{E}(\underline{A}\cdot\underline{X}\cdot\underline{B}) = \underline{A}\cdot\mathrm{E}(\underline{X})\cdot\underline{B} \tag{128}$$
$$\mathrm{Var}(\underline{X}+\underline{Y}) = \mathrm{Var}(\underline{X}) + \mathrm{Var}(\underline{Y}) + 2\cdot\mathrm{Cov}(\underline{X},\underline{Y}) \tag{129}$$
$$\mathrm{Var}(\underline{A}\cdot\underline{X}) = \underline{A}\cdot\mathrm{Var}(\underline{X})\cdot\underline{A}^T \tag{130}$$
$$\mathrm{Cov}(\underline{X},\underline{Y}) = \mathrm{E}(\underline{X}\cdot\underline{Y}) - \mathrm{E}(\underline{X})\cdot\mathrm{E}(\underline{Y}) \tag{131}$$
$$\mathrm{Cov}(\underline{X},\underline{X}) = \mathrm{Var}(\underline{X}) = \mathrm{E}(\underline{X}\cdot\underline{X}^T) - \mathrm{E}(\underline{X})\cdot\mathrm{E}(\underline{X}^T) \tag{132}$$
$$\frac{\partial \mathrm{Tr}(\underline{X}\cdot\underline{B}\cdot\underline{X}^T)}{\partial \underline{X}} = 2\cdot\underline{X}\cdot\underline{B} \qquad \text{wenn } \underline{B} = \underline{B}^T \tag{133}$$
$$\frac{\partial \mathrm{Tr}(\underline{X}\cdot\underline{A})}{\partial \underline{X}} = \underline{A}^T \tag{134}$$
$$\frac{\partial \mathrm{Tr}(\underline{A}\cdot\underline{X}^T)}{\partial \underline{X}} = \underline{A} \tag{135}$$

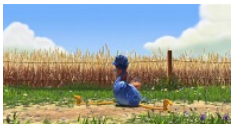
Quelle: Bronstein [8] und Petersen [9]

Folie 6.15

Weiterführende Literatur für Matrizenrechnung

- Ausführliche Beispiele zur Vektor- und Matrizenrechnung findet man z. B. in Koch, J. und Stämpfle, M. „Mathematik für das Ingenieurstudium“ [10].
- Weitere Rechenregeln z. B. zur Differenzial- und Integralrechnung findet man in Petersen, K. B. und Pedersen, M. S. „The Matrix Cookbook“ [9]
- Bzw. in Simon, D. „Optimal State Estimation: Kalman, H Infinity, and Nonlinear Approaches“ [5].

Folie 6.16



Literatur

[1] Marchthaler, Reiner ; Dingler, Sebastian: *Kalman-Filter: Einführung in die Zustandsschätzung und ihre Anwendung für eingebettete Systeme*. Wiesbaden : Springer Fachmedien, 2017. – ISBN 978–3658167271

[2] Wendel, Jan: *Integrierte Navigationssysteme: Sensordatenfusion GPS und inertiale Navigation*. 2. Auflage. München : Oldenbourg, 2011. – ISBN 978 – 3 – 486 – 70572 – 6

[3] Graf, Michael: *Methode zur Erstellung und Absicherung einer modellbasierten Sollvorgabe für Fahrdynamikregelsysteme*. München, Technische Universität München, Dissertation, Juni 2014

[4] Kalata, P.: The tracking index: A generalized parameter for $\alpha - \beta$ and $\alpha - \beta - \gamma$ target tracekrs. In: *IEEE Transactions on Aerospace and Electronic Systems* AES-20 (1984), S. 174–182. http://dx.doi.org/10.1109/TAES.1984.310438. – DOI 10.1109/TAES.1984.310438. – ISSN 0018 – 9251

[5] Simon, Dan: *Optimal State Estimation: Kalman, H Infinity, and Nonlinear Approaches*. Hoboken and NJ : Wiley-Interscience, 2006. – ISBN 0 – 471 – 70858 – 5

[6] Fegyver, Zoltán: *Generate random numbers with a given distribution*. Online aufgerufen bei: http://matlabtricks.com/post-44/generate-random-numbers-with-a-given-distribution, 23. Mai 2017

[7] Strampp, W.: *Lineare Algebra mit Mathematica und Maple: Repetitorium und Aufgaben mit Lösungen*. Vieweg+Teubner Verlag, 2013. – ISBN 978 – 3 – 322 – 80306 – 1

[8] Bronstein, I. N. ; Semendjajew, K. A.: *Taschenbuch der Mathematik*. 25. Auflage. B. G. Teubner Verlagsgesellschaft, Stuttgart, Leipzig und Verlag Nauka, Moskau, 1991

[9] Petersen, K. B. ; Pedersen, M. S.: *The Matrix Cookbook*. online aufgerufen bei: http://www2.imm.dtu.dk/pubdb/p.php?3274, Nov 2012. – Version 20121115

[10] Koch, J. ; Stämpfle, M.: *Mathematik für das Ingenieurstudium*. 2. Auflage. Carl Hanser Verlag München, 2013. – ISBN 978 – 3 – 446 – 43232 – 1

